

大模型的评测基准与自主生态体系

胡事民


清华大学计算机科学与技术系

大纲


- 大模型发展现状
- 计图框架与自主大模型生态
- 大模型评测
- 大模型应用

大模型在人工智能领域的突破性进展

- 2017年, Transformer架构被提出, 以“自注意力机制”重塑了NLP 的研究格局, BERT与GPT等模型也相继崛起, 增强了上下文理解与生成能力。
- 2022年底, ChatGPT问世, 在GPT的基础上, 引入人类反馈强化学习的训练机制和提示导引模式, 促使模型越来越顺应人类的思考逻辑, 更加符合人类认知和习惯。最近, OpenAI-o1、DeepSeek-R1等推理模型, 借助思维链和更加先进的强化学习技术, 正不断突破着复杂问题的解决上限




Transformer 核心架构 (Attention is all you need, 被引179107次)



BERT 核心架构 (Bidirectional Encoder Representations from Transformers, 被引130167次)

大模型在人工智能领域的突破性进展

- 2025年图灵奖授予了Andrew G. Barto 和Richard S. Sutton，以表彰他们对强化学习做出的基础性贡献。
- 如今，强化学习已成为提升大模型性能的核心方法之一，能赋予其更强的推理、决策与环境适应能力，助力大模型向更高效、更智能、更便捷方向发展，为实现通用人工智能奠定基础。



2025年图灵奖得主

RL Enhanced LLMs	Organization	# Params	RL Methods
Instruct-GPT (Ouyang et al., 2022)	OpenAI	1.3B, 6B, 175B	RLHF, PPO
GPT-4 (OpenAI, 2023)	OpenAI	-	RLHF, PPO, RBRM
Gemini (Team et al., 2023)	Google	-	RLHF
InternLM2 (Cai et al., 2024)	上海人工智能实验室	1.8B, 7B, 20B	RLHF, PPO
Claude 3 (Anthropic, 2024)	ANTHROPIC	-	RLAIF
Reka (Team et al., 2024c)	Reka	7B, 21B	RLHF, PPO
Zephyr (HuggingFaceH4, 2024)	Argilla	141B-A39B	ORPO
Phi-3 (Abdin et al., 2024)	Microsoft	3.8B, 7B, 14B	DPO
DeepSeek-V2 (Liu et al., 2024a)	deepseek	236B-A21B	GRPO
ChatGLM (GLM et al., 2024)	ZHIPU AI	6B, 9B	ChatGLM-RLHF
Nemotron-4 340B (Adler et al., 2024)	NVIDIA	340B	DPO, RPO
Llama 3 (Dubey et al., 2024)	Meta	8B, 70B, 405B	DPO
Qwen2 (Yang et al., 2024a)	Alibaba	(0.5-72)B, 57B-A14B	DPO
Gemma2 (Team et al., 2024b)	Google	2B, 9B, 27B	RLHF
Starling-7B (Zhu et al., 2024)	Berkeley	7B	RLAIF, PPO
Athene-70B (Nexusflow, 2024)	Nexusflow	70B	RLHF
Hermes 3 (Teknium et al., 2024)	NOUS	8B, 70B, 405B	DPO
o1 (OpenAI, 2024b)	OpenAI	-	RL through CoT

主流的大模型大都借助强化学习来提升模型性能

国际人工智能发展现状

- 在国际上，人工智能大模型已成为数字时代大国科技战略博弈的焦点。美国很早就将发展人工智能明确为国家战略，通过加大投资力度、成立特别工作组等方式推动人工智能发展，并不断寻求对从芯片设计到模型训练的全产业链垄断，为大模型的广泛应用打下良好基础。



美国政府联合相关企业推出超大规模人工智能基础设施建设计划（Star Gate）旨在为推出性能更强的基座大模型提供巨量算力支持



美国拥有20万张GPU的超算工厂

国际人工智能发展现状

- 欧洲人工智能大模型以开源和规制为特色，如法国的人工智能企业Mistral AI强调数据隐私与合规性，德国的Aleph Alpha体现了对透明度和可解释性的重视，DeepL提供高质量翻译服务。
- 日韩等国的人工智能大模型聚焦于垂直领域，如日本的医疗影像分析模型和韩国的智能客服系统发展较快，但总体来看其影响力与中美相比存在差距。



在2025年法国巴黎召开的人工智能行动峰会前后，法国和欧盟都宣布了千亿欧元级AI投资计划




欧洲代表性人工智能应用




富士胶片推出了 NURA，采用 AI 增强医疗检查技术的健康检查中心

以DeepSeek为首的国产大模型发展现状

- 2024年12月，杭州深度求索人工智能基础技术研究有限公司 (DeepSeek)先后上线大语言基座模型DeepSeek V3，以及基于V3训练、专为复杂推理任务设计的DeepSeek R1模型，并同步开源。它们以卓越的性能超越或接近了全球顶级的开源、闭源模型，引起了全球各界的广泛关注。



DeepSeek与其他模型的性能对比结果（深蓝色）



OpenAI CEO对DeepSeek的评价



特朗普对DeepSeek的评价

以DeepSeek为首的国产大模型发展现状

- DeepSeek在2024年迭代了3个版本，最显著的优势在于其惊人的成本效益。其训练成本约为Llama的十分之一。此外，DeepSeek在推理方面表现出色，并且在特定领域能够表现出更高的准确性和效率。

模型/指标	DeepSeek V1	DeepSeek V2	DeepSeek V3	Llama 3.1
发布时间	2024年1月	2024年6月	2024年12月	2024年7月
训练 Token	2 T	8.1 T	14.8 T	15T
模型规模	7B、67B	236B / 激活21B	671B / 激活37B	405B
模型架构	稠密	MoE 2+160	MoE 1+256	稠密
训练成本	300.6K GPU Hours	172.8K GPU Hours	2.788 M GPU Hours	30.84 M GPU Hours
关键技术	LlAMA、GQA	MLA、MoE	FP8、RL	N.A
上下文长度	4K	128K	128K	128K



DeepSeek 下棋骗赢了 ChatGPT

以DeepSeek为首的国产大模型发展现状

■ DeepSeek的出现对国内外产生了很大影响

时间	事件
2025-01-28	英伟达股价下跌17%，市值蒸发5900亿美元
2025-01-31	英伟达、亚马逊和微软宣布接入DeepSeek-R1
2025-02-01	华为云宣布接入DeepSeek-R1
2025-02-02	腾讯云宣布接入DeepSeek-R1
2025-02-03	阿里云和百度云宣布接入DeepSeek-R1
2025-02-03	DeepSeek占据140多个国家App Store下载排行榜首位

以DeepSeek为首的国产大模型发展现状

- 除DeepSeek外，以豆包、通义千问、混元、快手等为代表的通用大模型和视频大模型正如雨后春笋般涌现，国产大模型产业的落地应用将进一步加速，广泛赋能经济社会各个领域，开启迈向通用人工智能的新时代，并推动新一轮科技革命与产业变革。



阿里推出通义千问3版模型，在数学和编程等多个方面均可与DeepSeek的性能相媲美。还显著降低了部署成本。Qwen3无缝集成两种思考模式，便于Agent调用。



字节跳动推出全新Doubao-1.5-pro 模型综合能力显著增强，在多个权威测评基准上获得最佳成绩，综合得分优于 GPT4o、Claude 3.5 Sonnet等业界一流模型



腾讯推出HunyuanVideo是一个基于DiT架构的文生视频模型，参数量达到了13B，这是目前业界最大的开源视频生成模型。评测结果显示其优于Runway 3和Luma 1.6




快手推出的可灵2.0模型在动态质量、语义响应、画面美学等维度，保持全球领先对比谷歌 Veo2的胜负比为182%，对比Runway的Gen-4的胜负比达178%

DeepSeek的发展带给我们的启示


- 创新是生命力：通过MoE、GRPO架构的创新与软硬件协同优化，实现了系统性能的飞跃；
- 开源不仅无限扩展了生态和影响力，还推动了AI技术的普惠与平权；
- 虽然技术突破显著降低了训练成本，但前期巨大的投入和探索风险依然需要谨慎对待；
- 媒体盲目炒作和蹭热点，权威媒体需要及时、客观、理性地宣传科技成果；
- 对科技创新体制的影响和将带来的变革。

中美人工智能对比

- 人工智能创新指数和活力排名是反映国家人工智能创新水平的重要指标。自指数创建五年来，美国一直排名全球第一，中国从2020年起近四年一直排名第二。在人工智能活力排名中、中国和美国稳居前二，明显高于其他国家



部分参评国家人工智能创新指数得分与排名
来源：《2023全球人工智能创新指数报告》
(中国科学技术信息研究所&北大)



全球人工智能活力排名
来源：2024年《全球AI活力工具》(斯坦福大学)

中美人工智能对比

- 在大模型领域，美国2024年发布40个顶尖模型，中国为15个，虽然美国在生产重要AI模型数量上依然保持领先地位，但中美顶级AI模型性能差距正大幅和迅速缩小




Figure 1.3.1¹⁷




Figure 1.3.2




Figure 2.1.36


中美重要模型数量对比
来源：2025年《人工智能指数报告》（斯坦福大学）

近年中美两国顶级模型在LMSYS表现
来源：2025年《人工智能指数报告》（斯坦福大学）

中美人工智能对比

- 在科研领域，中国在AI论文总量(占全球23.2%)和专利(69.7%)上领先，而美国则在高影响力研究(Top 1%高被引论文)中占优，连续三年保持了最多的高被引论文数量。


AI publication citations in CS (% of total) by select geographic areas, 2013-23
Source: AI Index, 2025 | Chart: 2025 AI Index report



AI论文数量对比

来源：2025年《人工智能指数报告》
(斯坦福大学)


Granted AI patents (% of world total) by select geographic areas, 2010-23
Source: AI Index, 2025 | Chart: 2025 AI Index report



专利数量对比

来源：2025年《人工智能指数报告》
(斯坦福大学)

Number of highly cited publications in top 100 by select geographic areas, 2021-23
Source: AI Index, 2025 | Chart: 2025 AI Index report




近三年高被引论文数量对比

来源：2025年《人工智能指数报告》
(斯坦福大学)

从AI的技术体系看中美人工智能差距

■ 正视中美人工智能差距（高端芯片、国产生态、原始创新）




大纲

- 大模型发展现状
- 计图框架与自主大模型生态
- 大模型评测
- 大模型应用


驱动第三次人工智能浪潮的**技术体系**

- 在**算力**支撑下，平台化**编程框架**、**算法**和**数据**的开源开放，形成良性轮动的生态体系，促进了人类智慧的汇聚，推动了人工智能技术的创新发展。




为什么框架重要？以AlexNet为例

输出1000类别概率分布




Alex Krizhevsky和Geoffrey E. Hinton等的NIPS2012论文
ImageNet Classification with Deep Convolutional Neural Networks



- ← 最大池化操作
- ← 在特征维度上做局部响应归一化
- ← 11*11卷积核，步长为4个像素/ReLU非线性

为什么框架重要？以AlexNet为例




$$L = \text{cross_entropy}(F(x; \theta), y)$$

计算导数 $\partial L / \partial \theta$ 并使用梯度下降等方法更新参数 θ

=》深度学习框架


以深度学习框架为牵引，夯实我国AI生态

- 深度学习框架(平台)是人工智能的核心技术，负责深度学习模型的训练和推理
 - ◆ 管理着人工智能应用所需要的大规模数据和模型，为上层算法和应用提供编程软件平台
 - ◆ 统一调度和管理底层的计算资源，充分发挥计算潜力



深度学习框架-计图(Jittor)

- 计图(Jittor): 一个自主的高效深度学习框架; 实现了对Pytorch的性能超越和对国产芯片的快速适配和性能优化




测试结论:

“计图 Jittor 1.3.8.5”在功能性、性能效率、可靠性方面满足系统测试需求的相关要求。测试结果表明,与Pytorch对比,“计图 Jittor 1.3.8.5”执行速度更高,占用显存更小。在测试过程中,系统运行稳定,通过了中国软件评测中心(工业和信息化部软件与集成电路促进中心)的软件产品技术鉴定测试。

中国软件评测中心(工业和信息化部软件与集成电路促进中心)




中国软件评测中心评测结论



国产芯片适配


深度学习框架-计图(Jittor)

- **创新1：** 提出元算子概念和元算子融合策略，只需三类18个元算子即可融合得到深度学习计算所需的算子，易于优化、扩展和维护，硬件适配性强。



深度学习框架-计图(Jittor)

- 创新2：提出统一计算图思想，采用动态切分、静态子图融合的计算策略，兼顾动态图灵活和静态图高效的特点，支持跨迭代融合。




静态图算图

- 静态子图融合
- 静态子图优化
- 兼顾效率和灵活性


静态算图发送

静态子图

静态子图



元算子融合



元算子融合




计算设备 NVIDIA intel HUAWEI Ascend 中科曙光 Sugon

高效丰富的Jittor模型库

■ 涵盖计算机视觉、计算机图形学、自然语言处理等



语义分割模型库：11个算法模型、4个数据集
相比于PyTorch，可缩短训练时间30%左右




实例分割模型库：6种经典实例分割模型和人体Pose的实例分割
推理速度提升35%左右




遥感图像解译库：20种检测模型，国内最全开源库
训练速度较pytorch快约20%



图像对抗生成库：27种模型
速度最快是 pytorch 的 3.83 倍，平均速度是 2.26 倍



医疗图像库：28种模型



JRender：唯一支持PBR材质、环境遮挡、软阴影、全局光照以及次表面散射的可微渲染库
JNeRF：5秒完成三维重建的训练




图3:点云分割结果示例




图4: Jittor 与 Pytorch 速度对比

三维点云库：支持多种模型，加速效果显著



ChatGLM



稟临科技 ChatRWKV




盘古



LLaMA

大模型库：训练推理均有大幅提升




异构软硬件适配与迁移

- 基于元算子融合，实现了框架和硬件的高效适配以及模型在框架间的快速迁移，支持新兴芯片快速融入既有生态。



基于元算子融合的快速硬件适配




异构软硬件适配与迁移

- 基于元算子融合，实现了框架和硬件的高效适配以及模型在框架间的快速迁移，支持新兴芯片快速融入既有生态。




基于元算子融合的快速硬件适配



异构软硬件适配与迁移


- 基于元算子融合，实现了框架和硬件的高效适配以及模型在框架间的快速迁移，支持新兴芯片快速融入既有生态。



- 支持主流的国产操作系统

基于国产软硬件的大模型训练面临的挑战


- **算力瓶颈**：大模型训练需要海量算力，国产芯片性能与国际顶尖水平仍有差距。
- **模型优化**：大模型结构复杂，参数量巨大，优化难度大，国产硬件架构上难适配。




基于计图框架的大模型高效训练

■ 训练与微调


◆ 分布式训练：实现多类并行模式并高效结合



数据并行



模型并行




流水并行


基于计图框架的大模型高效训练

■ 训练与微调

- ◆ 分布式训练：实现多类并行模式并高效结合
- ◆ 海量训练数据采样优化：预计算所有训练文档索引，在不占用大量存储和内存资源的同时实现快速采样



HuggingFace 数据处理采样



基于索引的均匀随机采样(计图)

基于计图框架的大模型高效训练

■ 训练与微调

- ◆ 分布式训练：实现多类并行模式并高效结合
- ◆ 海量训练数据采样优化：预计算所有训练文档索引，在不占用大量存储和内存资源的同时实现快速采样
- ◆ 逐层梯度裁剪：减小梯度范围，避免“梯度爆炸”，在不影响收敛速度情况下减少了6%显存，训练加速10%

$$G_i = G_i / \max(1, \sqrt{|\Sigma G_i^2|})$$

梯度裁剪

G_i 为模型的第*i*个参数



$$G_i^L = G_i^L / \max(1, \sqrt{|\Sigma (G_i^L)^2|})$$

逐层梯度裁剪

G_i^L 为模型的第*L*层的第*i*个参数

基于计图框架的大模型高效训练

■ 支持多种大模型的训练与微调



模型大小	微调数据量	GPU	时间	成本
7B	51K条	2 A800	6小时	¥80
13B	51K条	4 A800	6小时	¥160

■ 相比Deepspeed+PyTorch，Jittor具有以下优势

- ◆ 训练和微调速度提升**20%**
- ◆ 内存消耗减少**30%**，大大提升模型训练规模，最大可支持万亿级别的模型训练





训练Loss曲线比较

Input: 清华校歌的第一句是什么?
Response: 清华校歌的第一句是“西山苍苍，东海茫茫，吾校庄严，泱泱然中央。”

微调示例


全量预训练的实践

- 帮助企业利用全量数据预训练7B-13B的大模型，相比 LLaMA2，收敛更快，loss更低
 - ◆ 250B-1T tokens的中文通用文本
 - ◆ 青海算力中心100P算力，训练 1-2 个月



基于国产软硬件的大模型推理面临的挑战


- **性能要求**：用户对推理反应速度和吞吐量要求高，国产推理芯片性能需进一步提升。
- **算力限制**：在算力不足的情况下，大参数量模型和长上下文理解对国产硬件提出了更高的推理加速要求。
- **部署成本**：经济高效的部署方案缺乏，硬件成本高。



基于计图框架的大模型高效推理

■ 推理库

- ◆ **动态swap机制**：通过内存直通读取，减少内存拷贝次数；相比PyTorch，模型加载效率提升40%。




加载CodeGeeX2 6B用时

Jittor	PyTorch
7s	12s

基于计图框架的大模型高效推理

■ 推理库

- ◆ **动态swap机制**：通过内存直通读取，减少内存拷贝次数；相比PyTorch，模型加载效率提升40%。
- ◆ **统一内存管理**：基于元算子的内存切分技术与统一内存管理，使得数据可以在显存，内存和硬盘之间快速切换



运行CodeGeeX2 6B速度(fp16)

资源配置	Jittor	PyTorch
TITAN RTX 24G	21 token/s	20 token/s
RTX3050 4G	2 token/s	无法运行
CPU 6G	0.3 token/s	无法运行

基于计图框架的大模型高效推理

■ 推理库

- ◆ **动态swap机制**：通过内存直通读取，减少内存拷贝次数；相比PyTorch，模型加载效率提升40%。
- ◆ **统一内存管理**：基于元算子的内存切分技术与统一内存管理，使得数据可以在显存，内存和硬盘之间快速切换
- ◆ 采用PagedAttention、FlashAttention、FlashDecoder等技术减少冗余的显存占用和GPU计算，实现低延迟、高吞吐推理


推理优化

- 定制化 GPU kernel 实现
- 自适应低精度量化
- 多卡加速优化



优化效果

目前已经将15B大模型加速到原版PyTorch实现的10倍以上，比 OpenAI api、Huggingface tgi、vllm 更快。



计图大语言模型库

- **成本低**：相比同类框架，本库可大幅降低硬件配置要求(内存显存减少80%)，人人皆可在普通机器上，实现大模型本地部署；
- **支持广**：华为盘古大模型；清华唐杰团队的ChatGLM大模型；blinkdl的ChatRWKV；国外Meta的LLAMA大模型；复旦大学NLP团队的MOSS大模型；阿里云的通义千问大模型；深度求索的DeepSeek大模型；
- **自主可控**：支持软硬件异构化，Pytorch被J Torch和Jittor替代后，速度全面提升；

同时，我们也提供了由深度学习框架 **计图Jittor** 支持的MOSS模型，您可以通过运行仓库中的

`moss_cli_demo_jittor.py` 来启动命令行Demo。计图能够在显存不足时通过内存交换大幅度减少显存的消耗。首先确保您安装了 **Jittor** 和 `cupy`：



```
pip install jittor
pip install cupy-cu114 # 根据您的 cuda 版本决定
```

接着运行下面的命令：

```
python moss_cli_demo.py --model_name fnlp/moss-moon-003-sft --gpu
```

华为昇腾910B上计图大模型推理

■ 为了支持 LLaMA 7B, ChatGLM等模型，做到所有算子对齐，输出结果正确，我们：

- ◆ 基于华为的CANN异构计算架构适配了100+深度学习的常用算子
- ◆ 构造了一套基于华为硬件-计图框架的效率、显存分析方法
- ◆ 基于并查集和拓扑排序的融合算子的动态显存回收，减少了显存
- ◆ 优化 GEMM 转置操作逻辑，减少冗余算子调用，加速基础矩阵乘法
- ◆ 适配针对大模型优化的加速算子，如FlashAttention、RoPe等。
- ◆ 针对计图算子在华为CPU上的发射机制进行优化

华为昇腾910B上计图大模型推理

- 目前已支持 LLaMA 7B, ChatGLM 模型, 所有算子对齐, 输出结果正确

用户输入: Can you explain briefly to me what is the Python programming language?

LLaMA : Python is a high-level programming language for general-purpose programming. It has a dynamic type system and a very high-level, dynamic, and flexible syntax. It supports multiple programming paradigms, including object-oriented, imperative, functional, and procedural styles. It provides constructs intended to enable clear programs on both a small and large scale. The language was designed to be highly dynamic, with special support for unit testing and integration with other languages.

用户输入: What were the main causes and outcomes of the French Revolution?

LLaMA : As a result of the French Revolution, the French monarchy was replaced by a republic, the Roman Catholic Church lost much of its power, and King Louis XVI and his wife Marie Antoinette were executed.

华为 LLaMA 推理效果展示

What is Machine Learning?


Machine Learning is the process of training a machine (a computer program) to learn from data, rather than being explicitly programmed.

华为 ChatGLM 推理效果展示

DeepSeek模型在华为昇腾910上的高效推理

- 在模型能力突飞猛进的同时，围绕其推理效率与部署灵活性的研究也日益成为业界关注焦点，涌现出以vLLM 等为代表的一系列高性能推理框架，然而，其优化主要针对于英伟达的 CUDA 生态，存在对国外硬件平台依赖强、适配国产硬件成本高等问题，制约了大模型在国产算力平台上的规模化部署能力。

- 为打通大模型国产芯片部署的全栈技术，构建安全可控、性能优越的大模型国产化部署解决方案。清华大学计图团队与南开大学



PyTorch



NVIDIA



件入国产算力的深度融合实践。

DeepSeek模型在华为昇腾910上的高效推理

- DeepSeek模型适配华为硬件平台面临一系列复杂、严峻的挑战：
 - ◆ **生态不完善**：作为最优秀的国产芯片，华为芯片的生态系统仍处于持续完善阶段，与英伟达相比，在生态上还有差距
 - ◆ **优化算法跨设备适配难**：在英伟达设备上的优化经验难以直接应用于华为设备；
 - ◆ **华为芯片显存限制**：当前主流模型大多基于A100、H20、H200等英伟达设备的强大算力与充足显存进行设计。然而，华为设备的显存相对较小，这导致模型在推理过程中频繁出现显存不足的问题。



DeepSeek模型在华为昇腾910上的高效推理

- 经过团队的不懈努力，完成了DeepSeek V2 Lite (16B)、DeepSeek V2 (236B) 以及DeepSeek R1 (671B) 模型在华为昇腾硬件平台上的适配与性能优化。主要成果如下：
 - ◆ **算子实现**：实现华为芯片上的DeepSeekMoE、具有外扩功能的旋转编码 (RoPE: Rotary Position Embedding)，并进行算子实现层面的优化与量化。
 - ◆ **内存布局**：实现基于矩阵吸收的MLA，大幅减少模型显存占用。
 - ◆ **并行策略**：包括实现华为芯片上的张量并行、专家并行和数据并行等关键环节的并行优化。
 - ◆ **服务端优化**：通过加速 Continuous Batching 机制，有效提升高并发场景下的推理吞吐与响应效率。

DeepSeek模型在华为昇腾910的高效推理


- 通过对模型算子权重进行 Int4 量化优化，显著降低了显存占用，首次实现单台华为8卡服务器上的DeepSeek R1的推理，同时在DeepSeek V2的推理性能比vLLM(Ascend版本)在不同请求下，平均提升53%以上。是一套自主可控的推理优化方案

请求数	vLLM-Ascend (token/s)	Our (token/s)	加速比
1	无法运行	3.0	N/A

单机(8卡)运行 DeepSeek R1 速度

请求数	vLLM-Ascend (token/s)	Our (token/s)	加速比
1	4.3	8.3	93.0%
2	7.8	15.5	98.7%
3	15.6	27.2	74.3%
8	26.3	49.5	88.2%

单机(8卡)运行 DeepSeek V2 速度



单机(8卡)运行 DeepSeek V2


大纲

- 大模型发展现状
- 计图框架与自主大模型生态
- 大模型评测
- 大模型应用

大模型评测背景


- 随着大模型能力迅速提升，传统基准如 MMLU、GSM8K、HumanEval 等已接近饱和，其测试难度已无法充分区分先进模型的性能差异，许多模型在这些基准上接近甚至超过人类水平。例如，o1模型在MMLU上达到了92.3%的准确率，大模型的发展需要更具挑战性的评估基准

MMLU: average accuracy
Source: Papers With Code, 2025 | Chart: 2025 AI Index report



大模型在MMLU数据集上表现已接近人类水平


HumanEval: Pass@1
Source: Papers With Code, 2025 | Chart: 2025 AI Index report



大模型在HumanEval数据集上表现已经趋于100%

$\mathcal{R}$ -Bench: 竞赛难度的多学科复杂推理评测基准

- 提出了一种融合模型推理思维链机制与人类专家参与的“主客观协同”推理数据引擎构建方案。基于此构建了一个全面、可靠的多学科推理评测基准 $\mathcal{R}$ Bench，全面系统地评估了目前已有大模型的推理能力，并为模型发展提供明确方向，论文已被ICML录用。



评测集特点


- **全面性**: 可以评估模型的多方面能力, 而非仅关注某一技能如数学推理。
- **多模态**: 可以同时评估语言模型和多模态模型
- **多语言**: 可以检验模型在多种语言下解决同样问题的能力, 以识别其是否真正具备泛化推理能力。

拓宽了评估维度, 推动模型能力评估从“知识记忆”走向“推理认知”

不同的模型提供区分度展提供指导。

数据引擎 workflow


- **第一步：** 根据清华大学 19 个院系的本科生和研究生的培养方案，制定收集学科列表。
- **第二步：** 在各个院系招募高年级本科生和研究生为我们提供“复杂推理”题目。(专家筛选)
- **第三步：** 超过 20 人的数据团队，将得到的题目进行数字化，即将截图、PPT、照片，pdf 等各类格式的题目全部人工转化为文本（txt）格式，以方便测试。



数据引擎 workflow


- **第四步：**使用 OpenAI o1 模型对题目的难度进行二次筛选，过滤掉 o1 思考tokens小于 2000 的题目，确保题目难度 (**模型筛选**)
- **第五步：**过滤题意不清晰、题目不完整、重复的题目。 (**人工筛选**)
- **第六步：**对剩余的题目构造选项和翻译，以方便后续的评估。

系统性构建高质量复杂推理题目，打造具有长期可扩展性的高水平推理评测基准




$\mathcal{R}$ Bench 总览

- $\mathcal{R}$ Bench覆盖数学、物理、生物、计算机科学、化学等领域，细化至无机化学、反应动力学、电磁学等 100 余个学科，共包含 1,094 道题目用于语言模型测试，其中 665 道专门用于评估多模态推理能力。



(a) Statistics of $\mathcal{R}$ -Bench-T



(b) Statistics of $\mathcal{R}$ -Bench-M

RBench 数据示例

- 相比已有的评测基准 RBench 是多学科、多模态和多语言的，并且题目复杂，而非通过记忆知识就可以解决。

Examples for language models reasoning ability test		Art & Design	Business	Science
Major: computer science; Subject: data structure. In the undirected graph $G=(V,E)$ where $V=\{1,2,3,4,5,6,7\}$ and $E=\{(1,2), (1,3), (2,3), (4,5), (3,6), (4,7), (5,7)\}$, how many different spanning forests does the graph G contain? Note: If the edge sets of two spanning forests are different, they are considered different spanning forests. A: 14 B: 9 C: 10 D: 12 E: 11 F: All other answers are incorrect	Major: math; Subject: complex variable function. English Consider the polynomial $p(z) = z^5 + z^3 + 5z^2 + 2$. How many zero points (counting multiplicities) does p have in the annulus $1 < z < 2$? A: 5 B: 3 C: 2 D: All other answers are incorrect E: 4 F: 6 Chinese 考虑多项式 $p(z) = z^5 + z^3 + 5z^2 + 2$. 在环域 $1 < z < 2$ 中 p 有多少个零点 (计入重数)? A: 5 B: 3 C: 2 D: 其他答案都不正确 E: 4 F: 6	Question: Among the following harmonic intervals, which one is constructed incorrectly? Options: (A) Major third <image 1> (B) Diminished fifth <image 2> (C) Minor seventh <image 3> (D) Major sixth <image 4> Subject: Music; Subfield: Music; Image Type: Sheet Music; Difficulty: Medium	Question: ... The graph shown is compiled from data collected by Gallup <image 1>. Find the probability that the selected Emotional Health Index Score is between 80.5 and 82? Options: (A) 0 (B) 0.2142 (C) 0.3571 (D) 0.5 Subject: Marketing; Subfield: Market Research; Image Type: Plots and Charts; Difficulty: Medium	Question: <image 1> The region bounded by the graph as shown above. Choose an integral expression that can be used to find the area of R. Options: (A) $\int_0^{1.5} [f(x) - g(x)] dx$ (B) $\int_0^{1.5} [g(x) - f(x)] dx$ (C) $\int_0^2 [f(x) - g(x)] dx$ (D) $\int_0^2 [g(x) - x(x)] dx$ Subject: Math; Subfield: Calculus; Image Type: Mathematical Notations; Difficulty: Easy
Examples for multimodal models reasoning ability test		Health & Medicine	Humanities & Social Science	Tech & Engineering
Major: mechanical engineering; Subject: theoretical mechanics. English The width of the brick clamp is 25 cm, and the curved rods AGB and GCED are hinged at point G, with dimensions as shown in the figure. Suppose the weight of the brick is $Q = 120\text{N}$ and the force P that lifts the brick acts along the centerline of the brick clamp. The coefficient of friction between the brick clamp and the brick is $f = 0.5$. Determine the maximum value of distance b required to lift the brick using the clamp. A: 9 cm B: 11 cm C: 15 cm D: 20 cm E: 25 cm F: All other answers are incorrect	Chinese 砖夹的宽度为 25 cm，曲杆 AGB 与 GCED 在 G 点铰接，尺寸如图	Question: You are shown subtraction <image 1>, <image 2> and T1 weighted axial on a screening breast MRI. What is the finding in the left breast? Difficulty: Hard	Question: In the political cartoon, the United States is seen as fulfilling which of the following roles? <image 1> Difficulty: Easy	Question: Find the VCE for the circuit shown in <image 1>. Neglect VBE Answer: 3.75 Explanation: ... $I_E = [(V_{EE}) / (R_E)] = [(5\text{ V}) / (4\text{ k-ohm})] = 1.25\text{ mA}$; $V_{CE} = V_{CC} - I_{ERL} = 10\text{ V} - (1.25\text{ mA}) 5\text{ k-ohm}$; $V_{CE} = 10\text{ V} - 6.25\text{ V} = 3.75\text{ V}$ Subject: Electronics; Subfield: Analog electronics; Image Type: Diagrams; Difficulty: Hard

RBench数据集举例

MMMU数据集举例

主流闭源大语言模型评测结果

- 主流闭源大语言模型在R-Bench上的复杂推理能力评测结果，中国和美国顶尖大模型有一定差距。

Model	Date	Average	R-Bench-T	R-Bench-T (zh)
OpenAI o1	2024-12-17	69.6	69.0	70.1
Gemini2.0-Flash-Thinking	2025-01-21	68.0	68.4	67.5
Doubao1.5Pro	2025-01-21	62.7	62.0	63.4
o1-Preview	2024-09-12	62.5	62.3	62.6
o1-mini	2024-09-12	62.0	64.0	59.9
Doubao-Pro	2024-12-15	60.8	60.7	60.8
Claude3.5-sonnet	2024-06-20	57.4	57.5	57.3
GPT-4o	2024-11-20	52.6	53.6	51.6
MiniMax-Text-01	2025-1-14	53.7	53.8	53.6
GLM-Zero-Preview	2024-12-31	51.1	52.6	48.6

主流开源大语言模型评测结果

- 主流开源大语言模型在R-Bench上的复杂推理能力评测结果，开源大模型效果普遍不如闭源大模型。

Model	Date	Average	R-Bench-T	R-Bench-T (zh)	Model	Date	Average	R-Bench-T	R-Bench-T (zh)
DeepSeek-R1	2025-01-22	60.3	61.2	59.3	QWen3-8B	2025-04-28	46.7	47.5	45.9
QWen3-235B	2025-04-28	58.1	57.9	58.4	QWen2.5-7B	2024-09-19	44.1	43.6	44.5
DeepSeek-V3	2024-12-26	58.1	59.6	56.6	InterLM3-8B	2025-01-15	43.4	41.1	45.8
QWen3-32B	2025-04-28	53.3	52.3	54.3	Gemma-2-27B	2024-06-28	37.4	36.0	38.9
QWen2.5-72B	2024-09-19	52.9	53.7	52.0	GLM-4-9B-chat	2024-11-25	29.0	25.6	32.4
Phi-4-14B	2024-12-12	51.3	55.3	47.3	Phi-3-14B	2024-04-26	26.9	29.5	24.4
QWen2.5-32B	2024-09-19	50.4	50.8	49.9	Llama-3.1-8B	2024-07-23	24.9	26.1	23.6
Llama-3.3-70B	2024-12.06	48.55	49.5	47.6	Llama-3.2-3B	2024-09-26	24.1	24.2	24.0

主流多模态大语言模型评测结果

- 主流多模态大模型在R-Bench上的复杂推理能力评测结果，OpenAI 仍占据首位，中美差距较大

Model	Date	Average	R-Bench-T	R-Bench-T (zh)
OpenAI o1	2024-12-17	53.1	53.2	53.0
Doubao1.5Pro	2025-01-21	40.2	37.9	42.4
Claude-3-5-sonnet	2025-04-10	39.0	39.7	38.3
Gemini1.5-Pro	2024-2-15	35.7	35.9	35.5
GPT-4o	2024-11-20	33.3	33.4	33.2
QWen2.5-72B	2024-09-19	25.4	25.1	25.7
LLaVA-OneVision-7B	2024-08-06	23.7	23.8	23.5
DeepSeek-VL2	2024-12-13	23.1	21.8	24.4
QWen2.5-7B	2024-09-19	21.0	19.6	22.3
Llama3.2V-11B-Instruct	2024-09-25	19.3	20.0	18.6


大纲

- 大模型发展现状
- 计图框架与自主大模型生态
- 大模型评测
- 大模型应用

Fitten Code代码大模型

VSCode 插件市场趋势榜第一

- 非十科技基于计图开发了AI编程助手 Fitten Code，速度准确度超越 OpenAI Copilot 等国内外知名产品
 - ◆ Human-Eval 测试中 FittenCode 代码生成准确率超过其他产品
 - ◆ FittenCode延迟较Copilot快233%，生成速度快36%



	Github Copilot	FittenCode	提升
延迟	平均约1秒	平均约300ms	233%
代码补全量	平均1-2行	平均3-5行	200%
准确率	49.5%	60.1%	21%
价格	每月10美元	免费	N/A


免费使用：<https://code.fittentech.com>

Fitten Code代码大模型


■ 覆盖典型使用场景




根据自然语言生成代码




代码测试




bug查找



代码补全



注释生成




代码编辑


Fitten Code代码大模型

■ 项目级感知的补全和对话

- ◆ 在补全时智能关联项目中相关代码，提升补全准确率
- ◆ 在对话时通过RAG自动检索项目中与对话相关代码，并根据所检索到的结果回答用户的问题





通过@workspace进行整项目对话



可以展示出项目中与提问相关的代码

Fitten Code代码大模型


- 国内首个把自主编码Agent部署在企业版的AI编程助手。
 - ◆ 实现自主决策、主动迭代式调用工具，可以根据任务完成项目级代码生成和修改。用户可以输入一项编程任务，该功能可以智能调用文件查找、代码搜索、联网查询、命令行调试执行、网页快照编译查错、调试执行等工具自动完成编程任务。



Fitten Code代码大模型

■ 管理后台

- ◆ 支持代码编辑追踪与效能分析：可视化看板实时统计日常工作状态，优化项目进程，**降低了30%**的研发成本，帮助技术管理者实现数据驱动的智能决策。



提升研发效率

≈ 30%




AI 生成代码占比

≈ 45%

基于大模型的三维动画创作

- 在动画领域，工业环境下骨骼蒙皮动画仍然是最重要的组成部分，这种算法在驱动一个三角网格形变的时候，需要预先对模型绑定好对应的骨骼和蒙皮才能进行相应的动作驱动。而细致的绑定工作往往需要花费专业人士数小时乃至数天的时间。



蒙皮动画的示意图



蒙皮动画的示意图


基于大模型的三维动画创作

- 大语言模型最常用的架构为自回归模型，其本质是将一个序列下一个词元(token)分布概率利用Transformers进行建模。然后在预测时根据概率分布逐个采样每个token，从而将整个序列完整还原出来。
- 受大语言模型的启发，我们以骨骼为例探索了自回归模型在图形学结构化信息上的生成能力，并结合蒙皮权重预测，用于驱动网格动画

Language Token




Skeleton Token



UniRig: 基于自回归模型的骨骼生成

- 为保证线性混合蒙皮（LBS）算法的可计算性，骨骼会被限制为一棵有根树，树上每个结点对应了一个三维坐标。
- 利用深度优先搜索（DFS）序，以及简单三维坐标离散化，我们可以将一棵骨骼树转化为一个离散的序列。原有的词元现在就变成骨骼，模型依次生成每个骨骼。



UniRig的流程示意图

UniRig: 基于自回归模型的骨骼生成

- Unirig采用了先进的大语言模型架构，相较于此前工作取得了较大的进步和惊艳的效果。朝着实现完全自动化且具备高度泛化能力的绑定流程迈出了关键一步。在大模型的加持下，图形学势必会朝着更智能、更高效、更统一的方向发展。



UniRig的演示视频


基于大模型的三维内容创作

- 复杂且高质量的三维内容制作是电影、游戏与动画等行业的核心环节，然而，即使对于专业领域的从业者而言，由于其高强度的工作量，该制作流程依然充满挑战。我们提出了DIScene，架起了复杂三维场景生成与工业生产流程之间的桥梁。能够根据自然语言描述或参考图像生成包含解耦对象（红色）和清晰交互关系（蓝色）的复杂三维场景，支持持续编辑（绿色）。




用于复杂场景生成的物体解耦与交互建模方法

- 利用可学习的结构化场景图对整个场景进行建模，实现对复杂输入的分解、对象解耦以及交互建模。在接收到灵活输入（图像或文本）后，利用大语言模型和Gaussian重建模型 (GRM) 初始化场景图。场景图中的节点与边采用不同的策略进行渲染，并在得分蒸馏采样引导下进行优化。



用于复杂场景生成的物体解耦与交互建模方法

■ 实验结果



用于复杂场景生成的物体解耦与交互建模方法

- 方法集成到电影、游戏、动画生产管线（Cinema4D）的效果





用于航空航天领域三维设计

“A detailed, high-poly 3D model of the J-20 stealth fighter jet, The jet has a sharp nose, bubble canopy, canard foreplanes, twin engines with vectoring nozzles, canted twin vertical stabilizers, and swept delta wings”




A high-poly 3D model of a cylindrical space module with detailed surface paneling, a complex mechanical rear section, and large rectangular solar panels extending from both sides.



High-poly 3D model of a sci-fi rocket with a modular cylindrical body, armored panels, geometric plating, side boosters, stabilizer fins, a reinforced nose cone, and rear thrusters.



A high-poly 3D model of a modular space station, featuring four cylindrical modules arranged in an X-shape around a central hub. Each module includes surface paneling and mechanical details, with rectangular solar panels extending outward.



敬请批评指正！



公众号：图形学与几何计算

计图(Jittor)合集



Jittor 计图

<https://cg.cs.tsinghua.edu.cn/jittor>