

DeepSeek 系统优化分析

DeepSeek 发展历程

► DeepSeek 2024 年迭代了 3 个版本

模型/指标	DeepSeek V1	DeepSeek V2	DeepSeek V3
发布时间	2024年1月	2024年6月	2024年12月
训练 Token	2 T	8.1 T	14.8 T
模型规模	7B、67B	236B / 激活21B	671B / 激活37B
模型架构	稠密	MoE 2+160	MoE 1+256
训练成本	300.6K GPU Hours	172.8K	2.788 M
关键技术	LlaMA、GQA	MLA、MoE	FP8、RL
上下文长度	4K	128K	128K


DeepSeek 发展历程

► DeepSeek 2024 年迭代了 3 个版本

模型/指标	DeepSeek V1	DeepSeek V2	DeepSeek V3	Llama 3.1
发布时间	2024年1月	2024年6月	2024年12月	2024年7月
训练 Token	2 T	8.1 T	14.8 T	15T
模型规模	7B、67B	236B / 激活21B	671B / 激活37B	405B
模型架构	稠密	MoE 2+160	MoE 1+256	稠密
训练成本	300.6K GPU Hours	172.8K	2.788 M	30.84 M
关键技术	LlaMA、GQA	MLA、MoE	FP8、RL	N.A
上下文长度	4K	128K	128K	128K

DeepSeek V2 性能

- 在英文测试方面次于 Llama 3
- 在代码生成方面接近 Llama 3
- 在数学和中文方面很多测试领先




	Benchmark (Metric)	# Shots	DeepSeek 67B	Qwen1.5 72B	Mixtral 8x22B	LLaMA 3 70B	DeepSeek-V2
English	Architecture	-	Dense	Dense	MoE	Dense	MoE
	# Activated Params	-	67B	72B	39B	70B	21B
	# Total Params	-	67B	72B	141B	70B	236B
	Pile-test (BPB)	-	0.642	0.637	0.623	0.602	0.606
	BBH (EM)	3-shot	68.7	59.9	78.9	81.0	78.9
	MMLU (Acc.)	5-shot	71.3	77.2	77.6	78.9	78.5
	DROP (F1)	3-shot	69.7	71.5	80.4	82.5	80.1
	ARC-Easy (Acc.)	25-shot	95.3	97.1	97.3	97.9	97.6
	ARC-Challenge (Acc.)	25-shot	86.4	92.8	91.2	93.3	92.4
	HellaSwag (Acc.)	10-shot	86.3	85.8	86.6	87.9	84.2
	PIQA (Acc.)	0-shot	83.6	83.3	83.6	85.0	83.7
	WinoGrande (Acc.)	5-shot	84.9	82.4	83.7	85.7	84.9
	RACE-Middle (Acc.)	5-shot	69.9	63.4	73.3	73.3	73.1
	RACE-High (Acc.)	5-shot	50.7	47.0	56.7	57.9	52.7
	TriviaQA (EM)	5-shot	78.9	73.1	82.1	81.6	79.9
	NaturalQuestions (EM)	5-shot	36.6	35.6	39.6	40.2	38.7
	AGIEval (Acc.)	0-shot	41.3	64.4	43.4	49.8	51.2
Code	HumanEval (Pass@1)	0-shot	45.1	43.9	53.1	48.2	48.8
	MBPP (Pass@1)	3-shot	57.4	53.6	64.2	68.6	66.6
	CRUXEval-I (Acc.)	2-shot	42.5	44.3	52.4	49.4	52.8
	CRUXEval-O (Acc.)	2-shot	41.0	42.3	52.8	54.3	49.8
Math	GSM8K (EM)	8-shot	63.4	77.9	80.3	83.0	79.2
	MATH (EM)	4-shot	18.7	41.4	42.5	42.2	43.6
	CMath (EM)	3-shot	63.0	77.8	72.3	73.9	78.7
Chinese	CLUEWSC (EM)	5-shot	81.0	80.5	77.5	78.3	82.2
	C-Eval (Acc.)	5-shot	66.1	83.7	59.6	67.5	81.7
	CMMLU (Acc.)	5-shot	70.8	84.3	60.0	69.3	84.0
	CMRC (EM)	1-shot	73.4	66.6	73.1	73.3	77.5
	C3 (Acc.)	0-shot	75.3	78.2	71.4	74.0	77.4
	CHID (Acc.)	0-shot	92.1	-	57.0	83.2	92.7
	CCPM (Acc.)	0-shot	88.5	88.1	61.0	68.1	93.1

DeepSeek V2 和主流模型对比

DeepSeek v3 性能分析

► DeepSeek V3 已经全面超越 Llama 3.1、GPT-4o



DeepSeek V3 和主流模型性能对比

DeepSeek V3 公开的预训练成本

- ▶ 按照 H800 GPU 每小时每卡 2 美元租赁成本，全部训练成本：**5,576,000 美元**

不包括前期探索模型架构、消融实验等开销

- ▶ 预训练时间估计：

2048 张 H800 计算：**~54天**

10000 张 H800 计算：**~11天**

Training Costs	Pre-Training	Context Extension	Post-Training	Total
in H800 GPU Hours	2664K	119K	5K	2788K
in USD	\$5.328M	\$0.238M	\$0.01M	\$5.576M

DeepSeek 公开的 V3 训练成本

DeepSeek V3 主要模型参数

► DeepSeek V3 模型参数:

- **671B 参数** (GPT-3: 175B、GPT-4: 1.76T?)
- 每个 token 激活 37B参数、**~5.5%**
- 61 层 Transformer、Hidden dimension: 7168
- FFN → MoE: **1** 共享专家 (shared expert) + **256** 路由专家 (routed experts)
每个 token 激活 **8** 个路由专家


► DeepSeek架构: MLA + MoE




MLA

DeepSeekMoE – Mixture of Expert

- 核心思想: **共享专家** + **大量细粒度路由专家**
- **共享专家**: 捕获通用知识、降低知识冗余
- **路由专家**: 量大、细粒度、灵活组合、方便知识表达
- V3: 1 共享专家 + 256 路由专家、每次激活 8 个路由专家



不同 MoE 架构对比



共享专家 + 路由专家 MoE 架构


MLA: Multi-Head Latent Attention

$Attention(q_i, K, V) = softmax(\frac{q_i K^T}{scale})V$

- 为了降低大模型推理成本，提出 **MLA 架构**
- 核心思想：通过**低秩压缩** KV，显著降低推理时 KV cache 的存储空间需求
- MLA 存储需求降低，同时可以更好地保持模型精度

$$\begin{aligned} \mathbf{c}_t^{KV} &= W^{DKV} \mathbf{h}_t, \\ [\mathbf{k}_{t,1}^C; \mathbf{k}_{t,2}^C; \dots; \mathbf{k}_{t,n_h}^C] &= \mathbf{k}_t^C = W^{UK} \mathbf{c}_t^{KV}, \\ \mathbf{k}_t^R &= \text{RoPE}(W^{KR} \mathbf{h}_t), \\ \mathbf{k}_{t,i} &= [\mathbf{k}_{t,i}^C; \mathbf{k}_t^R], \\ [\mathbf{v}_{t,1}^C; \mathbf{v}_{t,2}^C; \dots; \mathbf{v}_{t,n_h}^C] &= \mathbf{v}_t^C = W^{UV} \mathbf{c}_t^{KV}, \end{aligned}$$


$\mathbf{c}^{KV}$ 是KV 低秩压缩后的向量



MQA: PaLM、Gemini 等模型采用
GQA: LLAMA3、ChatGLM3、DeepSeek V1等模型采用

MLA 性能分析

- ▶ MLA 可以显著提升大模型推理性能，降低大模型推理成本
- ▶ KV Cache 使用: V2 vs. V1 降低 93.3%
- ▶ 推理吞吐性能: 5.76倍 V2 vs. V1
- ▶ V2 等价于 GQA 使用 2.25 个组




Attention Mechanism	KV Cache per Token (# Element)	Capability
Multi-Head Attention (MHA)	$2n_h d_h l$	Strong
Grouped-Query Attention (GQA)	$2n_g d_h l$	Moderate
Multi-Query Attention (MQA)	$2d_h l$	Weak
MLA (Ours)	$(d_c + d_h^R)l \approx \frac{9}{2}d_h l$	Stronger

不同策略每 Token 需要的KV Cache比较

并行训练框架

▶ 并行训练框架 HAI-LLM:

- ▶ 流水线并行: **16 路**
- ▶ 专家并行: **64 路** (跨 8 个物理节点)
- ▶ 数据并行: **ZeRO-1**
- ▶ 张量并行: **No** (通信开销大)



IB
50GB/s

NVLink
160GB/s


网络拓扑结构

并行训练：主要系统优化方法

- ▶ 负载均衡
- ▶ 通信优化
- ▶ 内存优化
- ▶ 计算优化

负载均衡优化

- ▶ **负载均衡**是 MoE 训练的一个主要挑战
- ▶ 提出 **Auxiliary-Loss-Free Load Balancing**
 - ▶ 核心思想：引入一个 **Expert Bias**
→ 保证专家负载均衡
 - ▶ Bias 只影响专家路由、不产生任何梯度影响
- ▶ 动态调整 Expert Bias
 - ▶ 降低 bias：如果对应专家 overloaded
 - ▶ 增大 bias：如果对应专家 underloaded





Loss-Free 负载均衡策略 [1]

[1] Lean Wang, Huazuo Gao, Chenggang Zhao, Xu Sun, Damai Dai. Auxiliary-Loss-Free Load Balancing Strategy for Mixture-of-Experts. 2024. Aug.

通信优化：精细编排计算和通信

► 提出 DualPipe 算法：

- 精细控制分配给计算和通信的 GPU SM 数量，保证计算和通信能够**完全重叠**
- 解决专家并行 **AlltoAll** 通信**开销大**的问题



前向和反向计算和通信的重叠

通信优化：双向流水线机制

- ▶ 双向流水线并行：
 - ▶  前向和反向重叠的阶段
 - ▶ 双向流水线导致两份模型参数存储 → 更大的**专家并行**



示例：8 级流水线并行、20 个 micro-batch

Method	Bubble	Parameter	Activation
1F1B	$(PP - 1)(F + B)$	$1\times$	PP
ZB1P	$(PP - 1)(F + B - 2W)$	$1\times$	PP
DualPipe (Ours)	$(\frac{PP}{2} - 1)(F\&B + B - 3W)$	$2\times$	$PP + 1$

通信优化：跨节点通信优化

► 跨节点通信优化：

- **跨节点**：每个 token 最多路由到 **4** 个物理节点
- **节点内**：每个 token 平均选择 **3.2** 个节点内专家

IB 和 NVLink 的重叠：


NVLink: 160GB/s $\leftrightarrow$ IB: 50GB/s = 3.2

- **路由策略**：IB 转发 $\rightarrow$ NVLink 转发

► warp specialization 技术^[1]

- **20** 个 SM 控制通信 (132 SM)
- **动态调整**：分配给通信任务 warp 数量
- **PTX (Parallel thread execution)**

[1] Singe: Leveraging Warp Specialization for High Performance on GPUs. 2014.



IB 带宽
50GB/s


NVLink带宽
160GB/s



内存优化

► 优化 GPU 内存使用:

- 重计算: RMSNorm、MLA up-projection
- 使用 CPU 内存: 在 CPU 侧保存模型参数的指数移动平均、异步更新
- 参数共享: 主模型和 MTP 模块的 output head 和 embedding 部署在相同节点



参数共享

计算优化：混合精度训练


- **FP8**：核心计算 GEMM 采用 FP8
- 提高模型精度（减缓 outlier 影响）：

- 细粒度量化：


Activation: 1 * 128 Tile 分组

Weight: 128 * 128 block 分组

- 增加累积的精度：FP32
- 增加尾数：**E4M3** vs E5M2
- 在线量化策略



FP8 混合精度的整体训练思路



细粒度量化策略

DeepSeek 推理系统

DeepSeek V3 推理配置 (PD分离架构) : **Prefill (计算密集)** + **Decode (访存密集)**

▶ **Prefill 阶段: 4个节点、32 GPU**

Attention 采用4路 TP 和 SP、8路 DP; MoE: 32路并行

Redundant expert: 缓解负载均衡

▶ **Decode 阶段: 40节点、320 GPU (每个 token 激活 37B参数)**

Attention: 4路 TP 和 SP、80路 DP、320路 MoE、每个GPU 1个专家 (256+64)

▶ **MoE 架构给推理系统带来挑战:**

- ▶ 负载均衡
- ▶ 算子效率
- ▶ 并行策略
- ▶ 编译优化

“八卦炉”：智能算力核心基础软件在神威平台实现

国产算力基础软件层

八卦炉：支撑国产AI算力的基础软件集

- ▶ PowerFusion：面向国产AI芯片智能编译器
- ▶ FastMoE：MOE大模型并行加速系统
- ▶ Einet：图算融合智能编译器
- ▶ FreeTensor：面向不规则智能程序编程语言
- ▶ FastDecode：高吞吐大模型推理系统

“八卦炉”基础软件系统

并行层	并行加速	通信库	容错系统
计算层	编程语言	编译器	加速库
底层系统	内存系统	存储系统	调度系统

在神威新一代超级计算机上研制了大模型训练加速系统：八卦炉

扩展到**全机规模**（10万台服务器）

目前正适配八卦炉系统支持更多国产芯片

八卦炉支撑多个大模型的训练任务：

北京智源研究院悟道 2.0、阿里巴巴 M6 大模型等

八卦炉 + 国产超算

实现百万亿参数量预训练模型加速

- ▶ 模型规模：174 万亿参数量（世界最大）
- ▶ 训练性能：1.18 EFLOPS（世界最快）
- ▶ 运行规模：3700 万处理器核

神威E级超级计算机（算力等效1.8万块 A100）



支撑多个AI for Science 应用程序：

跨尺度大气预测模型：swMPAS-A

第一性原理大模型：乾坤Net

DeepSeek 总结

- ▶ **协同优化：** DeepSeek 充分挖掘了算法、软件、硬件协同优化
- ▶ **系统软件：** 优秀的系统软件设计能充分释放底层硬件的潜力
- ▶ **工程创新：** 系统工程的极致创新能打破大模型依赖算力的范式
- ▶ **模型开源：** DeepSeek 开源能加速人工智能技术落地与迭代升级



Thank you!