



清华大学计算机科学与技术系本科专业主修课

计算机系统结构


第1章 计算机系统结构的基础知识

(课程复习)

计算机系统的层次结构

第 2 页

- 每一层以一种计算机语言为特征，计算机语言从低级向高级发展，高一级语言的语句相对于低一级语言功能更强，更便于应用，但又都以低级语言为基础



- 高级机器上的程序在低级机器上执行
 - 翻译与解释，或两者的结合
 - 上面3级：经常用翻译；下面3级：经常用解释
- 传统机器语言与微程序的区别
 - 微程序由硬件来解释执行
 - 无微程序技术，第2级指令系统由硬件直接执行
- 操作系统机器的执行机制
 - 传统机器级指令+操作系统级指令
- 虚拟机不一定由软件实现，些操作可以由硬件或固件实现

计算机系统结构的定义

第 3 页

1. **经典定义**：传统机器程序员看到的计算机属性，按照计算机系统的多级层次结构，不同级程序员所看到的计算机具有不同的属性 **(透明性)**。
2. **广义定义**：指令集结构 (Instruction Set Architecture) + 计算机组织 (Organization) + 计算机实现 (Implementation)
 - 计算机组成：计算机系统结构的逻辑实现
 - 计算机实现：计算机组成的物理实现
3. **指令系统设计与实现**：
 - 计算机系统结构：确定指令系统中是否有乘法指令
 - 计算机组成：乘法指令是用专用的乘法器还是用加法器经过多步操作实现
 - 计算机实现：乘法器、加法器的物理实现，如器件的选定及所用的微组装技术

系列机：由同一厂家生产的具有相同系统结构、但具有不同组成和实现的一系列不同型号的机器



常见的计算机系统结构分类法有**3**种：

1. Flynn分类法：SISD、SIMD、MISD、MIMD

2. 冯氏分类法：

◆**字串位串**： $n = 1, m = 1$ ，第一代计算机发展初期的纯串行计算机

◆**字串位并**： $n > 1, m = 1$ ，传统的单处理机，同时处理单个字的多个位

◆**字并位串**： $n = 1, m > 1$ ，同时处理多个字的同一位（位片）。

◆**字并位并**： $n > 1, m > 1$ ，同时处理多个字的多个位。

3. Handler分类法 t （系统型号） = $(k \times k', d \times d', w \times w')$

1. 以经常性事件为重点

■以经常性事件为重点是计算机设计中最重要、最广泛采用的设计原则

2. Amdahl定律——评估方案优化效果

加快某部件执行速度所能获得的系统性能加速比， 受限于该部件的执行时间占系统中总执行时间的百分比。

系统性能加速比：

$$\text{加速比} = \frac{\text{系统性能}_{\text{改进后}}}{\text{系统性能}_{\text{改进前}}} = \frac{\text{总执行时间}_{\text{改进前}}}{\text{总执行时间}_{\text{改进后}}}$$


改进后程序的总执行时间 T_n

$$T_n = T_0 \left(1 - Fe + \frac{Fe}{Se} \right)$$

- T_0 : 改进前整个程序的执行时间
- $1 - Fe$: 不可改进比例

系统加速比 S_n 为改进前与改进后总执行时间之比:

$$S_n = \frac{T_0}{T_n} = \frac{1}{(1 - Fe) + \frac{Fe}{Se}}$$



3. CPU性能公式

- 执行一个程序所需的CPU时间

$$\begin{aligned}\text{CPU时间} &= \text{执行程序所需的时钟周期数} \times \text{时钟周期时间} \\ &= \text{执行程序所需的时钟周期数} / \text{时钟频率}\end{aligned}$$

其中，时钟周期时间T是系统时钟频率的倒数 $1/f$ 。

- 每条指令执行的平均时钟周期数CPI (Cycles Per Instruction)

$$\text{CPI} = \text{执行程序所需的时钟周期数} / \text{IC}$$

其中，IC表示所执行的指令条数

- 程序执行的CPU时间可以写成

$$\text{CPU时间} = \text{IC} \times \text{CPI} \times \text{时钟周期时间}$$

CPU时间 = 执行程序所需的时钟周期数 × 时钟周期时间

$$= \sum_{i=1}^n (CPI_i \times IC_i) \times \text{时钟周期时间}$$

CPI可以表示为：

$$CPI = \frac{\text{时钟周期数}}{IC} = \frac{\sum_{i=1}^n (CPI_i \times IC_i)}{IC} = \sum_{i=1}^n (CPI_i \times \frac{IC_i}{IC})$$

其中： $\frac{IC_i}{IC}$ 反映了第*i*种指令在程序中所占的比例。



保持不变？

衡量计算机性能的唯一且可靠的标准是真实程序的执行时间

1. 执行时间和吞吐率：如何评测一台计算机的性能，与测试者看问题的角度有关。

- 用户关心的是：**单个程序的执行时间**（执行单个程序所花的时间很少）
- 数据处理中心的管理人员关心的是：**吞吐率**（在单位时间里能够完成的任务很多）

假设两台计算机为X和Y，X比Y快的意思是：对于给定任务，X的执行时间比Y的执行时间少。

X的性能是Y的n倍：
$$\frac{\text{执行时间Y}}{\text{执行时间X}} = n$$

执行时间与性能成反比：
$$n = \frac{\text{执行时间Y}}{\text{执行时间X}} = \frac{\frac{1}{\text{性能Y}}}{\frac{1}{\text{性能X}}} = \frac{\text{性能X}}{\text{性能Y}}$$

如何计算执行时间？

执行时间的计算：

1. 计算机完成某一任务所花费的**全部时间T**,

执行时间 $T = \text{CPU时间} + \text{磁盘访问时间} + \text{存储器访问} + \text{输入/输出开销} + \text{操作系统开销}$

2. **CPU时间**：CPU执行所给定的程序所花费的时间，不包含I/O等待时间以及运行其它程序的时间。

■ **用户CPU时间**：用户程序所耗费的CPU时间。

■ **系统CPU时间**：用户程序运行期间操作系统所耗费的CPU时间。

计算机系统的性能评测

第 11 页

	机器A	机器B	机器C
程序P1	1.00	10.00	20.00
程序P2	1000.00	100.00	20.00

从该表可以得出：

■ 执行程序1:

- A机的速度是B机的10倍
- A机的速度是C机的20倍
- B机的速度是C机的2倍

■ 执行程序2:

- B机的速度是A机的10倍
- C机的速度是A机的50倍
- C机的速度是B机的5倍

- 主要问题：计算机的配置基本相同，但不同计算机针对不同测试程序的测试结果是否一致？
- 为了公平地综合比较处理器性能，建立综合度量标准：

◆ 各程序的比重相同时

- 总执行时间
- 算术平均时间
- 调和平均时间

◆ 各程序的比重不同时

- 加权执行时间
- 标准化执行时间

总执行时间

$$S_m = \sum_{i=1}^n T_i$$

算术平均执行时间

$$A_m = \frac{1}{n} \sum_{i=1}^n T_i$$

调和平均执行时间

$$H_m = \frac{n}{\sum_{i=1}^n \frac{1}{T_i}}$$

其中：T_i为第i个程序的执行时间，n为程序数，R_i=1/T_i。

	机器A	机器B	机器C
程序P1	1秒	10秒	20秒
程序P2	1000秒	100秒	20秒
总执行时间S	1001秒	110秒	40秒
算术平均执行时间A	500.5秒	55秒	20秒
调和平均执行时间H	2秒	18秒	20秒

加权算术平均执行时间

$$A_m = \sum_{i=1}^n W_i \times T_i$$

其中： T_i 为第*i*个程序的执行时间， n 为程序数， W_i 为第*i*个程序的权重， $\sum_{i=1}^n W_i = 1$

	机器A	机器B	机器C
程序P1	1秒	10秒	20秒
程序P2	1000秒	100秒	20秒
算术平均 A_1	500.5秒	55秒	20秒
算术平均 A_2	91.91秒	18.19秒	20秒
算术平均 A_3	2秒	10.09秒	20秒

	W_1	W_2
组合1	0.5	0.5
组合2	0.909	0.091
组合3	0.999	0.001

加权调和平均执行时间

$$H_m = \frac{\sum_{i=1}^n W_i}{\sum_{i=1}^n \frac{W_i}{T_i}}$$

其中： T_i 为第*i*个程序的执行时间， n 为程序数， W_i 为第*i*个程序的权重

	机器A	机器B	处理器C
程序P1	1秒	10秒	20秒
程序P2	1000秒	100秒	20秒
调和平均A ₁	2秒	18.18秒	20秒
调和平均A ₂	1.1秒	10.89秒	20秒
调和平均A ₃	1秒	10.01秒	20秒

	W ₁	W ₂
组合1	0.5	0.5
组合2	0.909	0.091
组合3	0.999	0.001

标准化执行时间的计算方法：先将各程序的执行时间对一台参考机器进行标准化，然后取标准化执行时间的平均值（可以是算术平均值，也可以是几何平均值）

$$A_m = \frac{1}{n} \sum_{i=1}^n ETR_i$$

算术平均

$$G_m = \sqrt[n]{\prod_{i=1}^n ETR_i}$$

几何平均

ETR_i ：为第*i*个程序对参考机器标准后的执行时间， n ：为程序数

1. 并行性：计算机系统在同一时刻或者同一时间间隔内进行多种运算或操作。

只要在时间上相互重叠，就存在并行性。

- 同时性：两个或两个以上的事件在同一时刻发生。
- 并发性：两个或两个以上的事件在同一时间间隔内发生。

2. 从执行程序的角度来看，并行性等级从低到高可分为：

- 指令内部并行：单条指令中各微操作之间的并行
- 指令级并行：并行执行两条或两条以上的指令
- 线程级并行：并行执行两个或两个以上的线程
- 任务级或过程级并行：并行执行两个或两个以上的过程或任务（程序段）
- 作业或程序级并行：并行执行两个或两个以上的作业或程序

三种途径：

1. 时间重叠

- 引入时间因素，让多个处理过程在时间上相互错开，轮流重叠地使用同一套硬件设备的各个部分，以加快硬件周转而赢得速度。

2. 资源重复

- 引入空间因素，以数量取胜。通过重复设置硬件资源，大幅度地提高计算机系统的性能。

3. 资源共享

- 这是一种软件方法，它使多个任务按一定时间顺序轮流使用同一套硬件设备。



清华大学计算机科学与技术系本科专业主修课


计算机系统结构

第2章 指令系统的设计

(课程复习)

指令系统结构的分类

第 19 页



指令分类:

- 1、堆栈
- 2、累加器
- 3、寄存器-存储器结构
- 4、寄存器-寄存器结构 (现代处理器主流)

物理地址空间的信息存放方式:

- 1、允许跨边界存储, 存储效率高, 访问速度低
- 2、允许跨边界存储, 存储效率低, 访问速度高

七种基本寻址方式：


立即数寻址：	立即数 → 寄存器
直接寻址：	[偏移地址] → 寄存器
寄存器寻址：	寄存器 → 寄存器
寄存器间接寻址：	[基址寄存器/变址寄存器] → 寄存器
寄存器相对寻址：	[基址寄存器/变址寄存器+偏移量值] → 寄存器
基址变址寻址：	[基址寄存器+变址寄存器] → 寄存器
相对基址变址寻址：	[基址寄存器+变址寄存器+偏移量值] → 寄存器

1. 指令系统的设计

- 首先考虑所应实现的基本功能，确定哪些基本功能应该由硬件实现，哪些功能由软件实现比较合适，具体包括：
 - ✓ 指令的功能设计
 - ✓ 指令格式的设计

2. 在确定哪些基本功能用硬件来实现时， 主要考虑3个因素：速度、成本、灵活性。

- 硬件实现的特点：
 - ✓ 速度快、成本高、灵活性差
- 软件实现的特点：
 - ✓ 速度慢、价格便宜、灵活性好




3. 对指令系统的基本要求：**完整性、规整性、正交性、高效率、兼容性**

- **完整性**：在一个有限可用的存储空间内，对于任何可解的问题，编制计算程序时，指令系统所提供的指令足够使用，要求指令系统功能齐全、使用方便。
- **规整性**：主要包括对称性和均匀性
 - **对称性**：所有与指令系统有关的存储单元的使用、操作码的设置等都是对称的
 - **均匀性**：指对于各种不同的操作数类型、字长、操作种类和数据存储单元，指令的设置都要同等对待
- **正交性**：在指令中各个不同含义的字段，如操作类型、数据类型、寻址方式字段等，在编码时应互不相关、相互独立。
- **高效率**：指指令的执行速度快、使用频度高。
- **兼容性**：主要是要实现向后兼容，指令系统可以增加新指令，但不能删除指令或更改指令的功能——**指令数越来越多的原因**

■ 哈夫曼编码的实现方法——构造哈夫曼树

- 将各事件按其使用频度从小到大依次排列；
- 每次从中选择两个频度值最小的结点，将其合并成一个新的结点，并把新结点画在所选结点的上面，然后用两条边把新结点分别与那两个结点相连。新结点的频度值是所选两个结点的频度值的和。
- 把新结点与其他剩余未结合的结点一起，再以上面的步骤进行处理，反复进行，直到全部结点都结合完毕、形成根结点为止。
- 操作码优化的程度可以用信息熵来衡量




画哈夫曼树的一个基本步骤

$$H = - \sum_{i=1}^n p_i \log_2 p_i$$

表示用二进制编码表示n个码点时，理论上的最短平均编码长度

指令操作码的优化

第 24 页



哈夫曼树实例

该哈夫曼编码的平均码长是：

$$L = \sum_{i=1}^7 p_i l_i = 2.20$$

其信息冗余量为：

$$\frac{2.20 - 2.17}{2.20} \approx 1.36\%$$


优缺点：可以减少操作码的平均位数，但所获得的编码是变长度的，不规整，不利于硬件处理。

指令操作码的优化

m-n扩展编码

指令	频度 p_i	利用哈夫曼概念的 扩展操作码	操作码 长度 l_i
l_1	0.40	0 0	2
l_2	0.30	0 1	2
l_3	0.15	1 0	2
l_4	0.05	1 1 0 0	4
l_5	0.04	1 1 0 1	4
l_6	0.03	1 1 1 0	4
l_7	0.03	1 1 1 1	4

$$\sum_{i=1}^7 p_i l_i = 2.3$$



指令操作码的优化

第 26 页

■ m/n扩展编码

- 为了便于分级译码，一般都采用等长扩展码。在早期的计算机上，例如：15/15/15法和8/64/512法

✓ 选用哪种编码法取决于指令使用频度 p_i 的分布。若在前15种指令中 p_i 的值都比较大，但在后30种指令后急剧减少，则应选择15/15/15法；

若 p_i 的值在前8种指令中较大，之后的64种指令的 p_i 值也不太低，则应选择8/64/512法。

✓ 衡量标准：看哪种编码法能使平均码长最短。

15 {
0000
0001
⋮
1110
1111 0000
1111 0001
⋮
1111 1110
1111 1111 0000
1111 1111 0001
⋮
1111 1111 1110

15/15/15 编码法

8 {
0 000
0 001
⋮
0 111
64 {
1 000 0 000
1 000 0 001
⋮
1 111 0 111
512 {
1 000 1 000 0 000
1 000 1 000 0 001
⋮
1 111 1 111 0 111

8/64/512 编码法

■ 定长操作码


- 固定长度的操作码：所有指令的操作码都是同一的长度（如8位）。许多计算机都采用（特别是RISC结构的计算机）
- 保证操作码的译码速度、减少译码的复杂度。
- 以程序的存储空间为代价来换取硬件实现上的好处。

0001100	rs2	rs1	rm	rd	101001	R fdiv.s
0001100	00000	rs1	rm	rd	101001	R fsqrt.s
0010000	rs2	rs1	000	rd	101001	R fsgnj.s
0010000	rs2	rs1	001	rd	101001	R fsgnjn.s
0010000	rs2	rs1	010	rd	101001	R fsgnjx.s
0010100	rs2	rs1	000	rd	101001	R fmin.s

沿CISC方向发展和改进指令系统

第 28 页

复杂而高效



简约而不简单

思路

特点

应用

CISC体系

为了便于软件编程和提高程序运行速度，增加可实现复杂功能的指令和多种灵活的编址方式

- 1 编译优化、程序代码量低
- 2 指令执行效率高
- 3 处理器性能高

通用计算机系统
(PC、笔记本、服务器、集群、巨型机等)

RISC体系

为了便于硬件实现和降低处理器实现成本，只实现使用频率很高的少数指令与规则的编址方式

- 1 易于硬件实现
- 2 易于流水实现与并行处理
- 3 指令与数据存储效率高

嵌入式计算机系统
(手机、工业控制、医疗电子)

1. CISC指令系统的一大特点： 指令数量多、功能多样
2. 增强指令功能主要是从以下3个方面着手：
 - 面向目标程序增强指令功能
 - 面向高级语言的优化实现来改进指令系统
 - 面向操作系统的优化实现改进指令系统

2. 设计RISC机器遵循的原则，指令条数少、指令功能简单，方法如下：

- 指令系统：选取使用频度高的指令，在此基础上补充一些最有用的指令；
- 寻址机制：采用简单又统一的指令格式，并减少寻址方式；一般来说，指令字长都为32位或64位；
- 执行机制：采用流水线机制，指令的执行在单个机器周期内完成；
- 访存机制：采用load-store结构，只有load和store指令才能访问存储器，其它指令的操作都是在寄存器之间进行；
- 实现机制：大多数指令都采用硬连逻辑来实现；
- 编译机制：强调优化编译器的作用，为高级语言程序生成优化的代码。

■ 系统结构设计者首先要解决的问题：数据类型与表示

- 数据类型和表示是软硬件主要界面之一。
- 数据类型：面向应用、面向软件系统所处理的各种数据结构。例如定点、浮点、十进制、字符、字符串、逻辑、堆栈和向量等。
- 数据表示：硬件结构能够识别、指令系统可以直接调用的那些结构。

■ 确定数据类型和数据表示的原则：

- 一是缩短程序的运行时间；
- 二是减少CPU与主存储器之间的通信量；
- 三是这种数据表示的通用性和利用率。

数据类型和数据表示在不断发展， 例如矩阵、树、图、表及自定义数据类型等。



清华大学计算机科学与技术系本科专业主修课

计算机系统结构

第3章 流水线技术

(课程复习)


流水线的实现前提：

■ 空间并行性

- ◆ 指令操作可以由多个独立的操作部件共同完成

■ 时间并行性

- ◆ 不同指令可以分时使用同一个部件的不同部分




5段指令流水线 → **理想情况下**速度提高5倍

如何分析不理想情况下的流水线执行的实际效果？


流水线表示方法

第 34 页

- **时—空图**从时间和空间两个方面描述了流水线的工作过程
- 时—空图中横坐标代表时间，纵坐标代表流水线的各个阶段指令执行流水线的时空图



■ 连接图



- **功能段：**流水线的每一个阶段称为流水步、流水步骤、流水段、流水线阶段、流水功能段、流水级、流水节拍等。
- **流水寄存器：**在每一个流水段的末尾或开头必须设置一个寄存器，称为流水寄存器、流水锁存器等。
 - 作用：在相邻的两段之间传送数据，以保证提供后面要用到的信息，并把各段的处理工作相互隔离。

■ 按照流水技术的应用等级不同

- 部件级流水线：运算操作分段执行
- 处理器级流水线：指令分段执行
- 系统级流水线：程序（任务）分段执行

■ 按照流水线所完成的功能来分类

- 单功能流水线
- 多功能流水线
 - ✓ 静态流水线
 - ✓ 动态流水线（线性流水线与非线性流水线）

■ 按照任务流入和流出的顺序是否相同进行分类

- 顺序流水线
- 乱序流水线


■ 按照处理数据对象来进行分类

- 标量流水线
- 向量流水线

非线性流水线

第 37 页

- 非线性流水线必须用**连接图**和**预约表**共同表示，一条非线性流水线可以对应有很多张预约表，同样一张预约表实际上仅表示了一条非线性流水线的一种工作方式



一种简单的非线性流水线

	1	2	3	4
S1	×			
S2			×	
S3		×		×

	1	2	3	4	5
S1	×				
S2		×		×	
S3			×		×

对应的两种预约表

■ 流水线的实际吞吐率

$$TP = \frac{n}{(m + n - 1)\Delta t}$$

■ 最大吞吐率

$$TP = \lim_{n \rightarrow \infty} \frac{n}{(m + n - 1)\Delta t} = \frac{1}{\Delta t_{\max}}$$

■ 最大吞吐率与实际吞吐率的关系


$$TP = \frac{n}{m + n - 1} TP_{\max}$$

只有当 $n \gg m$ 时,
才有 $TP \approx TP_{\max}$

■解决流水线瓶颈问题的常用方法

◆ 方法一：细分瓶颈段

例如：对前面的5段流水线把瓶颈段 S_4 细分为3个子流水线段： S_{4-1} ， S_{4-2} ， S_{4-3}




改进后的流水线的吞吐量： $TP_{\max} = \frac{1}{\Delta t}$

■解决流水线瓶颈问题的常用方法

◆方法二：重复设置瓶颈段

- 缺点：控制逻辑比较复杂，所需的硬件增加了。
- 例如：对前面的5段流水线重复设置瓶颈段 S_4 ： S_{4a} ， S_{4b} ， S_{4c}



■ 流水线各段时间相等 (都是 Δt)

◆ 一条 m 段流水线完成 n 个连续任务所需要的时间为:

$$T_m = (m + n - 1)\Delta t$$

◆ 顺序执行 n 个任务所需要的时间:

$$T_s = nm\Delta t$$

◆ 流水线的实际加速比为:

$$S = \frac{nm}{m + n - 1} \quad \longrightarrow \quad S = \lim_{n \rightarrow \infty} \frac{nm}{m + n - 1} = S_{\max}$$

当 $n \gg m$ 时, $S \approx m$

思考: 流水线的段数愈多愈好?


假设在流水线各段的执行时间不相等，输入到流水线中的任务是连续的理想情况下。

■ 实际效率 (功能段权值相等)

$$E = \frac{n \cdot \sum_{i=1}^m \Delta t_i}{m \cdot [\sum_{i=1}^m \Delta t_i + (n-1) \cdot \max(\Delta t_1, \Delta t_2, \dots, \Delta t_m)]}$$

单功能非线性流水线的调度

第 43 页



时间 流水段	1	2	3	4	5	6	7
S1	x						x
S2		x				x	
S3			x		x		
S4				x			


求最小启动循环。

- 步骤一：由预约表得到禁止表F
- 步骤二：由禁止表F得到冲突向量C
- 步骤三：由冲突向量构造调度流水线的状态转换图
- 步骤四：在状态图中找出可用启动距离，并计算平均启动距离
- 步骤五：找出平均启动距离最小的启动循环或恒定循环

单功能非线性流水线的调度

第 44 页

由冲突向量构造调度流水线的状态转换图



$\text{SHR}^{(j)}(C_0) \vee C_0$
 其中: $\text{SHR}^{(j)}$ 表示逻辑右移j位

$$\begin{aligned}
 \text{SHR}^{(1)}(101010) &= 010101 \\
 (010101) \vee (101010) &= 111111 \\
 \text{SHR}^{(7)}(111111) &= 000000 \\
 (000000) \vee (101010) &= 101010
 \end{aligned}$$

第一组

$$\begin{aligned}
 \text{SHR}^{(3)}(101010) &= 000101 \\
 (000101) \vee (101010) &= 101111 \\
 \text{SHR}^{(5)}(101111) &= 000001 \\
 (000001) \vee (101010) &= 101011 \\
 \text{SHR}^{(3)}(101011) &= 000101 \\
 (000101) \vee (101010) &= 101111
 \end{aligned}$$

第二组

- 相关：两条指令之间存在某种依赖关系。

如果两条指令相关，则它们就有可能不能在流水线中重叠执行或者只能部分重叠执行。

- 相关有3种类型


- 数据相关（也称真数据相关）
- 名相关
- 控制相关

- 流水线冲突是指对于具体的流水线来说，由于相关的存在，使得指令流中的下一条指令不能在指定的时钟周期执行。
- 流水线冲突有3种类型：
 - 结构冲突：因硬件资源满足不了指令重叠执行的要求而发生的冲突。
 - 数据冲突：当指令在流水线中重叠执行时因需要用到前面指令的执行结果而发生的冲突。
 - 控制冲突：流水线遇到分支指令和其它会改变PC值的指令所引起的冲突。
- 带来的几个问题：
 - 导致错误的执行结果。
 - 流水线可能会出现停顿，从而降低流水线的效率和实际的加速比。

流水线冲突

第 47 页

- “先写后读” 相关在流水线顺序执行和乱序执行时都可能发生，“先读后写” 相关和 “写写” 相关只有在流水线乱序执行时才可能发生，而 “读读” 相关无需处理。



■ 控制冲突

■ 执行分支指令的结果有两种：

- 分支成功：PC值改变为分支转移的目标地址。在条件判定和转移地址计算都完成后，才改变PC值。
- 不成功或者失败：PC的值保持正常递增，指向顺序的下一条指令。

■ 处理分支指令最简单的方法：“冻结”或者“排空”流水线

- 优点：简单
- 前述5段流水线中，改变PC值是在MEM段进行的。给流水线带来了3个时钟周期的延迟

■ 3种通过软件（编译器）来减少分支延迟的方法

- 预测分支失败
- 预测分支成功
- 延迟分支

第一次作业

第一次作业

作业1：某系统的指令的CPI和执行频度如下表所示。

指令	基本指令				复杂指令	
	加法	减法	乘法	移位	除法	求平方根
CPI	1	1	2	1	10	100
执行频度	25%	25%	15%	20%	10%	5%

- (1) 优化方案：第一种是把乘法操作的CPI减至**1**；第二种是把求平方根操作的CPI减至**50**，试比较两种方案对系统性能的提高程度，并尝试总结系统优化方法规律。
- (2) 优化方案：采用加法结合移位的方法实现除法指令和求平方根指令。1个除法等效**40加法+10移位**；一个求平方根等效**400加法+100移位**。考虑在此改动的基础上，将系统频率提高到原来的多少倍才能够与原本性能打平？

第一次作业

第 51 页

作业2：假设存储器访问时间占整个程序执行时间的30%，拟对该存储系统进行性能优化：

- 第一步：采用L1 Cache，使80%存储器访问的时间缩短到原来的1/4；
- 第二步：采用L2 Cache，使剩余的20%存储器访问时间缩短到原来的1/2。

试计算改进前后整个程序的计算加速比。

作业3：假设对系统同时进行两种优化，且方案优化1与2无关。

方案优化1：可改进比例 F_{e1} 和部件加速比 S_{e1}

方案优化2：可改进比例 F_{e2} 和部件加速比 S_{e2}

尝试推导系统加速比公式 S_n 。

第一次作业

第 52 页

作业4：计算机系统有三个部件可以改进，这三个部件的加速比如下：

部件加速比 $S_1=30$ ；部件加速比 $S_2=20$ ；部件加速比 $S_3=10$

(1) 如果部件1和部件2的可改进比例都为30%，那么当部件3的可改进比例为多少时，系统的加速比才可以达到10？

(2) 如果三个部件的可改进比例分别为30%、30%和20%，三个部件同时改进，那么系统中不可改进部分的执行时间在总执行时间中占的比例是多少？

作业5：假设浮点数指令（FP）指令的比例为30%，其中浮点数平方根（FPSQR）占全部指令（包括非FP指令）的比例为4%，FP操作的CPI为5，FPSQR操作的CPI为20，其他指令的平均CPI为1.25。现有两种改进方案，第一种是把FPSQR操作的CPI减至3，第二种是把所有的FP操作的CPI减至3，试比较两种方案对系统性能的提高程度。

第一次作业

第 53 页

作业6：已知四个程序在三台计算机上的执行时间如下表所示。

程序	计算机A执行时间/s	计算机B执行时间/s	计算机C执行时间/s
程序1	1	10	20
程序2	1000	100	20
程序3	500	1000	50
程序4	100	800	100

假设四个程序都执行100 000 000条指令，计算这三台计算机中每台机器上每个程序的MIPS速率，分别计算它们的算术平均值、几何平均值和调和平均值。

第一次作业

作业7：某台处理机的各条指令使用频度如下表所示。

指令	使用频度	指令	使用频度	指令	使用频度
ADD	43%	JOM	6%	CIL	2%
SUB	13%	STO	5%	CLA	22%
JMP	7%	SHR	1%	STP	1%

请分别设计这9条指令操作码的赫夫曼编码、3/3/3扩展编码和2/7扩展编码，并计算这三种编码的平均码长。

第一次作业

第 55 页


作业8：某机器的指令字长为16位，设有单地址指令和双地址指令两类指令，若每个地址字段均为6位，且双地址指令有A条，问单地址指令最多可以有多少条？

作业9：某处理机的指令系统要求有三地址指令4条、单地址指令255条、零地址指令16条。设指令字长为12位，每个地址码长度为3位。问能否用扩展编码为其操作码编码？如果要求单地址指令为254条，能否对其操作码扩展编码？说明理由。

第一次作业

第 56 页

作业10: 有一指令流水线如下图所示。



- (1) 求连续输入10条指令，该流水线的实际吞吐率和效率。
- (2) 该流水线的“瓶颈”在哪一段？请采取两种不同的措施消除此“瓶颈”，要求最终流水线的时钟周期为50ns。对于给出的两种新的流水线，连续输入10条指令时，其实际吞吐率和效率各是多少？

第一次作业

第 57 页


作业11: 有一个流水线由4段组成，其中每当流经第3段时，总要在该段循环一次，然后才能流到第4段。如果每段经过一次所需要的时间都是 Δt ，请问：

- (1) 画出流水线的预约表
- (2) 当在流水线的输入端连续地每 Δt 时间输入一个任务时，该流水线会发生什么情况？
- (3) 此流水线的最大吞吐率为多少？如果每 $2\Delta t$ 输入一个任务，连续处理10个任务时的实际吞吐率和效率是多少？
- (4) 当每段时间不变时，如何提高该流水线的吞吐率？给出改进后的预约表。仍连续处理10个任务时，其吞吐率提高到多少？

第一次作业

第 58 页

作业12: 有一条动态多功能流水线由5段组成, 如下图所示, 加法用1、3、4、5段, 乘法用1、2、5段, 第2段的时间为 $2\Delta t$, 其余各段的时间均为 Δt , 而且水母的输出可以直接返回输入端或暂存于相应的流水线寄存器中。若在该流水线上计算 $\sum_{i=1}^4 (A_i \times B_i)$, 试计算其吞吐率、加速比和效率。



第一次作业

第 59 页

作业13: 在一个5段流水线处理机上, 各段执行时间均为 Δt , 需经 $9\Delta t$ 才能完成一个任务, 其预约表如下表所示。

功能段	时间								
	1	2	3	4	5	6	7	8	9
S_1	√								√
S_2		√	√						
S_3				√			√	√	
S_4				√	√				
S_5						√	√		

- (1) 画出流水线任务调度的状态转移图。
- (2) 求流水线的最优调度策略和流水线的最大吞吐率。
- (3) 按最优调度策略连续输入6个任务, 流水线的实际吞吐率是多少?

第一次作业

第 60 页

作业14: 在一个5段流水线，各段执行时间均为 Δt ，其预约表如下表所示。

功能段	时间						
	1	2	3	4	5	6	7
S_1	√						√
S_2		√			√		
S_3			√	√			
S_4				√			√
S_5					√	√	

- (1) 画出流水线任务调度的状态转移图。
- (2) 分别求出允许不等时间间隔调度和等时间间隔调度的两种最优调度策略，并计算这两种调度策略的流水线最大吞吐率。
- (3) 若连续输入10个任务，分别求采用这两种策略的流水线实际吞吐率和加速比？