



第5章 数据库存储

清华大学计算机系 李国良

liguoliang@tsinghua.edu.cn

<http://dbgroup.cs.tsinghua.edu.cn/ligl>



本章内容

1. 数据库系统如何存储数据
2. 数据的存储介质特性比较
3. 数据库系统如何查找数据
4. 如何提高数据访问的效率
5. 如何防止数据库数据丢失
6. 数据的最小单位数据页面
7. 数据库如何来管理缓冲区
8. 如何选择行存储和列存储



目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
5. 文件组织
6. 元数据存储
7. 缓冲区
8. 行存储与列存储



目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
5. 文件组织
6. 元数据存储
7. 缓冲区
8. 行存储与列存储



存储概览

SQL引擎

执行器


存储引擎

文件组织 页面组织 元数据 日志 索引 缓冲区 故障恢复 并发控制

存储介质




存储概览





存储概览






数据组织


记录

2021310001	张三	男	计算机系	3.9
Char	Varchar	Char	Varchar	Decimal

记录的字节表示




分槽页面 (8K)



数据表

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7

文件






目录

1. 存储概览
- 2. 存储介质**
3. 存储结构
4. 页面组织
5. 文件组织
6. 元数据存储
7. 缓冲区
8. 行存储与列存储



存储介质





存储介质介绍

□ 高速缓冲存储器

- 存取速度最快的存储介质，而单位价格却比较昂贵

□ DRAM主存(内存)

- 主要用于存放程序和其处理的数据。一般为4GB ~ 32GB (2022年)

□ 磁盘

- 容量大、数据持久性好，存储长期数据。一般为256GB ~ 10TB (2022年)

□ 闪存

- 又叫固态硬盘，个人计算机闪存大小一般为128GB ~ 1TB (2022年)

□ 非易失性主存

- 速度能DRAM相媲美，字节级寻址，在断电时不会丢失数据



存储介质特性比较

存储介质	访问速度	存储空间	单位价格	数据持久性
高速缓存	快	小	高	易失
DRAM	较快	中等	中等	易失
非易失性主存	中等	中等	较高	非易失
闪存	较慢	较大	较低	非易失
磁盘	慢	大	低	非易失



磁盘



□接口

- SATA (Serial ATA) 500 MB/s ~ 600MB/s
- 存储区域网络 (Storage Area Network , SAN)
- 网络附属存储 (Network Attached Storage , NAS)
- 非易失性主存主机控制器接口规范 (Non-Volatile Memory Express , NVMe)
- 磁盘阵列 (Redundant Arrays of Independent Disks , RAID) ~ 3500MB/s

磁盘结构

□ 盘片

- 覆盖磁性物质，通过改变磁性物质的磁场方向来存储二进制的0和1，高速旋转每分钟5400转至7200转

□ 磁头


- 改变磁性物质状态并且读写数据

□ 磁道

- 盘片上的圆环区域

□ 柱面

- 纵向对齐的多个磁道






磁盘结构

□ 磁盘读写时延

- 寻道时延：磁头移动时延10ms
- 旋转时延：盘片旋转时延
 - 5400转/分钟的磁盘平均时延是 $60 \times 1000 / 5400 \times 0.5 = 5.56$ 毫秒
- 数据读写时延：
 - 100MB/秒的磁盘
 - 读写4KB: $4KB / 100MB \times 1000 = 0.04$ 毫秒
 - 读写1MB: $1MB / 100MB \times 1000 = 10$ 毫秒

□ 顺序读写：快（只有读写时延）

□ 随机读写：慢（寻道+旋转+读写）



尽量顺序读写避免随机读写



磁盘性能与优化

□访问时间

- 系统发出读写指令后到磁盘开始返回数据的时间

□数据传输率

- 每秒钟磁盘读写的数据量



□磁盘访问优化技术

- 缓冲
- 预读
- 调度
- 文件组织




磁盘调度技术：电梯算法

磁盘访问序列：98, 183, 37, 122, 14, 124, 65, 67。读写头起始位置：53



□电梯算法

- 把磁头看作是在做横跨磁盘的扫描
- 从柱面最内圈到最外圈，然后再返回
- 正如电梯做垂直运动，从最底层再到顶层，然后再返回来。






目录

1. 存储概览
2. 存储介质
- 3. 存储结构**
4. 页面组织
5. 文件组织
6. 元数据存储
7. 缓冲区
8. 行存储与列存储



存储结构






存储结构

数据块

- 存储介质上的数据最小存储单位


页面

- 统一大小来管理数据
- 一般为8KB、16KB



数据表

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7






数据表空间管理

□ 数据表空间由段（segment）、区（extent）、页（page）组成。


- 数据段、索引段、回滚段分别存储
- 一次申请一个区（多个连续页），让相邻页的物理位置也相邻，方便实现顺序I/O。





申请新页面


- 假设所有的页面都满时，要继续插入记录的话就需要申请新的页面
- 每次申请固定数量的区 (extent)
 - 为了页面尽量连续





页面空闲空间管理：多级空闲空间数组

- 快速找到空闲空间的位置
- 从高到低扫描各级空闲空间数组



- 也可以用大根堆替代空闲空间数组，维护各页面空闲空间比例



目录

1. 存储概览
2. 存储介质
3. 存储结构
- 4. 页面组织**
5. 文件组织
6. 元数据存储
7. 缓冲区
8. 行存储与列存储




页面组织




元组管理

页面头	记录数量、checksum、上下页指针等				记录删除状态位向量 (11011...)₂	
记录地址	地址指针0	地址指针1	地址指针2	地址指针3	地址指针4	...
记录数据	记录0	记录1	记录2	记录3	记录4	
	记录5	记录6	记录7	记录8	记录9	
	记录10	记录11	记录12	记录13	记录14	
	...					



追加日志管理

Log Structured Merge Trees





页面组织

- 页面大小为8KB或者16KB，一般为2的整数次幂
- 一个页面往往包含了多条记录

页面头	记录数量、checksum、上下页指针等				记录删除状态位向量 (11011...) ₂	
记录地址	地址指针0	地址指针1	地址指针2	地址指针3	地址指针4	...
记录数据	记录0	记录1	记录2	记录3	记录4	
	记录5	记录6	记录7	记录8	记录9	
	记录10	记录11	记录12	记录13	记录14	
	...					



页面组织： 定长记录 vs 变长记录

- 定长记录：长度固定，页面中记录数目固定，易于定位一个页面的记录位置
 - 例如年龄short，学号char (10)
- 变长记录：长度可变，页面中记录数目不固定，难以直接计算并定位记录位置
 - 例如姓名varchar，院系varchar

定长记录

记录头	学号	姓名	性别	院系	绩点
	2021310001	张三	男	计算机系	3.9

变长记录

记录头	学号	性别	绩点	姓名	院系	空值向量 (00000) ₂		
	2021310001	男	3.9	37, 6	43, 12	0	张三	计算机系

字节 0 10 20 24 28 32 36 37 43 54

↑ ↑

元数据

属性	长度	位置	类型
学号	10	12	定
姓名	22	3	定
性别	25	1	定
院系	26	4	定
绩点	30	2	定



定长记录

记录的长度（占用空间）固定

- 学号, char, 10字节
- 姓名, char, 20字节
- 性别, char, 4字节
- 院系, char, 40字节
- 绩点, decimal, 4字节

记录组织方式

- 记录头: 事务信息、NULL值bitmap
- 每个属性值

	记录头	学号	姓名	性别	院系	绩点
定长记录		2021310001	张三	男	计算机系	3.9

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7

页面头	记录数量、checksum、上下页指针等				记录删除状态位向量 (11011...) ₂
记录数据	记录0	记录1	记录2	记录3	记录4
	记录5	记录6	记录7	记录8	记录9
	记录10	记录11	记录12	记录13	记录14
	...				



定长记录

□ 页面内组织形式

- 页面头
 - 记录数量
 - Checksum: 防止读写错误
 - 上下页面指针 (PageID)
 - 页面在文件的offset
 - 页面类型: 索引、数据
 - 空闲空间
- 记录内容

页面头	记录数量、checksum、上下页指针等				记录删除状态位向量 (11011...) ₂
	记录0	记录1	记录2	记录3	记录4
记录数据	记录5	记录6	记录7	记录8	记录9
	记录10	记录11	记录12	记录13	记录14
	...				



记录添加

如果页面可以容纳新纪录，添加到页面最后

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6



	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7



记录删除

删除记录，并依次将后续记录向前移动

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7



	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7



记录删除


将最后一条记录向前移动

	学号	姓名	性别	院系	绩点		学号	姓名	性别	院系	绩点	
记录0	2021310001	张三	男	计算机系	3.9		记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7		记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0		记录6	2021310013	张九	女	法学系	3.7
记录3	2021310004	张六	男	法学系	3.7		记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4		记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6		记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7							



记录删除

- 可用空闲位置链表
- 插入记录时快读定位第一个空位






定长记录 (bitmap)

- Bitmap位图：标记记录是否存在
- **Insert插入**：找到第一个空槽
- **Delete删除**：清楚槽标志位
- Bitmap数目根据页面大小和记录长度计算

记录: (Page 2, Record 4)




Bitmap




变长记录

记录中的变长属性通过偏移量和长度定位

- 学号, char, 10字节
- 姓名, varchar, 变长
- 性别, char, 4字节
- 院系, varchar, 变长
- 绩点, decimal, 4字节



	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7
记录4	2021310006	张七	女	物理系	3.4
记录5	2021310009	张八	女	物理系	3.6
记录6	2021310013	张九	女	法学系	3.7






变长记录 vs 定长记录

变长记录组织

- 记录头：事务信息、NULL值bitmap
- 属性槽位：起始位置和长度






页面组织-变长记录

□ 页面内记录组织


- 页面头：页类型、状态
- 槽位：记录起始地址、长度（索引会指向槽位）
- 两头挤：页面、槽位等页面内从前往后；记录从后往前






页面组织-变长记录


- 槽位→页面位置和长度
- 删除：删除槽位
- 插入：找到空闲槽位



- 插入记录3



- 删除记录2





页面组织思考

□如何处理记录长度大于页面大小？

- 记录跨页链接
- 专门存储方式

□如何处理一条记录有很多NULL值？

- 利用bitmap对NULL值进行压缩



目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
- 5. 文件组织**
6. 元数据存储
7. 缓冲区
8. 行存储与列存储




文件组织

- 数据文件中页面之间的组织方式
- 目标：高效的数据页面访问（插入、删除、查找）
- 主要的文件组织方法
 - 堆表
 - 顺序表
 - 哈希表
 - B+树
 - 多表聚簇




文件组织


堆表



顺序表



哈希表%3





堆表

记录的顺序没有限制，将记录简单排列在文件中





顺序表


□ 记录按某个或某些字段的大小顺序存储





顺序表-插入


- 记录按某个或某些字段的大小顺序存储，使用链表连接文件中的记录
- 删除记录2后插入记录7结果如下





顺序表-插入到新页面


- 页面已满
- 直接插入记录7结果如下





哈希表


□ 使用哈希表将记录存储到不同的页面或者不同的页面集合





B+树

平衡多叉树





文件组织方法性能对比

文件组织方法	复杂度	增	删	改	点查询	范围查询
堆表	简单	$O(1)$	$O(n)$	$O(n)$	$O(n)$	$O(n)$
堆表 + B+树	复杂	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n + k)$
顺序表	中等	$O(\log_2 n)$	$O(\log_2 n)$	$O(\log_2 n)$	$O(\log_2 n)$	$O(\log_2 n + b)$
顺序表 + B+树	复杂	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n)$	$O(\log_m n + b)$
哈希表	中等	$O(l)$	$O(l)$	$O(l)$	$O(l)$	$O(n)$

n 页面数目 m B树阶数 k 结果记录数目 b 结果页面数目 l 哈希链长度



多表聚簇文件组织

多个相关的表中的数据存储在同一个文件/页面中

院系记录0	计算机系	东主楼			
学生记录0	2021310001	张三	男	计算机系	3.9
学生记录1	2021310002	张四	女	计算机系	3.7
学生记录2	2021310003	张五	男	计算机系	4.0
院系记录1	物理系	西主楼			
学生记录3	2021310006	张七	女	物理系	3.4
学生记录4	2021310009	张八	女	物理系	3.6



空闲空间管理

- 插入一条长为 x 的记录，应该插入到哪个页面？
- 堆表需要找到合适的页面（空闲空间大于 x 的页面）
 - 1 记录每个页面空间大小

空闲空间比例	30	233	10	0	128	123	47	0	0	23
页面编号	0	1	2	3	4	5	6	7	8	9

页面编号	0	1	2	3	4	5	6	7	8	9
一级空闲空间数组	30	233	10	0	128	123	47	0	0	23
二级空闲空间数组	233				128		47	23		
页面编号	0,1,2			3,4,5		6,7,8		9		



空闲空间管理

- 插入一条长为 x 的记录，应该插入到哪个页面？
- 堆表需要找到合适的页面（空闲空间大于 x 的页面）
 - 1 记录每个页面空间大小
 - 2 利用倒排列表

空闲空间编码	可用字节数	Page IDs
0	0~31	Page2, Page12
1	32~63	Page8, Page15
...	...	Page7, Page14
255	8164~8192	Page9, Page13



插入记录 - 有空闲页面

数据表

	学号	姓名	性别	院系	绩点
记录0	2021310001	张三	男	计算机系	3.9
记录1	2021310002	张四	女	计算机系	3.7
记录2	2021310003	张五	男	计算机系	4.0
记录3	2021310004	张六	男	法学系	3.7


①插入记录

页面空闲空间数组

空闲空间比例	30	233	10	0
页面编号	0	1	2	3

③查询到页面1有233/255*8k比例（即7485字节）空闲空间


②在头页面查询空闲页面编号



④在页面中插入记录并修改指针




插入记录 - 无空闲页面






查询记录 - 无索引





查询记录 - 有索引





删除和更新记录

□ 删除一条记录：首先查找到该条记录，然后删除

- 定长：bitmap置为0
- 变长：槽位清零

□ 更新一条记录：首先查找到该条记录，然后更新

- 定长：直接可以原位更新
- 变长：
 - 如果新纪录不长于老记录，原位更新，更新槽位
 - 如果新纪录长于老记录，槽位清零，插入新纪录
 - 本页面可以容纳，则插入本页面
 - 本页面不可以容纳，则插入其他页面



目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
5. 文件组织
- 6. 元数据存储**
7. 缓冲区
8. 行存储与列存储



元数据


□关系表本身的属性

- 表名，即关系表名称
- 列名，即关系表的属性名
- 属性的域和长度
- 视图的名称和定义
- 完整性约束，例如外键约束
- 关系表的属性的统计信息，可用于辅助查询优化
- 索引信息



元数据的关系模式

□像存储关系表一样来存储元数据






目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
5. 文件组织
6. 元数据存储
- 7. 缓冲区**
8. 行存储与列存储



缓冲区


□ 将存储于磁盘的数据同时存储于主存，减少磁盘访问





缓冲区组成


缓冲区数据主要包含缓存的磁盘数据页面、索引、日志等。日志可用于故障恢复。





缓冲区管理

1. 更新缓冲区页面
2. 更新缓冲区索引
3. 更新缓冲区日志
4. 更新磁盘日志
5. 返回提交成功
6. 异步刷新数据和索引页面





缓冲区管理器

□为数据访问提供读取、修改和写入接口

□页面替换过程：

当程序请求访问磁盘页面时

1.如果该页面已经在缓冲区中，则返回缓冲区中的页面数据

2.如果该页面不在缓冲区中，则从磁盘上读取该页面


(1)如果缓冲区未满，则将数据写入缓冲区

(2)如果缓冲区已满，则根据缓冲区页面替换策略挑选其他页面剔除或写回到磁盘上，再读入新页面



缓冲区——读取页面

1.如果该页面已经在缓冲区中，则返回缓冲区中的页面数据






缓冲区——读取页面

2.如果该页面不在缓冲区中，则从磁盘上读取该页面

➡(1)如果缓冲区未满，则将数据写入缓冲区

(2)如果缓冲区已满，则根据缓冲区页面替换策略挑选其他页面剔除或到磁盘上，再读入新页面






缓冲区——读取页面

2.如果该页面不在缓冲区中，则从磁盘上读取该页面

(1)如果缓冲区未满，则将数据写入缓冲区

➡(2)如果缓冲区已满，则根据缓冲区页面替换策略挑选其他页面剔除或到磁盘上，再读入新页面






缓冲区——写入页面

2.写页面时

(1)如果该页面在缓冲区中，则写入缓存、日志和索引

(2)如果该页面不在缓冲区中，则从磁盘上读取该页面，再写入页面到缓存、日志和索引






缓冲区——写入页面

2.写页面时

- (1)如果该页面在缓冲区中，则写入缓存、日志和索引
- (2)如果该页面不在缓冲区中，则从磁盘上读取该页面，再写入页面到缓存、日志和索引






缓冲区——写入页面

2.写页面时

- (1)如果该页面在缓冲区中，则写入缓存、日志和索引
- (2)如果该页面不在缓冲区中，则从磁盘上读取该页面，再写入页面到缓存、日志和索引





预写日志与故障恢复

□ 为什么使用日志：

- 如果缓冲区中的脏页面在写回到磁盘过程中发生故障，则无法保证写入的数据的正确性。
- 页面随机写 → 日志的顺序写

□ 数据库使用预写日志 (write-ahead log, WAL) 来备份数据的修改以防丢失

- 写入数据前先写入日志，日志包含即将写入的页面编号和写入的内容，也可以包含原先页面中的内容作为备份以供恢复。
- 在日志写入到磁盘后再进行事务的提交，保证事务的持久性。
- 故障并重启时，扫描日志来判断每个操作的成功与失败，并决定撤销或者重做这些操作。





缓冲区页面固定和锁

□ 当一个进程正在读取或写入某个页面时，该页面不应该被剔除，否则会读取或写入错误的数据

- 因此需要将使用中的页面暂时固定 (pin) 住

□ 共享锁 (shared locks) 和排他锁 (exclusive locks)

- 页面共享锁使多个进程可同时读取页面
- 页面排他锁保证一个进程在修改页面时其他进程不可访问页面





缓冲区页面替换策略

□ 管理页面替换，最大化缓冲区命中率，最小化访问磁盘次数

– 最近最少使用策略LRU

- 前1次使用时间越晚（越近期）的页面将来越有机会被使用，越不应该被替换

– 最不经常使用策略LFU

- 使用频率越高的页面将来越有机会被使用，越不应该被替换

– LRU-K策略

- 前第K次访问的时间越晚的页面将来越有机会被使用，越不应该被替换



缓冲区页面替换策略

□ 最近最少使用策略LRU

- 前1次使用时间越晚（越近期）的页面将来越有机会被使用，越不应该被替换

访问	1	2	3	1	4	5	3	6
槽位1	1	1	1	1	1	1	1	6
槽位2		2	2	2	2	5	5	5
槽位3			3	3	3	3	3	3
槽位4					4	4	4	4

绿色为命中缓冲区不需要读取磁盘，蓝色格子为需要读取磁盘操作。



缓冲区页面替换策略

□ 最近最少使用策略LRU

- 顺序扫描时的缺陷：顺序扫描的数据大于缓存大小时，LRU命中率降低。

访问	1	2	3	4	5	1	2	3
槽位1	1	1	1	1	5	5	5	5
槽位2		2	2	2	2	1	1	1
槽位3			3	3	3	3	2	2
槽位4				4	4	4	4	3

绿色为命中缓冲区不需要读取磁盘，蓝色格子为需要读取磁盘操作。



缓冲区页面替换策略

□ 最不经常使用策略LFU

- 使用频率越高的页面将来越有机会被使用，越不应该被替换

访问	1	2	3	1	2	4	5	3	1	2
槽位1	1	1	1	1	1	1	1	1	1	1
槽位2		2	2	2	2	2	2	2	2	2
槽位3			3	3	3	3	5	5	5	5
槽位4						4	4	3	3	3


绿色为命中缓冲区不需要读取磁盘，蓝色格子为需要读取磁盘操作。



故障恢复

- 刷新日志后（写盘），但是还没有刷新数据页面，系统宕机如何恢复？
- 如何保障故障正确性？

Insert (A, 2);
Insert (B, 3);
Insert (C, 4);
Insert (D, 5)
CRASH → Redo All





故障恢复


- 刷新日志后（写盘），但是还没有刷新数据页面，系统宕机如何恢复？
- 如何保障故障正确性？

Insert (A, 2);
Insert (B, 3);

刷盘

Insert (C, 4);
Insert (D, 5)

CRASH → Redo 4,5





目录

1. 存储概览
2. 存储介质
3. 存储结构
4. 页面组织
5. 文件组织
6. 元数据存储
7. 缓冲区
- 8. 行存储与列存储**



行存储与列存储


□ 行存储 (row-oriented storage) : 适合数据增删改

□ 列存储 (column-oriented storage)

– 提高数据分析查询的速度; 提升数据压缩率


学号	姓名	性别	院系	绩点
2021310001	张三	男	计算机系	3.9
2021310002	张四	女	计算机系	3.7
2021310003	张五	男	计算机系	4.0
2021310004	张六	男	法学系	3.7

行存储




学号	姓名	性别	院系	绩点
2021310001	张三	男	计算机系	3.9
2021310002	张四	女	计算机系	3.7
2021310003	张五	男	计算机系	4.0
2021310004	张六	男	法学系	3.7

列存储





行列混存： PAX格式





列存储文件组织

	学号	姓名
记录0	2021310001	张三
记录1	2021310002	张四
记录2	2021310003	张五
记录3	2021310004	张六
记录4	2021310006	张七
记录5	2021310009	张八
记录6	2021310013	张九
记录6	2021310013	张九
记录6	2021310013	张九
记录6	2021310013	张九
记录6	2021310013	张九



行数据组0



行数据组1




⋮





行列转换





行列混存：PAX格式

NSM (N-ary Storage Model)

PAGE HEADER				RH1	1237
Jane	30	RH2	4322	John	
45	RH3	1563	Jim	20	RH4
7658	Susan	52			
			•	•	•
			•	•	•

- 消除不必要的内存访问
- 保持记录的字段在一起
- 不影响I/O性能

PAX (Partition Attributes Across)

PAGE HEADER				1237	4322								
1563	7658												
Jane		John		Jim		Susan							
										.	.	.	.
30	52	45	20										



行列混存：ORC File


□ ORC (Optimized Row Columnar, 优化行列式)

□ 条带 (Stripe)

- 索引数据 (Index Data) : min\max值
- 行数据 (Row Data) : 列存的实际数据
- 条带尾部 (Stripe Footer) : 元数据
 - 每个列启示位置
 - 编码方式

□ 压缩:

- 数值: 游程压缩
- 文本: 字典





行列混存：Parquet 格式

□ 文件格式和魔数


□ 行组 (Row Group)

- 列块 (Column Chunk)
- 页 (Page)

□ 两层压缩

- 编码 (游程、增量、字典)
- 压缩

□ 统一的元数据





行存储与列存储比较

存储模型	优点	缺点
行存储	(1) 数据被保存在一起 (2) 插入和更新速度快	选择操作时即使只涉及某几列，所有数据也都会被读取
列存储	(1) 查询操作时只有涉及的列会被读取 (2) 投影操作很高效 (3) 易于压缩	(1) 选择操作完成时，被选择的列要重新组装 (2) 插入和更新速度慢



行存储与列存储适用场景

存储类型	适用场景
行存储	(1) 点查询（返回记录少，基于索引的简单查询） (2) 增、删、改操作较多的场景
列存储	(1) 统计分析类查询（关联、分组操作较多的场景） (2) 即席查询（用户灵活自定义条件，查询条件不确定，行存表扫描难以使用索引）



本章小结

- ❑ 数据库存储是数据库的核心模块，负责将用户的数据持久保存在存储介质中同时又要满足高并发访问、高I/O性能、故障恢复等要求。
- ❑ 数据库将关系表用一个或者多个文件存储，关系表中的记录按顺序排列在文件中。为了在海量的记录中高效的增、删、改、查，数据库设计了多种文件组织方法。
- ❑ 数据库将磁盘数据块统一用页面进行管理。页面包含多条记录，记录分为定长记录和变长记录。
- ❑ 缓冲区用于在主存中暂时保存部分磁盘页面的拷贝，可以大大减少数据库访问磁盘的次数，提高查询速度。缓冲区管理器根据页面替换策略管理页面的读入和换出。
- ❑ 行存储和列存储通过不同的存储顺序应对事务性场景和分析型场景。