




数值分析(4)

Numerical Analysis

计算机系 软件所 喻文健

第四章 线性方程组的迭代解法


■ 直接解法的不足

- 不适合希望准确度可调整的情况
- 时间复杂度高— $O(n^3)$ ；即使对稀疏阵，“填入”会导致计算时间、空间开销增大

■ 本章内容

- 一阶定常迭代法基本理论
- 三种经典迭代法(**Jacobi**, **G-S**, **SOR**)及其收敛性
- 非固定格式迭代法—共轭梯度法

很多概念可与第二章“非线性方程求根”作类比



迭代法基本概念

基本概念

■ 求解线性方程组 $Ax = b$ 的迭代法

- 通过向量序列 $x^{(0)}, x^{(1)}, \dots, x^{(k)}, \dots$ 逼近准确解 x^*
- 类似于不动点迭代法构造: $x^{(k+1)} = g(x^{(k)})$
- $x = g(x)$ 为与原方程等价的方程
- 为使每个迭代步计算量尽可能小, g 为线性函数:

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, \dots,$$

- B, f 为常数矩阵和向量. 称为“一阶定常迭代法”
- 具体的构造方法——矩阵分裂法

$$A = M - N \quad \longrightarrow \quad Mx - Nx = b \Leftrightarrow x = M^{-1}Nx + M^{-1}b$$

- 怎么选 M ?
1. M 非奇异; 2. 迭代法易收敛、收敛快;
3. 求解以 M 为系数矩阵的方程计算量小

雅可比迭代法 (Jacobi)

以3阶方程组为例说明

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 = b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 = b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 = b_3 \end{cases}$$

$$\begin{cases} x_1 = -\frac{1}{a_{11}} (a_{12}x_2 + a_{13}x_3) + \frac{b_1}{a_{11}} \\ x_2 = -\frac{1}{a_{22}} (a_{21}x_1 + a_{23}x_3) + \frac{b_2}{a_{22}} \\ x_3 = -\frac{1}{a_{33}} (a_{31}x_1 + a_{32}x_2) + \frac{b_3}{a_{33}} \end{cases}$$

■ 分量迭代计算公式

$$\begin{cases} x_1^{(k+1)} = -\frac{1}{a_{11}} (a_{12}x_2^{(k)} + a_{13}x_3^{(k)}) + \frac{b_1}{a_{11}} \\ x_2^{(k+1)} = -\frac{1}{a_{22}} (a_{21}x_1^{(k)} + a_{23}x_3^{(k)}) + \frac{b_2}{a_{22}} \\ x_3^{(k+1)} = -\frac{1}{a_{33}} (a_{31}x_1^{(k)} + a_{32}x_2^{(k)}) + \frac{b_3}{a_{33}} \end{cases}, \quad k = 0, 1, \dots, \quad \boxed{x^{(k)} \rightarrow x^{(k+1)}}$$

■ 设 $A = D - (D - A)$, D 为对角阵

$$Dx^{(k+1)} = (D - A)x^{(k)} + b \longrightarrow x^{(k+1)} = D^{-1}(D - A)x^{(k)} + D^{-1}b$$

雅可比迭代法

■ 算法4.2 雅可比迭代法 ($A = (a_{ij}) \in \mathbb{R}^{n \times n}$)

输入: x, A, b ; 输出: x .

While 不满足判停准则 do

$y := x$; {上一步迭代解}

For $i=1, 2, \dots, n$

$$x_i := (b_i - \sum_{j=1}^{i-1} a_{ij} y_j - \sum_{j=i+1}^n a_{ij} \widehat{y}_j) / a_{ii} ;$$

End

End

若 A 为稀疏阵, 改为只遍历非零元

前提：矩阵A的对角元不为零

- 每步迭代的计算量相当于一次矩阵与向量的乘法;
对于稀疏矩阵, 计算量为 $\text{nnz}(A)$ 次乘法
- 计算过程不改变矩阵 A 算法简单, 易实现

迭代法的有关理论

■ 判停准则

□ 类似“非线性方程求根”：残差判据、误差判据

□ $\|b - Ax^{(k)}\| \leq \epsilon_1$


□ $\|x^{(k)} - x^{(k-1)}\| \leq \epsilon_2$

实际应用时，使用由它们
衍生出的相对量判据

■ 一阶定常迭代法的收敛性

□ $x^{(k+1)} = Bx^{(k)} + f, k = 0, 1, \dots$, 考察误差 $e^{(k+1)} = x^{(k+1)} - x^*$

$$x^* = Bx^* + f \longrightarrow e^{(k+1)} = Be^{(k)} \longrightarrow e^{(k)} = B^k e^{(0)}$$

□ 对任意初始误差 $e^{(0)} \neq 0$, 希望一阶定常迭代法全局收敛  迭代矩阵 B 的幂序列 $\{B^k\}$: $\lim_{k \rightarrow \infty} B^k = 0$

迭代法的有关理论

- **定义4.1** $A^{(k)} = (a_{ij}^{(k)})$ 形成一矩阵序列, 若 $\lim_{k \rightarrow \infty} a_{ij}^{(k)} = a_{ij}$, $(\forall i, j)$, 则称序列 $\{A^{(k)}\}$ 收敛于 $A = (a_{ij})$
- **定理4.1** 矩阵算子范数的等价性: $c_1 \|A\|_{\infty} \leq \|A\|_t \leq c_2 \|A\|_{\infty}$
- **定理4.2** 矩阵序列收敛 $\Leftrightarrow$ 误差的算子范数收敛到0
- **定理4.3** $\lim_{k \rightarrow \infty} A^{(k)} = A \Leftrightarrow \forall x \text{ 都有 } \lim_{k \rightarrow \infty} A^{(k)} x = Ax$ 回忆向量

推论 □ 一阶定常迭代法, 要 $\lim_{k \rightarrow \infty} B^k = O \Leftrightarrow \forall x \text{ 都有 } \lim_{k \rightarrow \infty} B^k x = 0$

- **定义4.2** 矩阵的谱半径 $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$, λ_i 为 A 的特征值
- **例:** $A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & -1 & 1 \end{bmatrix}$, $\det(\lambda I - A) = 0 \xrightarrow{\text{yellow}} (\lambda - 1)[(\lambda - 1)^2 + 1] = 0$
 $\xrightarrow{\text{yellow}} \rho(A) = \sqrt{2}$

迭代法的收敛性

- **定理4.4** 若矩阵 $A \in \mathbb{R}^{n \times n}$, 则 $\rho(A) \leq \|A\|$; 若 A 为实对称矩阵, 则 $\|A\|_2 = \rho(A)$
算子范数
- **定理4.5** 设 $B = (b_{ij}) \in \mathbb{R}^{n \times n}$, 则 $\lim_{k \rightarrow \infty} B^k = \mathbf{0} \iff \rho(B) < 1$
 - 利用相似标准型 $B = X\Lambda X^{-1}$, 或更一般Jordan标准型
- **定理4.6** 迭代法 $x^{(k+1)} = Bx^{(k)} + f$, ($k = 0, 1, \dots$), 且 $I - B$ 非奇异, 则: 对任意初始 $x^{(0)}$ 它收敛 $\iff \rho(B) < 1$. 并且, 收敛值 x^* 是方程 $x = Bx + f$ 的唯一解 (迭代法基本定理)
- **证明:** $\longleftarrow$ 设迭代解误差 $e^{(k)} = x^{(k)} - x^*$, 则 $e^{(k)} = B^k e^{(0)}$, 由定理4.5, $\lim_{k \rightarrow \infty} B^k = \mathbf{0}$, 再由定理4.3, 对任意 $e^{(0)}$ 或 $x^{(0)}$, $\lim_{k \rightarrow \infty} e^{(k)} = \mathbf{0}$, 即迭代法收敛
 $\longrightarrow$ 的证明, 请思考 ($I - B$ 非奇异很重要, 即原方程解唯一)

迭代法的收敛性

- $\rho(\mathbf{B}) < 1$ 是一阶定常迭代法的收敛判据
 - 对任意初值 $\mathbf{x}^{(0)}$, 迭代法都收敛 (全局收敛)
- 若某种范数下 $\|\mathbf{B}\|_t < 1$, 则收敛 (充分条件) 定理4.7
- 收敛阶

□ 若 $\lim_{k \rightarrow \infty} \|\mathbf{e}^{(k+1)}\| / \|\mathbf{e}^{(k)}\|^p = c$, 则 p 阶收敛 $\mathbf{e}^{(k+1)} = \mathbf{B}\mathbf{e}^{(k)}$

非亏损阵


- 设 $\mathbf{B}$ 可对角化, 特征值按模递减为 $\{\lambda_i\}$, 特征向量 $\{\mathbf{u}_i\}$
- 设 $\mathbf{e}^{(0)} = \sum_{i=1}^n \alpha_i \mathbf{u}_i$, 各误差成份随迭代衰减情况如下

$\mathbf{e}^{(0)}$	$\alpha_1 \mathbf{u}_1$	$\alpha_2 \mathbf{u}_2$	$\cdots$	$\alpha_n \mathbf{u}_n$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\mathbf{e}^{(k)} = \mathbf{B}^k \mathbf{e}^{(0)}$	$\lambda_1^k \alpha_1 \mathbf{u}_1$	$\lambda_2^k \alpha_2 \mathbf{u}_2$	$\cdots$	$\lambda_n^k \alpha_n \mathbf{u}_n$

最大

最小

可证明:
1阶收敛, 且
 $c = |\lambda_1| = \rho(\mathbf{B})$



更多经典迭代法 及其收敛性

高斯-赛德尔迭代法 (Gauss-Seidel)

■ 与雅可比迭代法类似

■ 求出 $x^{(k+1)}$ 的第1个分量后,
即用它求第2个分量 $x_2^{(k+1)}$.
依次类推, 得

$$\begin{cases} x_1 = -\frac{1}{a_{11}} (a_{12}x_2 + a_{13}x_3) + \frac{b_1}{a_{11}} \\ x_2 = -\frac{1}{a_{22}} (a_{21}x_1 + a_{23}x_3) + \frac{b_2}{a_{22}} \\ x_3 = -\frac{1}{a_{33}} (a_{31}x_1 + a_{32}x_2) + \frac{b_3}{a_{33}} \end{cases}$$

$$\begin{cases} x_1^{(k+1)} = -\frac{1}{a_{11}} (a_{12}x_2^{(k)} + a_{13}x_3^{(k)}) + \frac{b_1}{a_{11}} \\ x_2^{(k+1)} = -\frac{1}{a_{22}} (a_{21}x_1^{(k+1)} + a_{23}x_3^{(k)}) + \frac{b_2}{a_{22}} \\ x_3^{(k+1)} = -\frac{1}{a_{33}} (a_{31}x_1^{(k+1)} + a_{32}x_2^{(k+1)}) + \frac{b_3}{a_{33}} \end{cases}, k = 0, 1, \dots,$$

注意计算顺序

■ 设 $A = D - \tilde{L} - \tilde{U}$, 则迭代公式为

$$Dx^{(k+1)} = \tilde{L}x^{(k+1)} + \tilde{U}x^{(k)} + b \longrightarrow (D - \tilde{L})x^{(k+1)} = \tilde{U}x^{(k)} + b$$

$$\longrightarrow x^{(k+1)} = L^{-1}(L - A)x^{(k)} + L^{-1}b, \quad L \text{ 为 } A \text{ 的下三角阵} \quad \text{分裂法: } M = L$$

$$L = D - \tilde{L}$$

高斯-赛德尔迭代法

```
y := x;           {上一步迭代解}
For i=1, 2, ..., n
  xi := (bi -  $\sum_{j=1}^{i-1} a_{ij}y_j$  -  $\sum_{j=i+1}^n a_{ij}y_j$ )/aii ;
```

■ 算法4.3 高斯-赛德尔迭代法

输入: x, A, b ; 输出: x .

While 不满足判停准则 do

For $i=1, 2, \dots, n$

$x_i := (b_i - \sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^n a_{ij}x_j)/a_{ii}$;

End

End

若 A 为稀疏
阵, 改为只
遍历非零元

- 每步迭代的计算量相当于一次矩阵与向量相乘; 不需保留上一步迭代解, 与雅可比迭代法计算量一样
- 按从1到 n 的顺序计算解分量. 若从 n 到1更新解分量, 则得“逆向G-S算法”; 对称高斯-赛德尔(SGS)迭代法

思考: 推导它们的迭代公式, 及相应的矩阵 M, N

SOR迭代法 (逐次超松弛)

- Successive over-relaxation method
- 在G-S迭代法基础上引入松弛因子 ω 可能超出 $[0, 1]$ 范围
- 先按G-S方法由 $x^{(k)}$ 算得 $\tilde{x}_1^{(k+1)}$, 再将它与 $x_1^{(k)}$ 作加权平均得 $x_1^{(k+1)}$... 类似地依次算出后续分量

3阶方程的
计算公式

$\omega=1$ 时, 是G-S方法

$\omega=0$ 时 ?

$$\begin{cases} x_1^{(k+1)} = (1 - \omega)x_1^{(k)} + \omega \left(-\frac{a_{12}}{a_{11}}x_2^{(k)} - \frac{a_{13}}{a_{11}}x_3^{(k)} + \frac{b_1}{a_{11}} \right) \\ x_2^{(k+1)} = (1 - \omega)x_2^{(k)} + \omega \left(-\frac{a_{21}}{a_{22}}x_1^{(k+1)} - \frac{a_{23}}{a_{22}}x_3^{(k)} + \frac{b_2}{a_{22}} \right) \\ x_3^{(k+1)} = (1 - \omega)x_3^{(k)} + \omega \left(-\frac{a_{31}}{a_{33}}x_1^{(k+1)} - \frac{a_{32}}{a_{33}}x_2^{(k+1)} + \frac{b_3}{a_{33}} \right) \end{cases}$$

- 一般地, 设 $A = D - \tilde{L} - \tilde{U}$, 则SOR迭代公式为

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega D^{-1} [\tilde{L}x^{(k+1)} + \tilde{U}x^{(k)} + b]$$

SOR迭代法

- $\mathbf{x}^{(k+1)} = (1 - \omega)\mathbf{x}^{(k)} + \omega\mathbf{D}^{-1}[\tilde{\mathbf{L}}\mathbf{x}^{(k+1)} + \tilde{\mathbf{U}}\mathbf{x}^{(k)} + \mathbf{b}]$
- $\mathbf{x}^{(k+1)} = (\mathbf{D} - \omega\tilde{\mathbf{L}})^{-1}[(1 - \omega)\mathbf{D} + \omega\tilde{\mathbf{U}}]\mathbf{x}^{(k)} + (\mathbf{D} - \omega\tilde{\mathbf{L}})^{-1}\omega\mathbf{b}$
- 要求矩阵 A 的对角元不为0 对应于分裂法中, $\mathbf{M} = \frac{1}{\omega}\mathbf{D} - \tilde{\mathbf{L}}$
- **算法4.4 SOR迭代法**

输入: $\mathbf{x}, \mathbf{A}, \mathbf{b}, \omega$; 输出: $\mathbf{x}$.

While 不满足判停准则 **do**

For $i=1, 2, \dots, n$

$$x_i := (1 - \omega)x_i + \omega (b_i - \sum_{j=1}^{i-1} a_{ij}x_j - \sum_{j=i+1}^n a_{ij}x_j) / a_{ii};$$

End

End

- 计算量与G-S迭代法差不多
- 需按从1到n的顺序计算解分量

例子

- **例4.3 / 4.4:** 解线性方程组, 设 $\mathbf{x}^{(0)} = [0, 0, 0]^T$
(课本 § 4.2)
$$\begin{bmatrix} 10 & 3 & 1 \\ 2 & -10 & 3 \\ 1 & 3 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 14 \\ -5 \\ 14 \end{bmatrix}$$
 准确解 $\mathbf{x}^* = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$
- **Jacobi**迭代(解分量误差小于 10^{-3})
 - $\mathbf{x}^{(8)} = [1.0001, 0.9991, 1.0001]^T$ 都收敛!
- **G-S**迭代
 - $\mathbf{x}^{(5)} = [0.9998, 0.9998, 1.0001]^T$ 收敛快慢不同
- **SOR**迭代
 - 当 $\omega = 0.95$, $\mathbf{x}^{(4)} = [1.0008, 0.9999, 0.9999]^T$
 - 当 $\omega = 1.1$, $\mathbf{x}^{(6)} = [1.0005, 1.0005, 0.9997]^T$
 - 当 $\omega = 0.6$, $\mathbf{x}^{(9)} = [1.0010, 1.0001, 0.9998]^T$

三种迭代法的收敛条件

A 都是非奇异阵

- 一阶定常迭代法的收敛判据: 迭代矩阵的谱半径 $\rho(B) < 1$
- **Jacobi**迭代法: $B_J = D^{-1}(D - A)$ ✓ 计算迭代矩阵?
- **G-S**迭代法: $B_G = L^{-1}(L - A)$ ✗
- **SOR**迭代法: $B_S = (D - \omega \tilde{L})^{-1}[(1 - \omega)D + \omega \tilde{U}]$ ✗
- **Jacobi**迭代法收敛性的判断

□ 形成迭代矩阵, 若 $\|B_J\|_1 < 1$ 或 $\|B_J\|_\infty < 1$, 则迭代法收敛

Th4.8 □ 若 A 为 对角元 > 0 的对称阵, 全局收敛 $\longleftrightarrow A$ 与 $2D - A$ 都正定

思考: $B_J = D^{-1}(D - A) = D^{-1/2}(D^{1/2} - D^{-1/2}A) = D^{-1/2}(I - D^{-1/2}AD^{-1/2})D^{1/2}$

- **G-S**迭代法收敛性的判断

Th4.9 □ 考察 **Jacobi** 方法的迭代矩阵 B_J , 若 $\|B_J\|_1 < 1$ 或 $\|B_J\|_\infty < 1$, 则 **G-S** 迭代法收敛

三种迭代法的收敛条件

- 通过系数矩阵 A 判断; 常见情况: 对角占优, 对称正定

- **定义4.5** 设 $A \in \mathbb{R}^{n \times n}$, ($n \geq 2$), 若存在排列阵 P 使

$$P^T A P = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ \mathbf{O} & \tilde{A}_{22} \end{bmatrix} \quad \text{其中 } \tilde{A}_{11}, \tilde{A}_{22} \text{ 均为方阵}$$

方程求解
特征值计算

则 A 为**可约矩阵**(reducible matrix), 否则为**不可约矩阵**

- 例子 $\begin{bmatrix} \text{元} & \text{素} & \text{均} \\ \text{不} & \text{为} & \text{零} \\ \text{的} & \text{矩} & \text{阵} \end{bmatrix} \begin{bmatrix} \times & \times & & \\ \times & \times & \ddots & \\ & \ddots & \ddots & \times \\ & & \times & \times \end{bmatrix} \quad \begin{matrix} \curvearrowright \\ \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 2 & 2 \end{bmatrix} \end{matrix}$

- 对角占优矩阵 (按行、按列两种情况)

课后思考

Th4.10 □ **对角占优定理**: 若矩阵 A 为严格对角占优矩阵, 或者不可约的弱对角占优矩阵, 则 A 非奇异 (“不可约”很重要)

Th4.11 □ 对这样的 A , 求解 $Ax = b$ 的**Jacobi**与**G-S**迭代法都收敛

三种迭代法的收敛条件

(特征方程)

证明hint: 迭代矩阵, 反证法

■ 对角占优矩阵 (续)

Th4.11 □ 对严格对角占优(或不可约弱对角占优)矩阵, 若松弛因子 $0 < \omega \leq 1$, 则求解 $Ax = b$ 的SOR迭代法收敛

■ 定理4.12 对称正定矩阵A

□ 求解 $Ax = b$ 的G-S迭代法收敛

□ 若 $0 < \omega < 2$, 则相应的SOR迭代法收敛

■ 定理4.13 SOR迭代法收敛的必要条件是: 松弛因子 ω 满足 $0 < \omega < 2$

□ 证明: $B_S = (D - \omega \tilde{L})^{-1} [(1 - \omega)D + \omega \tilde{U}]$

$$\det(B_S) = \det((D - \omega \tilde{L})^{-1}) \det((1 - \omega)D + \omega \tilde{U}) = (1 - \omega)^n$$


另, $\det(B_S) = \lambda_1 \lambda_2 \cdots \lambda_n$  $|\det(B_S)| < 1$  $|1 - \omega| < 1$

三种迭代法的收敛条件

■ 求解方程 $Ax = b$

	Jacobi	G-S	SOR
对角占优阵 A	收敛	收敛	$0 < \omega \leq 1$ 时收敛
对称正定阵 A	若 A 对角元 > 0 且 $2D - A$ 对称正定, 则收敛	收敛	$0 < \omega < 2$ 时收敛*


- *这也是 **SOR** 对任意矩阵 A 收敛的必要条件
- **G-S** 和 **SOR** 比 **Jacobi** 适用范围更大些



共轭梯度法简介

最速下降法

若 A 不是
正定矩阵:



■ 构造迭代法的新思路


- 求解大规模线性方程组，一阶定常迭代法(SOR)收敛慢
- “变分原理”：解线性方程组 $\rightarrow$ 在 n 维空间搜索极值点

设 A 对称正定, 求 n 元二次函数 $\varphi(x) = \frac{1}{2} x^T A x - b^T x$ 的最小值点

$$\begin{cases} \frac{\partial \varphi}{\partial x_1} = a_{11}x_1 + \sum_{j \neq 1} a_{1j}x_j - b_1 = 0 \\ \vdots \\ \frac{\partial \varphi}{\partial x_n} = a_{nn}x_n + \sum_{j \neq n} a_{nj}x_j - b_n = 0 \end{cases} \quad \longrightarrow \quad Ax - b = 0$$

这个极值点一定是最小值?

$\varphi(x)$ 是定义在 $\mathbb{R}^n$ 空间上的标量场,
 $\varphi(x)$ 最小值对应的 x 就是 $Ax = b$ 的解



最速下降法

■ 直线搜索


- 求 $\varphi(x) = \frac{1}{2}x^T Ax - b^T x$ 的最小值点
- 无约束优化问题, 逐次搜索: $x^{(0)}, x^{(1)}, \dots, x^{(k)}, \dots$
- 在当前点 $x^{(k)}$, 设搜索方向 $p^{(k)}$, $x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$
- 步长 α_k 应使 $\varphi(x^{(k+1)})$ 最小 $\longrightarrow \alpha_k = \frac{(r^{(k)})^T p^{(k)}}{(p^{(k)})^T A p^{(k)}}$

梯度

$$\nabla \varphi(x^{(k)}) = \begin{bmatrix} \frac{\partial \varphi}{\partial x_1} \\ \vdots \\ \frac{\partial \varphi}{\partial x_n} \end{bmatrix} \bigg|_{x=x^{(k)}} = Ax^{(k)} - b = -r^{(k)}$$

■ 最速下降法 (如何选 $p^{(k)}$?)


- 沿负梯度方向 $p^{(k)} = r^{(k)}$ 搜索, 得 $\alpha_k = \frac{(r^{(k)})^T r^{(k)}}{(r^{(k)})^T A r^{(k)}}$



几何意义? 与等值面相切

$$(p^{(k)})^T r^{(k+1)} = 0$$

其中 $r^{(k)} = b - Ax^{(k)}$



最速下降法

■ 算法4.5 解线性方程组的最速下降算法 (steepest descent)

输入: x, A, b ; 输出: x .

$r := b - Ax$;

While 不满足判停准则 do

$\alpha := r^T r / r^T Ar$;

$x := x + \alpha r$;

$r := r - \alpha Ar$;

End

用残差判据无额外代价

常用相对残差 $\|b - Ax\| / \|b\|$

$$\Delta x = \alpha r$$

$$r = b - Ax$$

$$\begin{aligned} \Delta r &= -A\Delta x \\ &= -\alpha Ar \end{aligned}$$

- 每步做一次矩阵与向量乘法, 运算量与SOR迭代法一样
- 需额外存储2个向量
- $\varphi(x)$ 凸二次函数, 有唯一最小值点, 最速下降法一定收敛


最速下降法

■ 例: 解 $Ax = b$, $A = \begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix}$, $b = \begin{bmatrix} 2 \\ -8 \end{bmatrix}$

□ 设初始解为 $x^{(0)} = [-2, -2]^T$

□ $x^{(1)} = \begin{bmatrix} 0.08 \\ -0.6133 \end{bmatrix}$, ..., $x^{(9)} = \begin{bmatrix} 1.9926 \\ -1.9947 \end{bmatrix}$

□ $\varphi(x) = \frac{3}{2}x_1^2 + 2x_1x_2 + 3x_2^2 - 2x_1 + 8x_2$




最速下降法的缺点

□ 虽然每步找到局部最优解,
但整体效率低

□ 迭代法收敛速度慢

对一般优化问题: (随机)梯度下降法

推不出最优步长. 用负梯度方向、小的正数 α



共轭梯度法

没必要沿最速
下降方向搜索!


■ Conjugate Gradient method (CG法)

□ 从当前点 $x^{(k)}$ 出发, 沿 $r^{(k)}$ 方向 $\varphi(x)$ 的值减小最快

改进 □ 前一个搜索方向是 $p^{(k-1)}$ ($x^{(k+1)} = x^{(k)} + \xi r^{(k)} + \eta p^{(k-1)}$)

之处: □ 在过 $x^{(k)}$, 上述两方向张成的平面上找函数 φ 的最小值

详见课本



$$p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)},$$

$$\beta_{k-1} = - \frac{(r^{(k)})^T A p^{(k-1)}}{(p^{(k-1)})^T A p^{(k-1)}}$$


$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$\alpha_k = \frac{(r^{(k)})^T p^{(k)}}{(p^{(k)})^T A p^{(k)}}$$

□ 例4.8 (与前例相同)

■ $n=2$

保证两步内收敛!



共轭梯度法

■ 几个重要的结论

- $(p^{(k)})^T A p^{(k-1)} = 0$, 搜索方向相互“**A正交**” (**共轭正交**) 思考
- $x^{(k+1)} \in x^{(0)} + \text{span}\{r^{(0)}, A r^{(0)}, \dots, A^k r^{(0)}\}$ Krylov子空间 $\mathcal{K}(A, r^{(0)})$
- $x^{(k+1)}$ 不但在向量 $r^{(k)}$ 和 $p^{(k-1)}$ 所张仿射平面上使 $\varphi(x)$ 最小, 且在仿射子空间 $x^{(0)} + \mathcal{K}(A, r^{(0)})$ 上使 $\varphi(x)$ 最小 k + 1维
- 若不考虑数值误差, $x^{(n)}$ 为准确解

算法4.7:

```
r := b - Ax ; p := r ;
While 不满足判停准则 do
    α := rTr / pTA p ;           {计算搜索步长}
    x := x + α p ;                 {更新解}
     $\tilde{r} := r$  ; r := r - α A p ; {更新残差向量}
    β := rTr /  $\tilde{r}^T \tilde{r}$  ;
    p := r + β p ;                 {新的搜索方向}
End
```

一次矩阵向量乘法
两次向量内积
收敛所需步数 ≤ n

可扩展到一般非线性
优化问题

共轭梯度法

$$\frac{\|e_{k+1}\|_A}{\|e_k\|_A} \leq \frac{\sqrt{\text{cond}(A)_2} - 1}{\sqrt{\text{cond}(A)_2} + 1}$$

■ 说明几点

- 针对对称正定阵, 是具有迭代法形式的“直接解法”
- 虽然n步收敛到准确解, 但当k很大时, 舍入误差严重
- 对于病态矩阵, 可能收敛很慢, 甚至不收敛

■ 预条件技术 (preconditioned CG)

PCG算法有时可达超线性收敛阶

- 改善系数矩阵病态性, 加速迭代法的收敛

$$Ax = b \iff M^{-1}Ax = M^{-1}b, \quad M^{-1}A \text{ 的性质很好}$$

- 要保证系数矩阵正定, 取对称正定 M , 设 $M = LL^T$

$$Ax = b \iff \underline{L^{-1}AL^{-T}}y = L^{-1}b, \quad x = L^{-T}y$$

算法技巧

- 每步迭代中只需额外算一次 $M^{-1}r$ 怎么选 M , 或得到 L ?

实用技术

■ Matlab中的预条件CG法

- $[x, \text{flag}, \text{relres}, \text{iter}, \text{resvec}] = \text{pcg}(A, b, \text{tol}, \text{maxit}, M_1, M_2, x_0)$
- tol是迭代停止阈值, 控制相对残差 $\|b - Ax\|/\|b\|$
- maxit是迭代步上限, M_1, M_2 是预条件矩阵, 需保证 $M = M_1 M_2$ 为对称正定矩阵, $M^{-1}r$ 易于计算 (可只输入一个 M)
- relres是相对残差, iter为迭代步数, flag是标志信息

■ 构造预条件与其他Krylov子空间迭代法 Matlab演示

- 不完全Cholesky分解 ($L = \text{ichol}(A, \text{opt})$) opt.type='ict';
opt.droptol= 0.004;
- droptol值在0~1之间, =0是完全分解, =1时 L 为对角阵
- 针对一般非对称阵的迭代法: **GMRES, BICG**等
- **Matlab**命令: minres, gmres, bicgstab(l), cgs, qmr, ...


方法比较

■ 迭代法的比较 (第4.4节)

- 二维模型问题, 规模不同的一系列问题
- 收敛速度: **Jacobi** < **G-S** < **SOR** < **CG**
- 随着k增大, 前三种方法的 $\rho(B)$ 趋于1
- 共轭梯度法的收敛速度更快

■ 直接法与迭代法比较


- 直接法稳定、通用, 但不灵活, 处理大规模问题有困难
- 迭代法能更好地利用矩阵稀疏性, 可灵活设置准确度, 但无通用有效方法, 需依靠预条件技术改善收敛速度



$$\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = 0$$

$$\begin{cases} 4u_{1,1} - u_{0,1} - u_{2,1} - u_{1,0} - u_{1,2} = 0 \\ 4u_{2,1} - u_{1,1} - u_{3,1} - u_{2,0} - u_{2,2} = 0 \\ 4u_{1,2} - u_{0,2} - u_{2,2} - u_{1,1} - u_{1,3} = 0 \\ 4u_{2,2} - u_{1,2} - u_{3,2} - u_{2,1} - u_{2,3} = 0 \end{cases}$$

k=3



直接法与迭代法的比较 (续)

- 没用好的预条件 求解 $Ax = b$, $A \in \mathbb{R}^{n \times n}$

<i>Time Complexity</i>	稀疏矩阵 A	稠密矩阵 A
Krylov iterative (Theorem: $k \leq n$)	$O(kn) \leq O(n^2)$	$O(kn^2) \leq O(n^3)$
Direct method LU decomposition	$O(n^{1.2 \sim 1.8})$	$O(n^3)$

- 使用了好的预条件

- 取得3~4位数字精度, 迭代步数 k 常常只需10~50

<i>Time Complexity</i>	稀疏矩阵 A	稠密矩阵 A
Krylov iterative (k is a small const.)	$O(n)$	$O(n^2)$
Direct method LU decomposition	$O(n^{1.2 \sim 1.8})$	$O(n^3)$

巨大改善