




数值分析(6)

Numerical Analysis

计算机系 软件所 喻文健

第六章 函数逼近与函数插值

- 用较简单的函数表示已知的复杂函数、或未知函数
- 逼近：整体上近似 (整体误差最小)
- 插值：在若干点上两者的值相等 (误差为0)
- 本章内容
 - 函数逼近的基本概念
 - 连续函数的最佳平方逼近
 - 曲线拟合的最小二乘法
 - 多项式插值 (拉格朗日, 牛顿)
 - 分段多项式插值
 - 样条函数插值

函数逼近问题的例子

■ 已知表达式的函数的逼近

□ $f(t) = \sqrt{1+t^2} \approx a_0 + a_1 t$

□ $f(t) = |t| \approx \frac{\pi}{2} - \frac{4}{\pi} \cos(t)$

□ $\approx \frac{\pi}{2} - \frac{4}{\pi} \cos(t) - \frac{4}{9\pi} \cos(3t)$



傅里叶变换, 信号的频谱分析


■ 一系列数据点的逼近

□ $t=[1, 1.5, 2, 2.5, 3, 3.5, 4];$

□ $f=[33.4, 79.5, 122.65, \dots$
 $159.05, 189.15, 214.15, 238.65];$

表格函数, 曲线拟合






函数逼近的基本概念

函数逼近的基本概念

■ 问题描述

- 对给定函数 $f(x)$, 在某个较简单的函数类 Φ 中找 $p(x)$, 使得在某种度量意义下误差函数 $p(x) - f(x)$ 最小
- $f(x)$: 有表达式的复杂函数, 或表格函数 (数据对应关系)
- Φ : 多项式、指数函数、三角函数、有理分式、分段多项式等



■ 函数空间

- 某定义域上的所有函数构成线性空间 (值域 $\mathbb{R}$, or $\mathbb{C}$)
- 实连续函数集合 $C[a, b]$, k 阶导数连续函数集合 $C^k[a, b]$ 均构成无限维的线性空间
- 用范数度量函数的大小、误差函数的大小

函数逼近的基本概念

■ $C[a, b]$ 上的常用范数

□ ∞ -范数

□ $\|f(x)\|_{\infty} = \max_{x \in [a, b]} |f(x)|$

□ 1-范数


□ $\|f(x)\|_1 = \int_a^b |f(x)| dx$

□ 2-范数

□ $\|f(x)\|_2 = \left[\int_a^b f^2(x) dx \right]^{1/2}$

■ $C[a, b]$ 上的内积 (一般的实内积见 **定义6.1**)

□ $\langle u(x), v(x) \rangle = \int_a^b u(x)v(x) dx$, 内积范数 $\|u\| \equiv \sqrt{\langle u, u \rangle} \equiv \|u\|_2$
(复数域上的内积有所不同)



$$\langle u+av, u+av \rangle = \langle u, u \rangle + 2a\langle u, v \rangle + a^2\langle v, v \rangle \geq 0$$

$$\text{设 } a = \frac{-\langle u, v \rangle}{\langle v, v \rangle}, \dots$$

(用向量内积理解含义)

函数逼近的基本概念

■ **Th6.1:** Cauchy-Schwarz不等式 $|\langle u, v \rangle|^2 \leq \langle u, u \rangle \cdot \langle v, v \rangle$

■ **Th6.2:** 设 S 为实内积空间, $u_1, \dots, u_n \in S$, 则Gram矩阵

$$G = \begin{bmatrix} \langle u_1, u_1 \rangle & \langle u_2, u_1 \rangle & \cdots & \langle u_n, u_1 \rangle \\ \langle u_1, u_2 \rangle & \langle u_2, u_2 \rangle & \cdots & \langle u_n, u_2 \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle u_1, u_n \rangle & \langle u_2, u_n \rangle & \cdots & \langle u_n, u_n \rangle \end{bmatrix}$$

反证法: 存在 $x \neq 0$,

$$x^T G x = \langle \sum_{j=1}^n x_j u_j, \sum_{j=1}^n x_j u_j \rangle = 0$$

对称正定

非奇异的充要条件是 $u_1, \dots, u_n$ 线性无关 $\Leftrightarrow$?

■ 证明: 矩阵 G 非奇异 $\Leftrightarrow$ 线性方程组 $Ga = 0$ 只有全零解

反证法证必要性, 若 $u_1, \dots, u_n$ 线性相关, 存在非零向量 a


取 $k=1, 2, \dots, n$ 矛盾!

$$\sum_{j=1}^n a_j u_j = 0 \xrightarrow{\text{取 } k=1, 2, \dots, n} \forall k, \sum_{j=1}^n a_j \langle u_j, u_k \rangle = \langle \sum_{j=1}^n a_j u_j, u_k \rangle = 0, \text{ 即 } Ga = 0$$

充分性的证明 ...

函数逼近的基本概念

- **定义6.2:** 权函数 $\rho(x)$, 针对实函数空间 $C[a, b]$, 满足
 - $\rho(x) \geq 0, \forall x \in [a, b]$ (非负)
 - $\int_a^b x^k \rho(x) dx$ 存在, $(k = 0, 1, \dots)$ (多项式可积)
 - 对非负连续函数 $g(x)$, 若 $\int_a^b g(x) \rho(x) dx = 0$, 则 $g(x) \equiv 0$ (无局部恒为零)
- $C[a, b]$ 中一般的非负函数, 不在某个子区间上恒为0, 则可当权函数
- **定义6.3:** 加权内积
 - $\langle u(x), v(x) \rangle = \int_a^b \rho(x) u(x) v(x) dx$ 特例: $\rho(x) \equiv 1$
 - 内积范数: $\|f(x)\| = \left[\int_a^b \rho(x) f^2(x) dx \right]^{1/2}$ (广义的2-范数)




函数逼近的基本概念

- 按逼近误差的度量方式分类

- ∞ -范数: **最佳一致逼近**


- $\varepsilon = \|p(x) - f(x)\|_{\infty}$ 最小
- $-\varepsilon \leq p(x) - f(x) \leq \varepsilon, \forall x$
- $p(x)$ 在区间上**一致地**接近 $f(x)$



(“最大”误差尽量小)


- 1-范数, 2-范数

- $A = \|p(x) - f(x)\|_1$ 最小
- A 为两条曲线间的面积
- 区间上“平均”的误差



- 2-范数含义类似, 易于求解, 为**最佳平方(最小二乘)逼近**

- 求最佳一致逼近很复杂、困难, 仅考虑最佳平方逼近



连续函数的最佳平方逼近

最佳平方逼近

■ 问题描述

函数自变量改为 t

- 对 $f(t) \in C[a, b]$ 进行函数逼近
- 函数类 Φ 一般是线性空间, $\text{span}\{\varphi_1(t), \dots, \varphi_n(t)\}$
线性无关的一组基
- 求 $S(t) \in \Phi$, $S(t) = \sum_{j=1}^n x_j \varphi_j(t)$, 使 $\|S(t) - f(t)\|_2$ 最小

■ 问题的求解

$$\begin{aligned} F &\equiv \|S(t) - f(t)\|_2^2 = \langle \sum_{j=1}^n x_j \varphi_j - f, \sum_{j=1}^n x_j \varphi_j - f \rangle \\ &= \sum_{j=1}^n \sum_{l=1}^n x_j x_l \langle \varphi_j, \varphi_l \rangle - 2 \sum_{j=1}^n x_j \langle f, \varphi_j \rangle + \langle f, f \rangle \quad n\text{元二次函数} \\ \frac{\partial F}{\partial x_k} &= 2x_k \langle \varphi_k, \varphi_k \rangle + 2 \sum_{j \neq k} x_j \langle \varphi_j, \varphi_k \rangle - 2 \langle f, \varphi_k \rangle = 0, (k = 1, \dots, n) \end{aligned}$$

求解线性方程组 $Gx = b$, 即得到 x , 进而得到 $S(t)$ 法方程方法

最佳平方逼近


■ 法方程方法: 求解 $Gx = b$

$$G = \begin{bmatrix} \langle \varphi_1, \varphi_1 \rangle & \langle \varphi_2, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_1 \rangle \\ \langle \varphi_1, \varphi_2 \rangle & \langle \varphi_2, \varphi_2 \rangle & \cdots & \langle \varphi_n, \varphi_2 \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_1, \varphi_n \rangle & \langle \varphi_2, \varphi_n \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \end{bmatrix}, \quad b = \begin{bmatrix} \langle f, \varphi_1 \rangle \\ \langle f, \varphi_2 \rangle \\ \vdots \\ \langle f, \varphi_n \rangle \end{bmatrix}$$

- G 为 Gram 矩阵, 对称正定, 法方程存在唯一解
- 这个解会让 $\|S(t) - f(t)\|_2^2$ 达到最小值吗? (充分性)
- 设法方程的解为 x^* , 逼近问题的解 $S^* = \sum_{j=1}^n x_j^* \varphi_j$

法方程中第 k 个方程 $\sum_{j=1}^n x_j^* \langle \varphi_j, \varphi_k \rangle = \langle f, \varphi_k \rangle$


即 $\langle S^*, \varphi_k \rangle = \langle f, \varphi_k \rangle \longrightarrow \langle S^* - f, S \rangle = 0, \forall S \in \Phi$ 性质: $S^* - f \perp \Phi$



最佳平方逼近

■ 法方程方法

$$S^* - f \perp \Phi$$



- 要证充分性, 考虑任意 $S \in \Phi$, $\langle S - f, S - f \rangle - \langle S^* - f, S^* - f \rangle$
- $= \langle S, S \rangle - 2\langle f, S \rangle - \langle S^*, S^* \rangle + 2\langle f, S^* \rangle$
- $= \langle S, S \rangle - 2\langle S, S^* \rangle + \langle S^*, S^* \rangle + 2\langle S, S^* \rangle - 2\langle f, S \rangle - 2\langle S^*, S^* \rangle + 2\langle f, S^* \rangle$
- $= \|S - S^*\|_2^2 + \cancel{2\langle S, S^* - f \rangle} - \cancel{2\langle S^* - f, S^* \rangle} \geq 0$ 得证!

- **算法6.1:** 根据被逼近函数 f 与基函数 $\varphi_1, \dots, \varphi_n$, 形成法方程

对矩阵 G 进行Cholesky分解 $G = LL^T$

分两步求解方程 $LL^T x = b$, 得到 x , $S^* = \sum_{i=1}^n x_i \varphi_i$

- 计算逼近误差: $\|\delta\|_2 = \|S^* - f\|_2$

$$\|\delta\|_2^2 = \cancel{\langle S^* - f, S^* \rangle} - \langle S^* - f, f \rangle = \langle f - S^*, f \rangle = \|f\|_2^2 - \sum_{j=1}^n x_j^* \langle \varphi_j, f \rangle$$

最佳平方逼近

多项式函数可对 $C[a,b]$ 上函数逼近得任意好

Th6.3 (Weierstrass定理)

■ 最佳平方逼近多项式

□ $\Phi = \mathbb{P}_{n-1}$, 次数不超过 $n-1$ 的所有多项式函数的集合

□ 基函数为 $\{1, t, \dots, t^{n-1}\}$

(假设定义域为 $[0, 1]$)

□ 列法方程求解, 系数 $G_{kj} =$

$$\langle \varphi_j, \varphi_k \rangle = \int_0^1 t^{k+j-2} dt = \frac{1}{k+j-1}, \text{ 则 } G_n = \begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n} & \frac{1}{n+1} & \cdots & \frac{1}{2n-1} \end{bmatrix}$$

*Hilbert*矩阵

■ 两方面问题

□ n 较大时, G_n 高度病态

□ 当 n 很大时, 求解稠密线性方程组的计算量很大

□ **改进方法**: 用一组正交的基函数, G_n 变为对角阵!

正交函数族与正交多项式

■ 正交函数族

- 带权内积 $\langle f(t), g(t) \rangle = \int_a^b \rho(t) f(t) g(t) dt = 0$ 正交
- $[a, b]$ 上的正交函数族 $\{\varphi_k(t)\}$: 若它们两两正交 (定义6.4)
- 例: $[-\pi, \pi]$ 上的函数族: $1, \cos t, \sin t, \cos(2t), \sin(2t), \dots$,

■ 正交多项式

$\mathbb{P}_{n-1}$ 的一组正交基

- n 个次数不超过 $n-1$ 的正交多项式函数 $\{\varphi_1(t), \dots, \varphi_n(t)\}$
- 逐个正交化过程(Gram-Schmidt)构造正交基

由基 $\{1, t, t^2, \dots, t^{n-1}\}$ 开始, $\varphi_1(t) = 1$,

$$\varphi_k(t) = t^{k-1} - \sum_{j=1}^{k-1} \frac{\langle t^{k-1}, \varphi_j(t) \rangle}{\langle \varphi_j(t), \varphi_j(t) \rangle} \varphi_j(t)$$

性质(1): $\varphi_k(t)$ 是最高次项系数为1的 $k-1$ 次多项式

... ..

性质(5): $\varphi_k(t) = 0$ 的 $k-1$ 个根都是 (a, b) 上的单实根

勒让德多项式

如果 $\{\varphi_1(t), \dots, \varphi_n(t)\}$ 是正交多项式, G_n 为对角阵

- 法方程变得极简单, 易得逼近结果 $S^*(t) = \sum_{k=1}^n \frac{\langle f(t), \varphi_k(t) \rangle}{\langle \varphi_k(t), \varphi_k(t) \rangle} \varphi_k(t)$
- $[-1, 1]$ 上, $\rho(t) \equiv 1$, 正交多项式为勒让德多项式(罗德利克形式)

名称	定义域	权函数	表达式 / 递推公式
勒让德多项式	$[-1, 1]$	$\rho(t)=1$	$\begin{cases} P_0(t) = 1, & P_1(t) = t, \\ (k+1)P_{k+1}(t) = (2k+1)tP_k(t) - kP_{k-1}(t), & k = 1, 2, \dots \end{cases}$
切比雪夫多项式	$[-1, 1]$	$\rho(t)=\frac{1}{\sqrt{1-t^2}}$	$\begin{cases} T_0(t) = 1, & T_1(t) = t, \\ T_{k+1}(t) = 2tT_k(t) - T_{k-1}(t), & k = 1, 2, \dots \end{cases}$
切比雪夫多项式-2	$[-1, 1]$	$\rho(t)=\sqrt{1-t^2}$	$\begin{cases} U_0(t) = 1, & U_1(t) = 2t, \\ U_{k+1}(t) = 2tU_k(t) - U_{k-1}(t), & k = 1, 2, \dots \end{cases}$
拉盖尔多项式	$[0, +\infty]$	$\rho(t)=e^{-t}$	$\begin{cases} L_0(t) = 1, & L_1(t) = 1 - t, \\ L_{k+1}(t) = (1 + 2k - t)L_k(t) - k^2L_{k-1}(t), & k = 1, 2, \dots \end{cases}$
埃尔米特多项式	$(-\infty, +\infty)$	$\rho(t)=e^{-t^2}$	$\begin{cases} H_0(t) = 1, & H_1(t) = 2t, \\ H_{k+1}(t) = 2tH_k(t) - 2kH_{k-1}(t), & k = 1, 2, \dots \end{cases}$

用正交多项式求最佳平方逼近

■ 一般定义域上的勒让德(Legendre)多项式(罗德利克形式)

□ $P_k(t) \sim [-1, 1]$ $P_0(t) = 1, \quad P_1(t) = t$? $\sim [a, b]$

□ $\{P_k(t)\}$ 的特点是: 积分 $I = \int_{-1}^1 P_j(t)P_k(t)dt = 0, j \neq k$ $= \frac{2}{2k+1}, j=k$

□ 求 $[a, b]$ 上正交多项式: 通过变量代换使积分限变化

□ 变量代换 $\begin{cases} -1 \rightarrow a \\ 1 \rightarrow b \end{cases}, \quad s = \frac{b-a}{2}t + \frac{b+a}{2}, \quad t = \frac{2s - (a+b)}{b-a}$

$$I = \int_a^b \underbrace{P_j\left(\frac{2s - (a+b)}{b-a}\right)}_{\tilde{P}_j(s)} P_k\left(\frac{2s - (a+b)}{b-a}\right) \cdot \frac{2}{b-a} ds$$

$s \in [a, b]$ 的正交多项式 $\tilde{P}_j(s) = P_j\left(\frac{2s - (a+b)}{b-a}\right) \Rightarrow \langle \tilde{P}_j(t), \tilde{P}_k(t) \rangle = 0, \quad j \neq k$
 $\langle \tilde{P}_k(t), \tilde{P}_k(t) \rangle = \frac{b-a}{2} \cdot \frac{2}{2k+1}$

用正交多项式求最佳平方逼近

$$\tilde{P}_k(t) = P_k\left(\frac{2t - (a+b)}{b-a}\right)$$

- **例6.3:** $f(t) = \sqrt{1+t^2}, t \in [0, 1]$, 利用正交多项式求 $f(t)$ 的一次最佳平方逼近多项式

- 解: $\tilde{P}_0(t) = 1, \tilde{P}_1(t) = P_1(2t-1) = 2t-1$

法方程的解为

$$x_1^* = \frac{\langle f(t), \tilde{P}_0(t) \rangle}{\langle \tilde{P}_0(t), \tilde{P}_0(t) \rangle} = \frac{\int_0^1 \sqrt{1+t^2} dt}{\int_0^1 dt} \approx 1.147$$

$$x_2^* = \frac{\langle f(t), \tilde{P}_1(t) \rangle}{\langle \tilde{P}_1(t), \tilde{P}_1(t) \rangle} = \frac{\int_0^1 \sqrt{1+t^2} (2t-1) dt}{\int_0^1 (2t-1)^2 dt} \approx 0.213$$

$$S_1^*(t) = 1.147 + 0.213(2t-1) = 0.934 + 0.426t$$


- 正交函数族做最佳平方逼近

□ 计算方便; 算法稳定性好; 便于基函数的增、删

- **Th6.5:** $\forall f(t) \in C[a, b]$, 其最佳平方逼近多项式收敛; 逼近误差一致收敛

$$n \rightarrow \infty \quad \|e(t)\|_2 \rightarrow 0 \quad \text{若2阶导连续, } \|e(t)\|_\infty \leq \frac{\varepsilon}{\sqrt{n}}$$

与例6.1
结果一致



曲线拟合的最小二乘法

曲线拟合问题



实例演示Matlab, Excel


■ 目标

- 发现数据的规律, “回归分析”
- 由于数据可能有误差, 逼近曲线不必通过所有点

■ 问题描述

- 数据点 (t_i, f_i) , $(i=1, \dots, m)$, 用含参数的函数 $S(t)$ 来拟合
- 拟合要求: $\sum_{i=1}^m [S(t_i) - f_i]^2$ 最小, “**最小二乘**” 几何意义?
- 若 $S(t) \in \Phi$, $S(t) = \sum_{j=1}^n x_j \varphi_j(t)$, 求系数 x_j , **线性最小二乘**
- 定义在离散点 $\{t_i\}$ 上的**表格函数**构成线性空间 是一种最佳平方逼近!

通常
 $m > n$



线性最小二乘 (Linear Least Squares)

■ 问题的矩阵表述

□ 用函数值构成的向量表示定义在离散点 t_i , ($i = 1, \dots, m$) 上的表格函数 $f(t) \Rightarrow \mathbf{f} = [f(t_1), \dots, f(t_m)]^T$

□ 表格函数的2-范数: $\|f(t)\|_2 = \|\mathbf{f}\|_2 = \left[\sum_{i=1}^m |f(t_i)|^2 \right]^{1/2}$

□ 曲线拟合的线性最小二乘: $f(t) \approx \sum_{j=1}^n x_j \varphi_j(t)$

设 $A = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \cdots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \cdots & \varphi_n(t_2) \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \cdots & \varphi_n(t_m) \end{bmatrix}$ $\mathbf{f} \approx \mathbf{Ax}$, 或记为 $\mathbf{Ax} \cong \mathbf{f}$
求 $\mathbf{x}$, 使 $\|\mathbf{f} - \mathbf{Ax}\|_2$ 最小

解 $\mathbf{x}$ 称为最小二乘解, 进而得 $S(t) = \sum_{j=1}^n x_j \varphi_j(t)$ 除以 $\sqrt{m}$ 得均方根误差(RMSE)

线性最小二乘 – 法方程法

■ 法方程方法: 求解 $Gx = b$

$$G = \begin{bmatrix} \langle \varphi_1, \varphi_1 \rangle & \langle \varphi_2, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_1 \rangle \\ \langle \varphi_1, \varphi_2 \rangle & \langle \varphi_2, \varphi_2 \rangle & \cdots & \langle \varphi_n, \varphi_2 \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_1, \varphi_n \rangle & \langle \varphi_2, \varphi_n \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \end{bmatrix}, \quad b = \begin{bmatrix} \langle f, \varphi_1 \rangle \\ \langle f, \varphi_2 \rangle \\ \vdots \\ \langle f, \varphi_n \rangle \end{bmatrix}$$

$$A = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \cdots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \cdots & \varphi_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \cdots & \varphi_n(t_m) \end{bmatrix} \quad A = [\varphi_1 \quad \varphi_2 \quad \cdots \quad \varphi_n]$$
$$A^T = \begin{bmatrix} \varphi_1^T \\ \varphi_2^T \\ \vdots \\ \varphi_n^T \end{bmatrix} \quad \xrightarrow{\text{green arrow}} \quad G = A^T A$$
$$b = A^T f$$

算法6.2

- 形成矩阵 A ; 得到 $A^T A x = A^T f$; 解之 $\xrightarrow{\text{blue arrow}} A$ 列满秩
- 若表格函数 $\varphi_1(t), \dots, \varphi_n(t)$ 线性无关, 法方程存在唯一解

线性最小二乘 – 法方程法

■ 法方程方法: 求解 $A^T A x = A^T f$

□ 不同于连续函数, 表格函数是否线性无关受 $\{t_i\}$ 取值影响

□ 例: $\{t_i = 0, \pi, 2\pi\}$ 时, 表格函数 $\sin t, \sin(2t)$ 是线性相关的

Haar条件:


判断线性
无关

□ 一个结论: 若 $t_i, (i = 1, \dots, m)$ 中至少有 n 个不同的值, 则 $\mathbb{P}_{n-1}$ 的基函数对应的表格函数 **线性无关** (多项式拟合好判断)

■ 无论离散点 t_i 是否有相同的

□ 按 **数据点** 逐行形成矩阵 A 、向量 f

$$A = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \cdots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \cdots & \varphi_n(t_2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \cdots & \varphi_n(t_m) \end{bmatrix} \longrightarrow Ax \cong f$$



否则, 要看 A 是否列满秩

当 $\{t_i\}$ 中不同值数目 $>$ 拟合多项式的多项式次数, 算法 6.2 一定有唯一解

线性最小二乘 – 正交变换法

■ 正交变换法解线性最小二乘

□ 法方程方法的缺点: 当 n 较大时, 病态性 (类似于连续函数)

□ 计算 $A^T A$, 数值误差也较显著

□ 改进: 构造表格函数的正交基(依赖自变量点) 例6.6, 自己看

1965年, □ 等价的实用方法: 用QR分解实现基函数的正交化

G. Golub
提出

设按任意一组基函数 $\{\varphi_1(t), \dots, \varphi_n(t)\}$, 它们在自变量点上的函数值构成矩阵 A , 被逼近函数值向量为 f

求拟合系数 x , 它使得 $\|f - Ax\|_2$ 达到最小值

$$A = QR \longrightarrow f - Ax = Q(Q^T f - Rx) \longrightarrow \|f - Ax\|_2 = \|Q^T f - Rx\|_2$$

Q 是正交阵 问题转化为: 求 x , 使得 $\|Q^T f - Rx\|_2$ 达到最小值

线性最小二乘 – 正交变换法

精简QR分解

$$\text{解 } Q_1 R_1 x \cong f$$

正交基

$$\text{解 } Ax \cong f \quad R_1 x = Q_1^T f$$

■ 正交变换法解线性最小二乘 (续)

$$A = \underset{m \times n}{Q} \underset{m \times m}{R} \underset{m \times n}{R} \quad \text{求 } x, \text{ 使得 } \|Q^T f - Rx\|_2 \text{ 达到最小值}$$

$$\text{设 } Q = \begin{bmatrix} Q_1 & Q_2 \\ \text{n列} & \end{bmatrix}, R = \begin{bmatrix} R_1 \\ O \end{bmatrix}^{n \text{行}}, Q^T f - Rx = \begin{bmatrix} Q_1^T \\ Q_2^T \end{bmatrix} f - \begin{bmatrix} R_1 \\ O \end{bmatrix} x = \begin{bmatrix} Q_1^T f - R_1 x \\ Q_2^T f \end{bmatrix}$$

$$\|Q^T f - Rx\|_2^2 = \|Q_1^T f - R_1 x\|_2^2 + \|Q_2^T f\|_2^2 \geq \|Q_2^T f\|_2^2 \quad \text{取等号条件: } R_1 x = Q_1^T f$$

■ 算法6.3 Householder变换作用于 f 得 $Q^T f$, $Q_1^T f$ 是它前 n 行

- 根据基函数 $\varphi_1, \dots, \varphi_n$ 在离散点 $t_1, \dots, t_m$ 上的取值形成 A
- 用算法5.3将 A 正交三角化成 R , 同时将 f 变换为 $\tilde{f} = Q^T f$
- $R_1 := R(1:n, :)$, $b := \tilde{f}(1:n)$, 用回代法(算法3.2)解 $R_1 x = b$
数值稳定, 实用 若 A 不是列满秩, 解不唯一! ...

线性最小二乘

Excel 例子

- 例6.5: 一组数据如下表, 用适当的函数对它们进行拟合

t_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46
$\tilde{y}_i$	1.6292	1.7561	1.8764	2.0082	2.1353

(非线性函数关系怎么用
线性最小二乘拟合?)

- 解: 在直角坐标系里绘出这些数据点, 根据其分布趋势, 采用指数函数来描述: $y \approx x_1 e^{x_2 t}$
不能直接用线性最小二乘, 需做变换 $\ln(y) \approx \ln(x_1) + x_2 t$
线性拟合基函数 $\varphi_1(t) = 1, \varphi_2(t) = t$

$$A = \begin{bmatrix} 1 & 1.00 \\ 1 & 1.25 \\ 1 & 1.5 \\ 1 & 1.75 \\ 1 & 2.00 \end{bmatrix}, f = \begin{bmatrix} 1.6292 \\ 1.7561 \\ 1.8764 \\ 2.0082 \\ 2.1353 \end{bmatrix}$$

要解 $A^T A x = A^T f$, 即 解得:

$$\begin{bmatrix} 5 & 7.5 \\ 7.5 & 11.875 \end{bmatrix} \begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 9.4052 \\ 14.4239 \end{bmatrix} \quad \begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.1225 \\ 0.5057 \end{bmatrix}$$

$$\longrightarrow x_1 = e^{\tilde{x}_1} = 3.0725$$

最后的解为 $S(t) = 3.0725 e^{0.5057t}$

线性最小二乘

- 例6.7: 对例6.5的问题, 用矩阵正交变换的方法求解

t_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46
$\tilde{y}_i$	1.6292	1.7561	1.8764	2.0082	2.1353

- 解: 用指数函数形式 $y \approx x_1 e^{x_2 t}$, 变换为 $\ln(y) \approx \ln(x_1) + x_2 t$
线性最小二乘拟合 $\tilde{y} = \tilde{x}_1 + x_2 t$ (基函数 $\varphi_1(t) = 1, \varphi_2(t) = t$)

解 $Ax \cong f$: 用Householder变换对A作正交三角化

$$A = \begin{bmatrix} 1 & 1.00 \\ 1 & 1.25 \\ 1 & 1.5 \\ 1 & 1.75 \\ 1 & 2.00 \end{bmatrix}, f = \begin{bmatrix} 1.6292 \\ 1.7561 \\ 1.8764 \\ 2.0082 \\ 2.1353 \end{bmatrix}$$

第一个变换用的 $v_1 = \begin{bmatrix} 1+\sqrt{5} \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$, 则

$$\begin{bmatrix} -2.236 & -3.354 \\ 0 & -0.095 \\ 0 & 0.155 \\ 0 & 0.405 \\ 0 & 0.655 \end{bmatrix} x \cong \begin{bmatrix} -4.206 \\ -0.047 \\ 0.073 \\ 0.205 \\ 0.332 \end{bmatrix}$$

再做第二个变换得

$$\begin{bmatrix} -2.236 & -3.354 \\ 0 & 0.791 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} x \cong \begin{bmatrix} -4.206 \\ 0.400 \\ -0.005 \\ 0.001 \\ 0.002 \end{bmatrix}$$

解得:

$$\begin{bmatrix} \tilde{x}_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.1225 \\ 0.5057 \end{bmatrix}$$

线性最小二乘

■ Matlab命令


$m \times n$ 矩阵, $m > n$

- 线性最小二乘问题 $Ax \cong b$,
- `>> x=A \ b`
- 其内部算法主要是 **算法6.3**

$$A = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \cdots & \varphi_n(t_1) \\ \varphi_1(t_2) & \varphi_2(t_2) & \cdots & \varphi_n(t_2) \\ \vdots & \vdots & \vdots & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \cdots & \varphi_n(t_m) \end{bmatrix}$$

$m < n$ 的情况它也可以解 ...

- 用不超过 n 次的多项式拟合离散点 (x_i, y_i)
- `>> p = polyfit (x, y, n)`
- 拟合多项式的系数存于向量 p , 相关命令还有 `polyval`



多项式插值

插值与多项式插值

Word/Power Point中的绘图按钮




■ 插值的基本概念

- 为离散点配曲线, 并要求曲线通过各个离散点
- 一种特殊的“逼近”

■ 目的与用途

- **Office**软件中曲线绘制功能
- **图形学/CAD**: 画一条通过离散点的光滑曲线
- 假设数据无误差时做函数“拟合”, 估算中间点函数值
- 快速方便地计算复杂数学函数的函数值
- **其他方法的基础**: 简单函数近似**复杂的**或**未知**函数
(非线性方程、数值积分与微分、微分方程数值解法)



插值与多项式插值

最小二乘拟合 $Ax \cong f$
当数据点与拟合参数一样多时

■ 插值问题

- **定义6.6:** 设 $x_0, x_1, \dots, x_n$ 满足 $a \leq x_0 < x_1 < \dots < x_n \leq b$, 它们对应的函数 $f(x)$ 值为 $y_0, y_1, \dots, y_n$, 若 $P(x) \in C[a, b]$ 使得 $P(x_i) = y_i$, ($i = 0, 1, \dots, n$), 则 $P(x)$ 为 $f(x)$ 的插值函数
- 插值节点: $x_0, \dots, x_n$; 插值区间、插值问题
- 不同于曲线拟合: 要求数据点的自变量值互不相同

■ 问题的类型

- 多项式插值 $P(x) = a_0 + a_1x + \dots + a_nx^n$
- 分段插值; 三角插值 **DFT** $P(x) = \begin{cases} \dots, x \in [x_0, x_1] \\ \dots, x \in [x_1, x_2] \\ \dots \end{cases}$
- 有理分式插值: $P(x) = \frac{a_0 + a_1x + \dots + a_nx^n}{b_0 + b_1x + \dots + b_mx^m}$

插值与多项式插值

■ 多项式插值

- 求n次多项式 $P(x) = a_0 + a_1x + \cdots + a_{n-1}x^{n-1} + a_nx^n$
 - 满足n+1个插值点的条件 $P(x_i) = y_i, (i = 0, 1, \cdots, n)$
 - 多项式插值问题、插值多项式
 - $a_0, a_1, \dots, a_n$ 满足线性方程组
 - **定理6.6:** Vandermonde矩阵
- $$\begin{cases} a_0 + a_1x_0 + \cdots + a_nx_0^n = y_0 \\ a_0 + a_1x_1 + \cdots + a_nx_1^n = y_1 \\ \cdots \\ a_0 + a_1x_n + \cdots + a_nx_n^n = y_n \end{cases}$$

$$V = \begin{bmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^n \end{bmatrix} \quad \text{非奇异}$$

解存在、唯一吗?

比较病态

- **证明:** 反证法. 设V奇异, 则存在一组不全为0的系数 $\{a_i\}$, 使 $Va = 0$, 这些系数对应的多项式 $P(x)$ 在n+1个点上的值均为0, 即n次多项式方程有n+1个不同的根. 矛盾!

Lagrange插值法

■ 如何求插值多项式？

- 待定系数法, 解线性方程组 不便于计算、理论分析
- Lagrange(拉格朗日)插值法

■ $n=1$ 的情况


- 插值节点: x_0, x_1 , 函数值: y_0, y_1 , 求一次多项式

“两点式”直线公式: $y = \frac{x-x_1}{x_0-x_1} y_0 + \frac{x-x_0}{x_1-x_0} y_1$


- 插值多项式看成是基函数的线性组合

$$L_1(x) = y_0 l_0(x) + y_1 l_1(x)$$

- 插值基函数 $l_k(x)$ 特点: 1次多项式, 且 $l_k(x_i) = \begin{cases} 1, & i=k \\ 0, & i \neq k \end{cases}$
($k = 0, 1$)



Lagrange插值法



■ 推广到 $n > 1$ (求 n 次多项式 $L_n(x)$)

□ 插值节点: $x_0, x_1, \dots, x_n$, 函数值: $y_0, y_1, \dots, y_n$

Lagrange

插值函数

$$L_n(x) = \sum_{k=0}^n y_k l_k(x), \text{ 基函数 } l_k(x) \in \mathbb{P}_n, \text{ 且 } l_k(x_i) = \begin{cases} 1, i = k \\ 0, i \neq k \end{cases}$$

□ 如何求 $l_k(x)$?

(一个常用的技巧)

设 $l_k(x) = g \cdot (x - x_0) \cdots (x - x_{k-1})(x - x_{k+1}) \cdots (x - x_n)$

根据条件 $l_k(x_k) = 1$, 确定 g 的值

$$\longrightarrow l_k(x) = \frac{(x - x_0) \cdots (x - x_{k-1})(x - x_{k+1}) \cdots (x - x_n)}{(x_k - x_0) \cdots (x_k - x_{k-1})(x_k - x_{k+1}) \cdots (x_k - x_n)}$$

设 $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$

$$\text{则 } \omega'_{n+1}(x_k) = \prod_{j \neq k} (x_k - x_j) \longrightarrow L_n(x) = \sum_{k=0}^n y_k \frac{\omega_{n+1}(x)}{(x - x_k) \omega'_{n+1}(x_k)}$$

多项式插值误差估计

■ Lagrange插值余项 $(R_n(x) \triangleq f(x) - L_n(x))$

□ **定理6.7:** $f(x) \in C^n[a, b]$, $n+1$ 阶导数存在, 则

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \text{ 其中 } \xi \in (a, b), \text{ 且依赖于 } x$$

□ **证明:** 首先注意到 $R_n(x)$ 在 $n+1$ 个插值节点上的值为0


设 $x \neq$ 插值节点 设 $R_n(x) = f(x) - L_n(x) = g(x)(x-x_0) \cdots (x-x_n) = g(x)\omega_{n+1}(x)$

为求 $g(x)$, 做辅助函数 $\varphi(t) = f(t) - L_n(t) - g(x)(t-x_0) \cdots (t-x_n)$

考察 $\varphi(t) = 0$ 的根, 至少有 $n+2$ 个: $t = x_i, (i = 0, \dots, n), t = x$

考察 $\varphi'(t)$ 的零点, 至少有 $n+1$ 个互不相同的

Rolle定理


 $f'(\xi) = 0 \implies \dots, \varphi^{(n+1)}(t) \text{ 至少有 1 个零点, 记为 } \xi$
 $\varphi^{(n+1)}(\xi) = f^{(n+1)}(\xi) - g(x) \cdot (n+1)! = 0 \implies g(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!}$

为 $f(x)$ 的插值多项式
(插值节点 $x_0, x_1, \dots, x_n$)

Lagrange插值小结

- **Lagrange插值及余项公式** $R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$
 - 估算非插值节点处的函数值
 - 用余项估计插值误差: 虽然 ξ 的值不确定, 但 $\xi \in (a, b)$, 有时可估计 $f^{(n+1)}(\xi)$ 的取值范围 (例6.8)
 - **算法6.4**: 用Lagrange插值计算函数值

- **Lagrange插值法**

- **特点**: 公式结构对称、便于记忆与编程, 便于分析 $L_n(x) = \sum_{k=0}^n y_k \frac{\omega_{n+1}(x)}{(x - x_k) \omega'_{n+1}(x_k)}$
- **注意**: 当增加或减少一个插值节点时, 公式变化较大

Newton插值

■ 差商

□ **定义6.7**: 函数 $f(x)$ 关于一系列互不相等点的 k 阶差商

关于 x_i 的0阶差商: $f[x_i] = f(x_i)$

关于 x_0, x_i 的1阶差商: $f[x_0, x_i] = \frac{f(x_i) - f(x_0)}{x_i - x_0}$

关于 $x_0, x_1, \dots, x_k$ 的 k 阶差商:
(递归定义) $f[x_0, x_1, \dots, x_k] = \frac{f[x_0, \dots, x_{k-2}, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_{k-1}}$

Th6.8 □ $x_0, x_1, \dots, x_k$ 为互不相等的值, 则

用数学归纳法证明

$$f[x_0, \dots, x_k] = \sum_{j=0}^k \frac{f(x_j)}{\prod_{l=0, l \neq j}^k (x_j - x_l)} \rightsquigarrow \omega'_{k+1}(x_j)$$

Th6.9

□ 差商自变量顺序可任意: $f[x_0, x_1, \dots, x_k] = \dots = f[x_k, \dots, x_1, x_0]$

差商计算的对称性: $f[x_0, \dots, x_k] = \frac{f[x_1, \dots, x_k] - f[x_0, \dots, x_{k-1}]}{x_k - x_0}$

Newton插值

■ 与Lagrange插值等价的另一种形式

- 考虑插值节点数目逐渐增加的情况


■ 基本思想

- 最简单情况: 一个插值点 x_0 , 函数值 $f(x_0)$
- 增加一节点 x_1 及 $f(x_1)$, 求 $P_1(x)$

插值多项式

$$P_0(x) = f(x_0)$$

“点斜式”直线公式: $P_1(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_0)$



- 即 $P_1(x) = f[x_0] + f[x_0, x_1](x - x_0)$
- 再增加 x_2 及 $f(x_2)$, 设插值多项式为

$$P_2(x) = f[x_0] + f[x_0, x_1](x - x_0) + c_2(x - x_0)(x - x_1)$$

- 代入 $P_2(x) = f(x_2)$, 求出 $c_2 = f[x_0, x_1, x_2]$ 依此类推 ...

Newton插值

■ Newton插值多项式 (设节点按 $x_0, x_1, \dots$ 的顺序增加)

$$N_n(x) = c_0 + c_1(x - x_0) + \dots + c_n(x - x_0) \cdots (x - x_{n-1})$$

□ 其中 $c_k = f[x_0, \dots, x_k]$, $k = 0, 1, \dots, n$

■ 例6.9: 设有3个数据点(-2, -27), (0, -1)和(1, 0), 分别用牛顿插值法和拉格朗日插值法求二次多项式

□ 先做牛顿插值, 构造差商表

□ 写出插值多项式

$$\begin{aligned} N_2(x) &= -27 + 13(x+2) - 4(x+2)x \\ &= -4x^2 + 5x - 1 \end{aligned}$$

□ 拉格朗日插值:

$$\begin{aligned} L_2(x) &= -27 \cdot \frac{x(x-1)}{-2 \cdot -3} + (-1) \cdot \frac{(x+2)(x-1)}{2 \cdot -1} \\ &= -\frac{9}{2}(x^2 - x) + \frac{1}{2}(x^2 + x - 2) = -4x^2 + 5x - 1 \end{aligned}$$

x_k	$f(x_k)$	1阶差商	2阶差商
-2	-27		
0	-1	13	
1	0	1	-4

Newton插值

■ Newton插值余项 (多项式插值余项的另一种形式)

设 $x \in [a, b]$, $x \neq x_0, \dots, x_n$

$$f(x) = f(x_0) + f[x, x_0](x - x_0),$$

$$f[x, x_0] = f[x_0, x_1] + f[x, x_0, x_1](x - x_1),$$

$$f[x, x_0, x_1] = f[x_0, x_1, x_2] + f[x, x_0, x_1, x_2](x - x_2), \quad + \dots$$

... ..

$$f[x_0, \dots, x_n](x - x_0) \cdots (x - x_{n-1}) + \dots$$

$$f[x, x_0, \dots, x_{n-1}] = f[x_0, \dots, x_n] + f[x, x_0, \dots, x_n](x - x_n).$$

$$\square f(x) = N_n(x) + \underline{f[x, x_0, \dots, x_n](x - x_0) \cdots (x - x_n)} \quad \text{插值余项}$$

□ 由于插值多项式的唯一性,

$$f[x, x_0, \dots, x_n] = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \quad \xi \in (a, b)$$

注意: 隐含了 $f(x)$, 不好算

小结

■ 多项式插值方法比较

计算复杂, n 较大时病态

□ 待定系数法: $P_n(x) = a_0 + a_1x + \cdots + a_nx^n$


□ Lagrange插值: $L_n(x) = \sum_{k=0}^n y_k l_k(x)$

$$\begin{bmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \cdots & x_n^n \end{bmatrix}$$

□ Newton插值: 先计算差商表, $N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \cdots + f[x_0, \dots, x_n](x - x_0) \cdots (x - x_{n-1})$

便于动态增、减插值节点

思考题: 比较后两种插值法计算未知点处函数值的计算量



分段多项式插值

高次多项式插值的问题

单个多项式的插值公式: 光滑性好、易于理论分析


■ 收敛性差

Runge现象: 并非插值多项式的次数 n 越高, 就逼近得越好

$$f(x) = \frac{1}{1+x^2}, x \in [-5, 5]$$

做等距节点插值, $L_n(x)$

$$\lim_{n \rightarrow \infty} L_n(x) \begin{cases} = f(x), |x| \leq c \\ \text{不收敛}, |x| > c \end{cases}, (c \approx 3.63)$$



■ 保凸性差

□ 有多余拐点(起伏), 违背曲线的凸性(单调性)


■ 数值稳定性差: 某个插值点函数值的误差影响整个区间 (问题的病态性与算法的稳定性一起考虑)

分段线性插值

■ 基本思想

□ 插值数据点连成折线

□ 设 $x_0 < x_1 < \dots < x_n$, 相应函数值为 $f_0, f_1, \dots, f_n$, 则分段线性插值函数 $I_h(x)$ 满足: 当 $x \in [x_j, x_{j+1}]$ 时,




$$I_h(x) = \frac{x - x_{j+1}}{x_j - x_{j+1}} f_j + \frac{x - x_j}{x_{j+1} - x_j} f_{j+1}$$

■ 整体表达式 $I_h(x) = \sum_{j=0}^n f_j l_j(x)$

□ 基函数

$$l_j(x) = \begin{cases} \frac{x - x_{j-1}}{x_j - x_{j-1}}, & x_{j-1} \leq x \leq x_j \text{ (} j=0 \text{ 时略去)} \\ \frac{x - x_{j+1}}{x_j - x_{j+1}}, & x_j \leq x \leq x_{j+1} \text{ (} j=n \text{ 时略去)} \\ 0, & x \notin [x_{j-1}, x_{j+1}] \end{cases}$$



$l_j(x)$ 只在 x_j 附近非零
(局部非零性质)

分段线性插值

- 分段线性插值函数 $I_h(x) = \sum_{j=0}^n f_j l_j(x)$
 - $I_h(x) \in C[a, b]$
 - 在每个小区间上是一次多项式 $\frac{f''(\xi)}{2}(x - x_j)(x - x_{j+1})$
 - 每个小区间内插值误差为Lagrange余项, 则
$$|f(x) - I_h(x)| \leq \frac{M_2}{2} \max_{x_j \leq x \leq x_{j+1}} |(x - x_j)(x - x_{j+1})| \leq \frac{M_2}{8} h^2$$
其中 $M_2 = \max_{a \leq x \leq b} |f''(x)|$ $h = \max_j (x_{j+1} - x_j)$
 - 分段线性插值的收敛性

定理6.10: 设 $f(x) \in C^2[a, b]$, 则

$$\lim_{h \rightarrow 0} I_h(x) = f(x), \forall x \in [a, b], \text{ 其中 } h = \max_j (x_{j+1} - x_j)$$

分段埃尔米特(Hermite)插值

■ 整体Hermite插值

- 插值条件不仅包括函数值, 还包括导数值

$$P(x_i) = f(x_i), \quad P'(x_i) = f'(x_i)$$

- 常考虑插值条件中函数值与导数值个数相等的情况

- 在插值节点 x_i , ($i = 0, 1, \dots, n$)上, 记 $f(x_i)$ 为 f_i , $f'(x_i)$ 为 f'_i
求插值多项式 $H(x)$, 满足 $H(x_i) = f_i$, $H'(x_i) = f'_i$

- 解的存在性与唯一性 (证明类似定理6.6) 称为埃尔米特插值多项式
插值多项式的存在唯一性

2n+2个条件, 确定次数不超过2n+1的多项式 $H_{2n+1}(x)$

- 类似于Lagrange插值的公式

$$H_{2n+1}(x) = \sum_{j=0}^n [f_j \alpha_j(x) + f'_j \beta_j(x)]$$

分段埃尔米特(Hermite)插值

- 整体Hermite插值 $H_{2n+1}(x) = \sum_{j=0}^n [f_j \alpha_j(x) + f'_j \beta_j(x)]$
 - 基函数须满足如下要求

$$\alpha'_j(x_i) = 0, \quad \forall i$$

$$\alpha_j(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

$\longrightarrow$

$$\alpha_j(x) = [1 - 2(x - x_j)l'_j(x_j)]l_j^2(x)$$

其中 $l_j(x)$ 为Lagrange插值基函数

验证它们！

$$\beta'_j(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \quad \longrightarrow \quad \beta_j(x) = (x - x_j)l_j^2(x)$$

$$\beta_j(x_i) = 0, \quad \forall i$$
 - 特殊Hermite插值多项式如何推导？

例6.11: 求满足插值条件 $P(x_j) = f(x_j), (j = 0, 1, 2)$ 及 $P'(x_1) = f'(x_1)$ 的插值多项式 $P(x)$ (插值余项不要求)

解: 设 $P(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1)$
 再根据 $P'(x_1) = f'(x_1)$, 求出 $A + A(x - x_0)(x - x_1)(x - x_2)$

分段埃尔米特(Hermite)插值

■ 两点三次埃尔米特插值多项式

□ 即 $n=1$ 时的整体Hermite插值

设插值节点为 x_k, x_{k+1} ,


基函数: $H_3(x) = f_k \tilde{\alpha}_k(x) + f_{k+1} \tilde{\alpha}_{k+1}(x) + f'_k \tilde{\beta}_k(x) + f'_{k+1} \tilde{\beta}_{k+1}(x)$

$$\tilde{\alpha}_k(x) = \left(1 + 2 \frac{x - x_k}{x_{k+1} - x_k}\right) \left(\frac{x - x_{k+1}}{x_k - x_{k+1}}\right)^2$$

$$\tilde{\alpha}_{k+1}(x) = \left(1 + 2 \frac{x - x_{k+1}}{x_k - x_{k+1}}\right) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2$$

$$\tilde{\beta}_k(x) = (x - x_k) \left(\frac{x - x_{k+1}}{x_k - x_{k+1}}\right)^2$$

$$\tilde{\beta}_{k+1}(x) = (x - x_{k+1}) \left(\frac{x - x_k}{x_{k+1} - x_k}\right)^2$$




验证与推导?

类似于分段线性插值,
可得**分段三次埃尔米特插值** $H_h(x)$

$$H'_h(x_k - 0) = f'_k = H'_h(x_k + 0)$$

整体一阶导数连续



分段埃尔米特(Hermite)插值

■ 分段三次埃尔米特插值


$x \in [x_k, x_{k+1}]$ 时, $H_h(x) = f_k \tilde{\alpha}_k(x) + f_{k+1} \tilde{\alpha}_{k+1}(x) + f'_k \tilde{\beta}_k(x) + f'_{k+1} \tilde{\beta}_{k+1}(x)$

$\tilde{\alpha}_k(x), \tilde{\beta}_k(x)$ 表示两点三次埃尔米特插值的两种基函数

$H_h(x)$ 的整体公式 $H_h(x) = \sum_{j=0}^n [f_j \alpha_j(x) + f'_j \beta_j(x)]$

整体基函数 $\alpha_j(x) =$

$$\begin{cases} \left(1 + 2 \frac{x - x_j}{x_{j-1} - x_j}\right) \left(\frac{x - x_{j-1}}{x_j - x_{j-1}}\right)^2, & x_{j-1} \leq x \leq x_j (j=0 \text{ 时略去}) \\ \left(1 + 2 \frac{x - x_j}{x_{j+1} - x_j}\right) \left(\frac{x - x_{j+1}}{x_j - x_{j+1}}\right)^2, & x_j \leq x \leq x_{j+1} (j=n \text{ 时略去}) \\ 0, & x \notin [x_{j-1}, x_{j+1}] \end{cases}$$



局部非零的性质

思考: $\beta_j(x)$ 公式与图形?

类似分段线性插值(定理6.10), 可证分段埃尔米特插值收敛

保形分段插值 (shape-preserving)

■ 基本思想

- 分段三次Hermite插值需节点上的导数值, 不便提供
- 可根据插值节点的函数值来**设定导数值**
- 得到的曲线光滑, 且**保持数据点反映的单调性(凸性)**

■ 节点处导数的设定


- 对插值节点 x_k , 先计算两侧割线斜率(一阶差商)

$$d_{k-1} = \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}, \quad d_k = \frac{f(x_{k+1}) - f(x_k)}{x_{k+1} - x_k}$$

- 若 $d_{k-1}d_k \leq 0$, 令 $f'_k = 0$

- 否则取加权调和平均, $\frac{w_{k-1} + w_k}{f'_k} = \frac{w_{k-1}}{d_{k-1}} + \frac{w_k}{d_k}$

$$\text{权重 } w_{k-1} = h_{k-1} + 2h_k, \quad w_k = 2h_{k-1} + h_k$$




比算术/几何平均
得到的曲线更平缓

保形分段插值 (shape-preserving)

■ 节点处导数的设定 (续)

- 对两端的插值节点, f'_0 和 f'_n 的计算作类似的单侧分析
 - 注意: f'_0 与 d_0, d_1 都有关, $\neq d_0$
 - 一旦设定了导数值, 用分段三次Hermite插值确定插值公式
 - Matlab函数 `pchip` (piecewise cubic Hermite interpolating polynomial)
-
- Word/Power Point中的绘图按钮




Word/Power Point中的绘图按钮



■ 小结三种分段低次插值

- 收敛性好
- 保凸性好 (分段Hermite, 保形分段还有一定的光滑性)
- 数值稳定性好 (局部非零性质)




样条函数插值

三次样条插值

■ 目标

- 前面介绍的分段插值二阶导数不连续
- 样条(spline)是早期工程师绘图所用的薄木条, 将它固定在一些给定点上得到光滑曲线
- 在物理上, 样条势能达到最小, 曲线必二阶导数连续



■ 三次样条插值函数

- **定义6.8:** 给定插值节点 $x_0, x_1, \dots, x_n \in [a, b]$, 若函数 $S(x)$
 - 在每个小区间 $[x_j, x_{j+1}]$ 上为三次多项式
 - 整体二阶导数连续则称 $S(x)$ 为这些节点上的三次样条函数
- 若还满足 $S(x_j) = f(x_j)$, 则 $S(x)$ 为 $f(x)$ 的三次样条插值函数

三次样条插值

■ 如何确定 $S(x)$?


$$S(x) = \begin{cases} s_0(x), & x \in [x_0, x_1] \\ s_1(x), & x \in [x_1, x_2] \\ \vdots \\ s_{n-1}(x), & x \in [x_{n-1}, x_n] \end{cases}$$

其中 $s_j(x)$ 为三次多项式, 且

$$s_j(x_j) = f_j, s_j(x_{j+1}) = f_{j+1}$$

$$j = 0, 1, \dots, n-1$$

左导数=右导数




$$S(x) \in C^2[a, b] \longrightarrow \begin{cases} s'_{j-1}(x_j) = s'_j(x_j) \\ s''_{j-1}(x_j) = s''_j(x_j) \end{cases}$$
$$j = 1, 2, \dots, n-1$$

每个 $s_j(x)$ 为三次多项式, 有4个待定系数, 所以共有 $4n$ 个待定系数, 故需 $4n$ 个方程才能确定. 前面已经得到
 $2n + 2(n-1) = 4n - 2$ 个方程, 还缺2个方程!

三次样条插值

■ 确定 $S(x)$ 的额外条件

- 第1种边界条件: 给定函数在端点处的一阶导数 $S'(x_0) = f'_0, S'(x_n) = f'_n$
- 第2种边界条件: 给定函数在端点处的二阶导数 $S''(x_0) = f''_0, S''(x_n) = f''_n$ (若 $f''_0 = f''_n = 0$, 自然样条插值)
- 第3种边界条件: 设 $f(x)$ 是以 $x_n - x_0$ 为周期的周期函数 $S'(x_0) = S'(x_n), S''(x_0) = S''(x_n)$
(一般应要求 $f_0 = f_n$)
- 第4种边界条件: 设起始、结束的两个小区间上都为统一的三次多项式
(not-a-knot条件, Matlab中spline函数)



三次样条插值

■ 三次样条插值函数的构造

①以节点一阶导数为参数列分段Hermite公式, 再定参数

②以节点二阶导数为参数, 根据插值条件确定它们

□ 介绍第②种方法, 设 $S''(x_j) = M_j, (j = 0, \dots, n)$

小区间 $[x_j, x_{j+1}]$ 上
 $S''(x)$ 为一次多项式 $S''(x) = M_j \left(\frac{x - x_{j+1}}{x_j - x_{j+1}} \right) + M_{j+1} \left(\frac{x - x_j}{x_{j+1} - x_j} \right)$

做两次积分, 得 $= M_j \left(\frac{x_{j+1} - x}{h_j} \right) + M_{j+1} \left(\frac{x - x_j}{h_j} \right)$

$$S(x) = -\frac{M_j}{6h_j} (x - x_{j+1})^3 + \frac{M_{j+1}}{6h_j} (x - x_j)^3 + a_j x + b_j$$

利用 $S(x_j) = f_j, S(x_{j+1}) = f_{j+1}$, 确定 a_j, b_j 的值

三次样条插值

■ 三次样条插值函数的构造

$$S(x) = M_j \frac{(x_{j+1} - x)^3}{6h_j} + M_{j+1} \frac{(x - x_j)^3}{6h_j} + \left(f_j - \frac{M_j h_j^2}{6}\right) \frac{x_{j+1} - x}{h_j} + \left(f_{j+1} - \frac{M_{j+1} h_j^2}{6}\right) \frac{x - x_j}{h_j}$$

在上述构造过程中, 满足了节点上函数值、
以及二阶导数连续的插值要求

利用节点处一阶导数连续、及边界条件确定 M_j 的值

$$S'(x) = -M_j \frac{(x_{j+1} - x)^2}{2h_j} + M_{j+1} \frac{(x - x_j)^2}{2h_j} + \frac{f_{j+1} - f_j}{h_j} - \frac{M_{j+1} - M_j}{6} h_j, x \in [x_j, x_{j+1}]$$

$$\text{令 } x = x_j, S'(x_j + 0) = -\frac{h_j}{3} M_j - \frac{h_j}{6} M_{j+1} + \frac{f_{j+1} - f_j}{h_j} \quad \begin{matrix} M_{j-1}, M_j, M_{j+1} \text{ 满} \\ \text{足的方程} \end{matrix}$$

$$j \rightarrow j-1, \text{再令 } x = x_j, S'(x_j - 0) = \frac{h_{j-1}}{3} M_j + \frac{h_{j-1}}{6} M_{j-1} + \frac{f_j - f_{j-1}}{h_{j-1}}$$

三次样条插值

■ 三次样条插值函数的构造

□ 根据节点 x_j 上一阶导数连续, 得 $n-1$ 个方程

$$\mu_j M_{j-1} + 2M_j + \lambda_j M_{j+1} = d_j, (j = 1, \dots, n-1) \quad \mu_j + \lambda_j = 1$$

□ 第1种边界条件: $S'(x_0) = f'_0, S'(x_n) = f'_n$ (2个方程)

$$2M_0 + M_1 = \frac{6}{h_0} \left(\frac{f_1 - f_0}{h_0} - f'_0 \right) \quad \dots \quad \text{未知量为位移的二阶导数, 在力学上的意义为“弯矩”}$$

完整的 $(n+1) \times (n+1)$

线性方程组

(“三弯矩”方程)

严格对角占优阵

三对角阵

解存在、且唯一

$$\begin{bmatrix} 2 & 1 & & & \\ \mu_1 & 2 & \lambda_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & 1 & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ \vdots \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix}$$

三次样条插值

■ 三次样条插值函数的构造

- 对于第2~4种边界条件, 构造出类似的“三弯矩”方程
- 解出 $M_j, (j=0, \dots, n)$, 代入公式得三次样条插值函数
- 解 n 阶三对角线性方程组, 计算量 < 解 $4n$ 阶的方程组 (完全的待定系数法)

- 收敛性、稳定性、保凸性、光滑性好

- 例6.12: 与其他插值比较

“样条”光滑性好

“保形”更反映数据趋势, 且计算简单

